Einführung in die Forschungsmethoden der Psychologie

2027

Dirk Ostwald

Wintersemester 2026/2027

Inhaltsverzeichnis

1 Naturwissenschaft **3**
- 1.1 Naturwissenschaft . . . 3
- 1.2 Historische Phasen . . . 4
- 1.3 Das naturwissenschaftliche Ideal . . . 8
- 1.4 Theorien, Hypothesen, Experimente und Variablen . . . 14

2 Psychologische Forschung **20**
- 2.1 Formen psychologischer Forschung . . . 20
- 2.2 Beispiele psychologischer Grundlagenforschung . . . 21
- 2.3 Beispiele psychologischer Anwendungsforschung . . . 28
- 2.4 Psychologische Anwendungsforschung durch BigTech . . . 28

3 Psychologische Daten **31**
- 3.1 Verhaltensdaten . . . 35
- 3.2 Physiologische Daten . . . 38
- 3.3 Datenbereitstellung . . . 45

4 Messen und Quantifizieren **50**
- 4.1 Naiver Realismus . . . 52
- 4.2 Operationalismus . . . 56

Referenzen **60**

1 Naturwissenschaft

1.1 Naturwissenschaft

Wir wollen uns zunächst mit der Frage beschäftigen, was *Wissenschaft* eigentlich ist. Dazu bietet sich folgende Definition nach Carrier (2011) an:

Definition 1.1 (Wissenschaft)**.** Wissenschaft bezeichnet den methodischen Prozess intersubjektiv nachvollziehbaren Forschens und Erkennens in einem bestimmten Bereich, der nach herkömmlichem Verständnis ein begründetes, geordnetes und gesichertes Wissen hervorbringt. Wissenschaft kennzeichnet entsprechend das gesicherte und in einen rationalen Begründungszusammenhang gestellte Wissen, welches kommunizierbar und überprüfbar ist sowie bestimmten wissenschaftlichen Kriterien folgt. Wissenschaft bezeichnet somit ein zusammenhängendes System von Aussagen, Theorien und Verfahrensweisen, das strengen Prüfungen der Geltung unterzogen wurde und mit dem Anspruch objektiver, überpersönlicher Gültigkeit verbunden ist.

•

Auch wenn es sicherlich viele Möglichkeiten gibt, die menschliche wissenschaftliche Tätigkeit zu systematisieren (vgl. Kogge, 2022), so bietet sich für den Einstieg doch eine Kategorisierung in die *Naturwissenschaften*, die *Geisteswissenschaften* und die *Formalwissenschaften* an.

Naturwissenschaften (*Science*) erforschen die Natur empirisch mit dem Ziel, Regelmäßigkeiten zu erkennen. Dazu beobachten, messen und analysieren sie das Verhalten der Natur quantitativ. Ihre Erkenntnisse bilden die Grundlage für die Nutzbarmachung der Natur in den Ingenieursdisziplinen. Zu den Naturwissenschaften zählen unter anderem Physik, Chemie, Biologie, Medizin, Psychologie und Geologie. Geisteswissenschaften (*Humanities*) befassen sich mit der analytischen Erforschung menschlicher Kultur. Zu ihren Vorgehensweisen gehören qualitative Sinnsuche, informelle Kritik und Spekulation. Beispiele sind Philosophie, Theologie, Geschichtswissenschaft und Literaturwissenschaft. Geisteswissenschaftliche Ansätze tragen auch zur naturwissenschaftlichen Theoriebildung bei. Formalwissenschaften (*Formal Sciences*) analysieren formale Systeme und stellen sprachliche Werkzeuge bereit. Zu ihnen zählen unter anderem Mathematik, Logik, theoretische Informatik und Rechtswissenschaft. Auch sie tragen zur naturwissenschaftlichen Theoriebildung bei.

Zentral für den naturwissenschaftlichen Erkenntnisgewinn ist das Zusammenspiel von *Rationalität* und *Empirie*. Das Prinzip der *Rationalität* bezeichnet den Erkenntnisgewinn innerhalb eines Gedankengebäudes nach formalen Regeln. Dieser ist intersubjektiv nachvollziehbar, bleibt jedoch an die zugrunde gelegten Gedankenansätze gebunden. Das Prinzip der *Empirie* bezeichnet den Erkenntnisgewinn durch Beobachtung und Experiment. Auch

dieser ist intersubjektiv nachvollziehbar, bedarf jedoch der theoretischen Einordnung. Beide Prinzipien ergänzen sich also: Bereits Bacon betont die Verbindung experimenteller und rationaler Fähigkeiten (vgl. Bacon, 1620, Buch I, Aphorismus 95). Kant beschreibt entsprechend eine Naturforschung, in der die Vernunft das Experiment anleitet und sich zugleich durch die Natur belehren lässt (vgl. Kant, 1787, B XIII–XIV). Das Zusammenwirken von Rationalität und Empirie fasst Kant in die Worte: „Gedanken ohne Inhalt sind leer, Anschauungen ohne Begriffe sind blind“ (Kant, 1787, B 75, auch 1781, A 51).

1.2 Historische Phasen

In der Geschichte des naturwissenschaftlichen Erkenntnisgewinns mag man drei Phasen unterscheiden: die Zeit der *Naturphilosophie*, die Zeit der *Wissenschaftlichen Revolution* und schließlich die Ausdifferenzierung der Naturwissenschaft zur *Modernen Naturwissenschaft*.

Naturphilosophie

Die Naturphilosophie (*Natural Philosophy*) widmet sich dem Studium der Natur und des physikalischen Universums. Von der Antike bis in die frühe Neuzeit war sie der dominierende Ansatz zum Verständnis der Welt. Ihr Gegenstand waren die Beschaffenheit der Dinge, ihre Veränderungen und die Ursachen natürlicher Vorgänge. Sie umfasste Untersuchungen in Bereichen, die heute der Physik, Astronomie, Biologie, Chemie, Geologie und Psychologie zugeordnet werden. Fragen nach der Bewegung der Himmelskörper, den Eigenschaften der Materie oder dem Wesen des Lebendigen gehörten damit zu einem gemeinsamen philosophischen Zusammenhang. Dabei bediente sich die Naturphilosophie der Vernunft, der Beobachtung, der metaphysischen Spekulation und der Theologie. Beobachtungen wurden durch begriffliche Überlegungen und Annahmen über die grundlegende Ordnung der Wirklichkeit gedeutet. Insbesondere im Mittelalter war die Untersuchung der Natur zudem eng mit Fragen nach Gott und der Schöpfung verbunden. Prägend war dabei die Scholastik, eine an mittelalterlichen Schulen und Universitäten entwickelte Lehr- und Denkmethode. Philosophische und theologische Fragen wurden durch die Auslegung maßgeblicher Texte sowie das systematische Abwägen von Argumenten und Gegenargumenten untersucht. Ein wichtiges Anliegen war es, das Verhältnis zwischen vernünftiger Erkenntnis und christlichem Glauben zu klären.

Beispielhafte Vertreter des naturphilosophischen Ansatzes sind Platon (ca. 428–347 v. Chr.), der abstrakte Formen und mathematische Erklärungen betonte, und Aristoteles (384–322 v. Chr.), der die Natur klassifizierte und Theorien zu Bewegung und Kausalität entwickelte. Während Platon im *Timaios* die Ordnung des Kosmos auf ein ewiges Vorbild und mathematische Verhältnisse zurückführte, untersuchte Aristoteles die Prinzipien, nach denen natürliche Dinge entstehen, sich verändern und vergehen. Avicenna (980–1037) bewahrte und erweiterte die griechische Naturphilosophie. Er griff insbesondere aristotelische Vorstellungen auf und entwickelte sie zu eigenen Erklärungen von Körpern, Bewegung, Raum und Zeit weiter. Hildegard von Bingen (1098–1179) verband Naturbeobachtung, Heilkunst und Theologie. Ihre Beschäftigung mit der Natur und dem Menschen stand im Zusammenhang mit ihrem Verständnis der göttlichen Schöpfung. Thomas von Aquin (ca. 1225–1274) verknüpfte die Naturphilosophie im Rahmen der Scholastik mit der christlichen Theologie. Dabei setzte er sich eingehend mit den Schriften des Aristoteles

auseinander und betrachtete die vernünftige Untersuchung der Natur als einen Zugang zur Erkenntnis Gottes.

Wissenschaftliche Revolution

Die Wissenschaftliche Revolution (*Scientific Revolution*) bezeichnet den Übergang von der aristotelisch-scholastischen Naturphilosophie zu einer Naturwissenschaft mit mathematischer Modellbildung und experimenteller Überprüfung im 16. und 17. Jahrhundert (vgl. Henry, 2008).

Ein Ausgangspunkt dieser Entwicklung war *De revolutionibus orbium coelestium* (1543), in dem Nikolaus Kopernikus das heliozentrische Weltbild darlegte. An die Vorstellung einer um die Sonne kreisenden Erde knüpfte Johannes Kepler an und formulierte in seiner *Astronomia nova* (1609) die ersten beiden Gesetze der Planetenbewegung. Neue Beobachtungsmöglichkeiten eröffnete kurz darauf das Fernrohr: Im *Sidereus nuncius* (*Sternenbote*, 1610) berichtete Galileo Galilei von seinen teleskopischen Entdeckungen, darunter den Jupitermonden und der Beschaffenheit der Mondoberfläche, die überlieferte Vorstellungen vom Aufbau des Himmels infrage stellten. Parallel zu diesen astronomischen Entwicklungen widmete sich Francis Bacon der Frage nach den Methoden der Naturforschung und legte mit dem *Novum Organum* (1620) Grundlagen einer auf Beobachtung und Experiment gestützten Methode. Auch in der Medizin gewann die experimentelle Untersuchung an Bedeutung: William Harvey veröffentlichte in *De motu cordis* (1628) seinen Nachweis des Blutkreislaufs. Die Auseinandersetzung um das Weltbild führte unterdessen Galilei in seinem *Dialogo sopra i due massimi sistemi del mondo* (1632) fort, in dem er das geozentrische und das heliozentrische Weltsystem verglich und die kopernikanische Auffassung verteidigte. Einen weiteren methodischen Zugang entwickelte René Descartes im *Discours de la méthode* (1637) mit seinem rationalistischen Ansatz. Die gemeinsam damit veröffentlichte *Géométrie* legte Grundlagen der analytischen Geometrie. Diesen Ansatz führte er in den *Principia philosophiae* (1644) zu einer mechanistischen Gesamterklärung der Natur aus. In der Chemie trug Robert Boyle mit *The Sceptical Chymist* (1661) zur Begründung der modernen Disziplin bei und vertrat ebenfalls die Vorstellung einer aus Teilchen aufgebauten Materie. Eine umfassende mathematische Verbindung von irdischer und himmlischer Bewegung gelang schließlich Isaac Newton: In den *Philosophiae naturalis principia mathematica* (1687) formulierte er die Bewegungsgesetze und das Gesetz der universellen Gravitation, mit denen sich auch die von Kepler beschriebenen Planetenbewegungen erklären ließen. Bis heute gelten die *Principia* als eines der Gründungswerke der modernen Physik.

Ein lokaler Vertreter der Wissenschaftlichen Revolution war der in Magdeburg geborene Otto von Guericke. Ursprünglich hieß er Otto Gericke. Im Zuge seiner Erhebung in den Adelsstand 1666 nahm er den Namen Otto von Guericke an. Die veränderte Schreibweise sollte die korrekte Aussprache seines Namens im Französischen, der damaligen Diplomatensprache, ermöglichen (vgl. Erfurt-Web). Als Bürgermeister und Diplomat setzte er sich für den Wiederaufbau seiner im Dreißigjährigen Krieg zerstörten Heimatstadt ein. Zugleich entwickelte er eine Vakuumluftpumpe und untersuchte experimentell die Eigenschaften des luftleeren Raums und die Wirkung des Luftdrucks. Berühmt wurden seine Versuche mit den Magdeburger Halbkugeln (Abbildung 1.1). Seine Forschungen beschrieb er in den *Experimenta nova (ut vocantur) Magdeburgica de vacuo spatio* (1672).

Abbildung 1.1 Otto von Guericke und der Versuch mit den Magdeburger Halbkugeln. Die Darstellung zeigt Guerickes Porträt sowie den Aufbau und die Vorführung seines berühmten Versuchs. Zwei metallene Halbkugeln wurden mit einem Dichtungsring zu einer Hohlkugel zusammengefügt. Mit einer Luftpumpe wurde ein großer Teil der Luft aus ihrem Inneren entfernt, sodass der Innendruck deutlich unter den äußeren Luftdruck sank. Die umgebende Luft presste die Halbkugeln dadurch so fest zusammen, dass selbst zwei in entgegengesetzte Richtungen ziehende Pferdegespanne sie nicht ohne Weiteres trennen konnten. Sobald wieder Luft eingelassen wurde, glichen sich Innen- und Außendruck an, und die Halbkugeln ließen sich leicht voneinander lösen. Der Versuch veranschaulichte damit die Kraft des atmosphärischen Luftdrucks. Die Vorführung mit Pferden fand erstmals 1657 in Magdeburg statt. Bereits 1654 hatte Guericke in Regensburg andere Vakuumversuche gezeigt (vgl. Knapp, 2020).

Moderne Naturwissenschaft

Im 19. Jahrhundert wurden die Naturwissenschaften durch den Ausbau von Lehrstühlen, Laboratorien und Fachdisziplinen zunehmend im akademischen System verankert. Mit dieser Institutionalisierung verband sich das Ideal einer Einheit von Forschung und Lehre, wie es Wilhelm von Humboldt in seiner 1810 verfassten Denkschrift *Über die innere und äußere Organisation der höheren wissenschaftlichen Anstalten in Berlin* formulierte. Zugleich spezialisierten und diversifizierten sich die Gegenstände und Methoden naturwissenschaftlicher Tätigkeit. Aus der gemeinsamen Tradition der Naturphilosophie entwickelte sich eine zunehmend ausdifferenzierte Wissenschaftslandschaft, deren Beiträge sich exemplarisch nach physikalischen und chemischen, biologischen, psychologischen und informatischen Fragestellungen ordnen lassen.

Physikalische und chemische Beiträge

Eine Grundlage der modernen Chemie legte Antoine Lavoisier mit dem *Traité élémentaire de chimie* (1789), in dem er unter anderem die Rolle des Sauerstoffs bei der Verbrennung darstellte. Im Zusammenhang mit der Industrialisierung rückten Wärme, Arbeit und Energie in den Mittelpunkt physikalischer Untersuchungen. Sadi Carnot untersuchte in den *Réflexions sur la puissance motrice du feu* (1824) die Leistungsfähigkeit von Wärmekraftmaschinen. Hermann von Helmholtz formulierte in *Über die Erhaltung der Kraft* (1847)

das Prinzip der Energieerhaltung. Einen weiteren Bereich erschloss James Clerk Maxwell mit *A Treatise on Electricity and Magnetism* (1873), das elektrische und magnetische Erscheinungen in einer gemeinsamen Theorie beschrieb.

Zu Beginn des 20. Jahrhunderts veränderten neue Erkenntnisse über Materie, Raum und Zeit das physikalische Weltbild. Marie Curie fasste in *Recherches sur les substances radioactives* (1903) ihre Untersuchungen zur Radioaktivität zusammen. Albert Einstein begründete mit *Zur Elektrodynamik bewegter Körper* (1905) die spezielle Relativitätstheorie. Niels Bohr entwickelte in *On the Constitution of Atoms and Molecules* (1913) ein Atommodell mit diskreten Energiezuständen. Über dieses Modell hinaus führte Werner Heisenbergs Arbeit *Über quantentheoretische Umdeutung kinematischer und mechanischer Beziehungen* (1925), die einen Ausgangspunkt der Matrizenmechanik bildete. Für die Erforschung des Atomkerns stehen die 1939 veröffentlichten Arbeiten unter Beteiligung von Otto Hahn und Lise Meitner: *Über den Nachweis und das Verhalten der bei der Bestrahlung des Urans mittels Neutronen entstehenden Erdalkalimetalle* berichtete über den experimentellen Befund, während *Disintegration of Uranium by Neutrons: A New Type of Nuclear Reaction* dessen physikalische Deutung als Kernspaltung lieferte.

Biologische Beiträge

In der Biologie entwickelte Charles Darwin in *On the Origin of Species* (1859) eine Erklärung der Evolution durch natürliche Selektion. Gregor Mendel untersuchte unabhängig davon die Weitergabe von Merkmalen und beschrieb in *Versuche über Pflanzenhybriden* (1866) Gesetzmäßigkeiten der Vererbung. Damit wurden sowohl die Veränderung von Arten als auch die Übertragung ihrer Merkmale einer systematischen naturwissenschaftlichen Erklärung zugänglich.

Im 20. Jahrhundert gewannen die physikalischen und molekularen Grundlagen biologischer Vorgänge an Bedeutung. Alan Hodgkin und Andrew Huxley beschrieben in *A Quantitative Description of Membrane Current and Its Application to Conduction and Excitation in Nerve* (1952) ein mathematisches Modell des Aktionspotentials. Zur Aufklärung der DNA-Struktur trugen im folgenden Jahr Rosalind Franklin, James Watson und Francis Crick bei. Franklins Röntgenbeugungsuntersuchungen wurden in *Molecular Configuration in Sodium Thymonucleate* (1953) veröffentlicht. Watson und Crick stellten in *Molecular Structure of Nucleic Acids: A Structure for Deoxyribose Nucleic Acid* (1953) das Modell der DNA-Doppelhelix vor.

Psychologische Beiträge

Einen philosophischen Ausgangspunkt für die Beschäftigung mit menschlicher Erkenntnis bildet Immanuel Kants *Kritik der reinen Vernunft*(1781). Kant untersuchte die Bedingungen und Grenzen möglicher Erkenntnis und damit Fragen, die auch für die spätere Psychologie bedeutsam wurden. Die methodische Untersuchung wissenschaftlicher Erkenntnis griff Wilhelm Wundt in seiner *Logik* auf, deren zweiter Band, *Methodenlehre*(1883), die Verfahren wissenschaftlicher Forschung behandelte. Einen anderen Zugang zum psychischen Geschehen entwickelte Sigmund Freud mit *Die Traumdeutung*(1900), in der er seine Theorie unbewusster psychischer Vorgänge anhand der Deutung von Träumen entfaltete. Im Behaviorismus rückte die experimentelle Untersuchung des Verhaltens und seiner Umweltbedingungen in den Mittelpunkt. Burrhus Frederic Skinner beschrieb in *The Behavior*

of Organisms: An Experimental Analysis(1938), wie die Konsequenzen einer Handlung deren zukünftiges Auftreten beeinflussen können – ein grundlegender Zusammenhang des operanten Konditionierens. Mit der kognitiven Wende seit den 1950er Jahren gewannen innere Prozesse wie Wahrnehmung, Gedächtnis und Denken wieder stärker als eigenständige Erklärungsgegenstände an Bedeutung. Einen frühen Beitrag hierzu leistete George Miller mit *The Magical Number Seven, Plus or Minus Two: Some Limits on Our Capacity for Processing Information* (1956), in dem er die begrenzte Kapazität menschlicher Informationsverarbeitung und die Bündelung von Informationen zu größeren Einheiten (Chunks) untersuchte. Dabei entstanden enge Verbindungen zur Informatik und Informationstheorie: Kognitive Vorgänge wurden als Prozesse der Aufnahme, Speicherung und Verarbeitung von Informationen untersucht. Computermodelle ermöglichten es, Annahmen über diese Vorgänge präzise zu formulieren und ihre Vorhersagen mit menschlichem Verhalten zu vergleichen. So verband sich die experimentelle Tradition der Psychologie mit der formalen Modellierung geistiger Leistungen (vgl. Miller, 2003, *The Cognitive Revolution: A Historical Perspective*).

Informatische Beiträge

Die theoretischen Grundlagen der automatisierten Berechnung und Informationsverarbeitung, an die diese kognitiven Ansätze anknüpften, entstanden seit den 1930er Jahren. Alan Turing präzisierte in *On Computable Numbers, with an Application to the Entscheidungsproblem* (1936) den Begriff der Berechenbarkeit mithilfe eines abstrakten Maschinenmodells. John von Neumann beschrieb im *First Draft of a Report on the EDVAC* (1945) eine Rechnerarchitektur, bei der Programme und Daten im Speicher abgelegt werden. Claude Shannon entwickelte in *A Mathematical Theory of Communication* (1948) die mathematischen Grundlagen der Informationstheorie. Eine Verbindung zur Modellierung von Lernen und Wahrnehmung stellte Frank Rosenblatt mit *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain* (1958) her, einem frühen Ansatz künstlicher neuronaler Netze.

Die Entwicklung dieser unterschiedlichen Forschungsbereiche wurde selbst zum Gegenstand wissenschaftstheoretischer Untersuchung. Thomas Kuhn beschrieb in *The Structure of Scientific Revolutions* (1962) wissenschaftlichen Wandel als Wechselspiel zwischen Forschung innerhalb etablierter Paradigmen und grundlegenden Veränderungen dieser Paradigmen. Seine Überlegungen betreffen damit die Entwicklung der Naturwissenschaften über die Grenzen einzelner Fachdisziplinen hinweg.

1.3 Das naturwissenschaftliche Ideal

Im Folgenden wollen wir uns nun damit beschäftigen, welche Vorstellungen vom naturwissenschaftlichen Prozess im Zuge der Wissenschaftlichen Revolution prägend wurden (vgl. Abbildung 1.2). Im Mittelpunkt steht dabei die systematische Verbindung theoretischer Überlegungen mit der empirischen Untersuchung der Natur. Aussagen über natürliche Vorgänge sollen nachvollziehbar begründet und anhand von Beobachtungen und Experimenten überprüft werden können. Dabei handelt es sich um eine Idealvorstellung, der die tatsächliche wissenschaftliche Praxis nur selten vollständig entspricht. Forschung verläuft häufig weniger geradlinig, als es eine schematische Darstellung nahelegt: Einzelne Untersuchungen können sich auf die Entwicklung von Theorien, die Erhebung von Daten oder

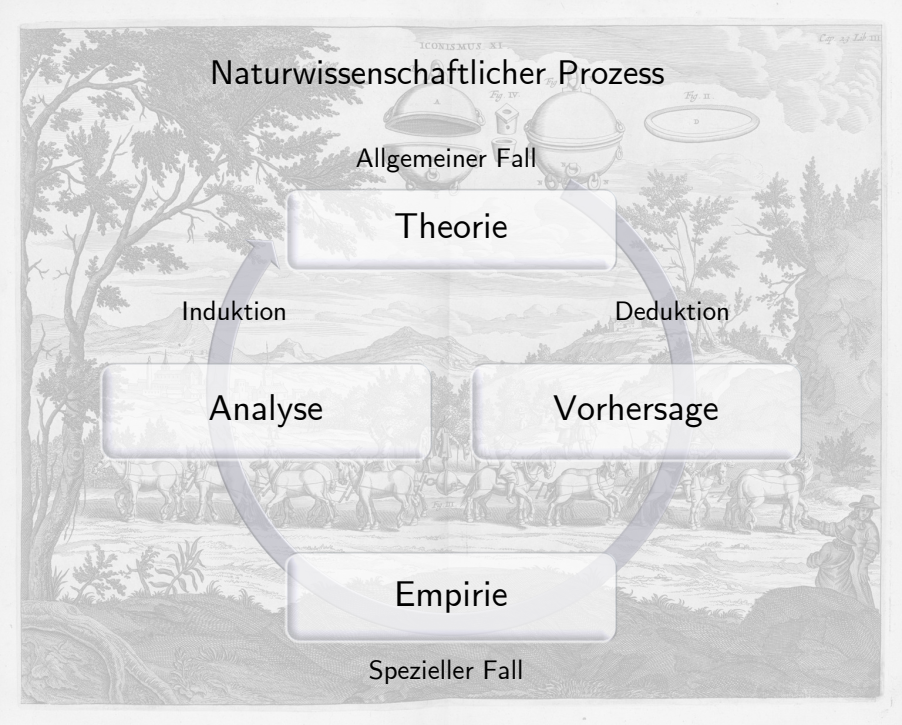

Abbildung 1.2 Das naturwissenschaftliche Ideal

deren Analyse konzentrieren. Dennoch bietet dieses Ideal einen hilfreichen Ausgangspunkt, um das Nachdenken über naturwissenschaftliche Erkenntnisgewinnung zu strukturieren und die unterschiedlichen Tätigkeiten in ihrem Zusammenhang zu betrachten.

Abbildung 1.2 stellt den naturwissenschaftlichen Prozess als einen Kreislauf aus *Theorie*, *Vorhersage*, *Empirie* und *Analyse* dar. Die Theorie beschreibt den allgemeinen Fall, indem sie Zusammenhänge formuliert, die über einzelne Beobachtungen hinausreichen. Aus ihr werden Vorhersagen für bestimmte Bedingungen abgeleitet. Die Empirie erfasst dagegen den speziellen Fall in Form konkreter Beobachtungen und Messungen. Die gewonnenen Daten werden analysiert und auf die theoretischen Erwartungen bezogen. Die kreisförmige Anordnung verdeutlicht, dass die Untersuchung damit nicht abgeschlossen ist: Ihre Ergebnisse können Anlass geben, eine Theorie weiterzuentwickeln und neue Vorhersagen zu prüfen. Theorie und Empirie sind somit aufeinander bezogen. Die beiden Schlussrichtungen zwischen dem Allgemeinen und dem Speziellen werden dabei als *Deduktion* und als *Induktion* bezeichnet.

Bei der *Deduktion* wird vom Allgemeinen auf das Spezielle geschlossen: Aus einer wissenschaftlichen Theorie werden Vorhersagen über empirische Daten abgeleitet. Diese Vorhersagen werden mit Daten verglichen, die durch Beobachtung oder Experiment erhoben werden. Die anschließende Analyse dient dazu, die Übereinstimmung zwischen Vorhersage und empirischem Befund zu beurteilen und damit bestehende Theorien zu überprüfen. Die *Induktion* führt vom Speziellen auf das Allgemeine zurück. Aus der Analyse empirischer Daten werden übergreifende Zusammenhänge erschlossen, die zur Bildung neuer oder zur Weiterentwicklung bestehender Theorien beitragen. Aus diesen lassen sich wiederum neue Vorhersagen ableiten, sodass sich der dargestellte Kreislauf fortsetzt. Induktion dient da-

mit der Theoriebildung, während Deduktion die Grundlage für die empirische Überprüfung von Theorien schafft (vgl. Döring (2023), Kapitel 2).

Die idealisierte Verbindung von Theorie, Vorhersage, Empirie und Analyse lässt sich am Beispiel der Fallbewegung der klassischen Mechanik verdeutlichen (vgl. Abbildung 1.3). Ausgangspunkt ist das zweite Newtonsche Bewegungsgesetz, in heutiger Schreibweise $F = ma$, zusammen mit der Gewichtskraft $F = -mg$, wobei m die Masse eines Objektes im Schwerefeld der Erde und g die Erdbeschleunigung bezeichnen. Wie im Folgenden erläutert, lässt sich aus dieser Theorie eine konkrete Vorhersage deduzieren, die beschreibt, wie sich die Höhe eines Körpers unter festgelegten Anfangsbedingungen mit der Zeit verändert.

Beispiel 1.1 (Deduktion einer konkreten Vorhersage für den freien Fall)**.** Wir betrachten einen Körper mit konstanter Masse $m > 0$, der im Vakuum nahe der Erdoberfläche fällt. Seine Höhe wird nach oben positiv gemessen. Das zweite Newtonsche Bewegungsgesetz lautet

$$F = m\ddot{x}(t), \tag{1.1}$$

wobei $F := -mg$ die Gravitationskraft, m die Masse des fallenden Objektes, $x : \mathbb{R} \to \mathbb{R}, t \mapsto x(t)$ die Ortsfunktion des Objektes und $g := 9.81\,\mathrm{m/s^2}$ die Erdbeschleunigung bezeichnen. Über die betrachtete Fallstrecke nehmen wir die Erdbeschleunigung als konstant an. Aus dem Bewegungsgesetz und der Gewichtskraft folgt

$$F = m\ddot{x}(t) \Leftrightarrow -mg = m\ddot{x}(t) \Leftrightarrow -g = \ddot{x}(t). \tag{1.2}$$

Eine Ortsfunktion, die diese Differentialgleichung zweiter Ordnung erfüllt, ist

$$x : \mathbb{R} \to \mathbb{R}, t \mapsto x(t) := x_0 + v_0 t - \frac{1}{2} g t^2 \text{ mit } x_0, v_0 \in \mathbb{R}. \tag{1.3}$$

Dabei bezeichnen x_0 die Anfangsposition und v_0 die Anfangsgeschwindigkeit. Die Ortsfunktion erfüllt die Bewegungsgleichung, denn zweimaliges Ableiten von x nach t ergibt

$$\ddot{x}(t) = \frac{d^2}{dt^2} x(t) = \frac{d}{dt}\left(\frac{d}{dt}\left(x_0 + v_0 t - \frac{1}{2} g t^2\right)\right) = \frac{d}{dt}\left(v_0 - gt\right) = -g. \tag{1.4}$$

Sie erfüllt außerdem die vorgegebenen Anfangsbedingungen. Damit ist aus dem allgemeinen Bewegungsgesetz und den Annahmen über die konkrete Situation eine überprüfbare Vorhersage abgeleitet.

Lassen wir den Körper also beispielsweise zum Zeitpunkt $t = 0\,\mathrm{s}$ aus einer Höhe von $x_0 = 10\,\mathrm{m}$ ohne Anfangsgeschwindigkeit, also mit $v_0 := 0\,\mathrm{m/s}$, los, folgt die Vorhersage

$$x(1) = 10 + 0 \cdot 1 - \frac{1}{2} \cdot 9.81 \cdot 1^2 = 5.095 \approx 5.10 \tag{1.5}$$

für die Höhe des Objektes in m nach $t = 1\,\mathrm{s}$ freiem Fall. Nach einer Sekunde befindet sich der Körper demnach noch etwa 5.10 m über dem Boden und hat etwa 4.90 m zurückgelegt. Diese Vorhersage gilt unter den genannten Modellannahmen und bis zum Auftreffen auf den Boden. Ihr Vergleich mit Messungen erlaubt es, die Eignung des Modells für die untersuchte Situation zu beurteilen.

△

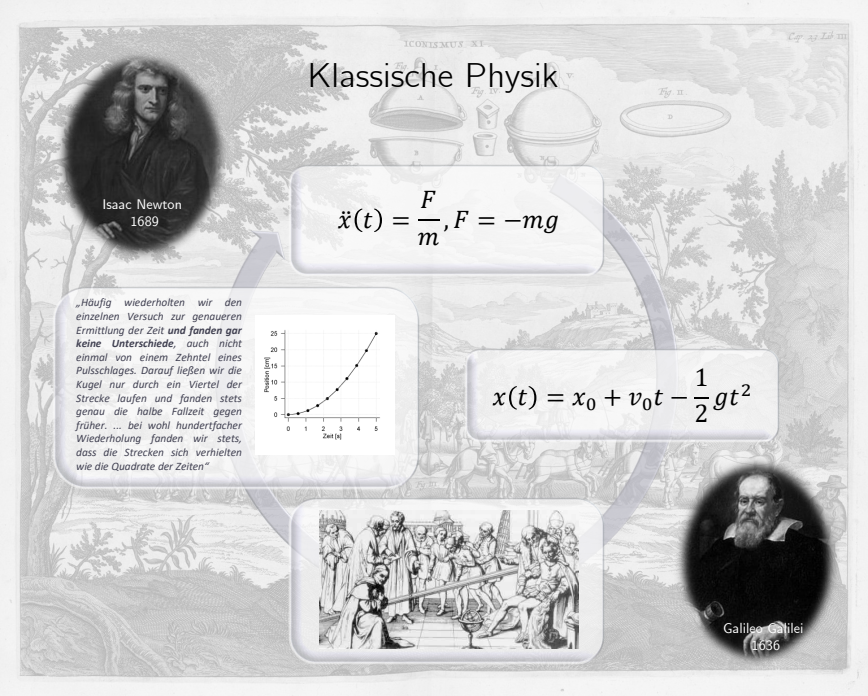

Abbildung 1.3 Der idealisierte naturwissenschaftliche Prozess am Beispiel der Fallbewegung. Die Begriffe aus Abbildung 1.2 werden hier anhand der klassischen Mechanik konkretisiert: Die *Theorie* besteht aus dem zweiten Newtonschen Bewegungsgesetz und der Beschreibung der Gewichtskraft. Durch *Deduktion* ergibt sich daraus unter festgelegten Anfangsbedingungen die *Vorhersage* einer Ortsfunktion $x(t) = x_0 + v_0 t - \frac{1}{2} g t^2$. Die *Empirie* wird durch Galileis Versuche mit einer rollenden Kugel auf der schiefen Ebene veranschaulicht. Die *Analyse* untersucht den Zusammenhang zwischen zurückgelegter Strecke und benötigter Zeit sowie seine Übereinstimmung mit einem quadratischen Zeitverlauf. Dabei entspricht einer Verdopplung der Zeit eine Vervierfachung der Strecke. Die Rückführung solcher Befunde auf allgemeine Zusammenhänge steht für die *Induktion*. Die Darstellung verbindet damit den allgemeinen Fall einer Bewegungstheorie mit dem speziellen Fall einer konkreten Bewegung. Die Beschleunigung auf der schiefen Ebene unterscheidet sich von der Erdbeschleunigung beim freien Fall, beide Bewegungen weisen unter idealisierten Bedingungen jedoch den dargestellten quadratischen Zeitverlauf auf.

Einen empirischen Zugang zur Untersuchung beschleunigter Bewegungen bieten Galileis Versuche mit einer schiefen Ebene (vgl. Abbildung 1.3). In seinen *Discorsi e dimostrazioni matematiche intorno a due nuove scienze* (1638), Dritter Tag berichtet Galileo Galilei, dass er eine Bronzekugel durch eine Rinne auf einer schiefen Ebene rollen ließ. Für ein Viertel der Strecke benötigte sie nach seinem Bericht die Hälfte der Zeit. Auch bei vielfacher Wiederholung und unterschiedlichen Neigungen habe sich gezeigt, dass sich die zurückgelegten Strecken wie die Quadrate der Zeiten verhalten. Zur Zeitmessung beschreibt er das Auffangen und anschließende Wiegen ausfließenden Wassers. Die schiefe Ebene machte die beschleunigte Bewegung langsamer und damit leichter messbar. Sie veranschaulicht denselben quadratischen Zeitverlauf wie der freie Fall aus der Ruhe, besitzt aber eine andere Beschleunigung, die unter anderem von der Neigung und der Rotation der Kugel abhängt.

Beim freien Fall aus der Ruhe nimmt die zurückgelegte Strecke quadratisch mit der Zeit zu (vgl. Abbildung 1.3). In der doppelten Zeit wird die vierfache Strecke zurückgelegt. Im idealisierten Kreislauf werden solche empirischen Beziehungen mit den deduzierten Vorhersagen verglichen. Ihre Übereinstimmung stützt die Eignung der Theorie zur Beschrei-

bung der untersuchten Bewegung. Abweichungen geben Anlass, die Modellannahmen, die Messungen oder die Theorie zu überprüfen. Die Analyse empirischer Daten kann so zur Weiterentwicklung theoretischer Vorstellungen beitragen.

Historisch ging Galileis Fallgesetz Newtons Mechanik voraus. Bereits in einem Brief an Paolo Sarpi vom 16. Oktober 1604 formulierte Galilei den quadratischen Zusammenhang zwischen Strecke und Zeit, damals allerdings noch mit einer unzutreffenden Annahme über die Zunahme der Geschwindigkeit. Die ausgearbeitete Darstellung mit dem Bericht über die schiefe Ebene erschien 1638. Newton veröffentlichte seine *Philosophiae naturalis principia mathematica* erst 1687. Sein zweites Bewegungsgesetz ist dort sprachlich formuliert, die Gleichung $F = ma$ ist die heute übliche Darstellung für konstante Masse. Newton bettete die ihm bekannten Erkenntnisse über das Fallgesetz in eine allgemeinere Theorie der Bewegungen ein, so dass sich heute der von Galilei beschriebene Zusammenhang als Spezialfall aus den allgemeinen Bewegungsgesetzen und der Gewichtskraft ableiten lässt. Der Kreislauf der Abbildung beschreibt also lediglich einen idealisierten Zusammenhang von Theorie und Empirie, ohne die historische Abfolge der Entdeckungen wiederzugeben.

Die klassische Mechanik erklärt allerdings nicht alle beobachteten Bewegungen vollständig. Dies zeigt sich beispielsweise an der Periheldrehung, also der langsamen Drehung der Bahnellipse eines Planeten um die Sonne. Die beobachtete Periheldrehung des Merkur lässt sich mit der Newtonschen Gravitationstheorie nicht vollständig erklären. Eine weitergehende Beschreibung lieferte hier die Gravitationstheorie der allgemeinen Relativitätstheorie.

Die Fallbewegung aus Sicht der modernen probabilistischen Datenwissenschaft

Das oben skizzierte Zusammenspiel von Theorie und Empirie im Fall der klassischen Mechanik stellt die Dinge allerdings stark vereinfacht dar. Galilei berichtete bereits, man habe „gar keine Unterschiede, auch nicht einmal von einem Zehntel eines Pulsschlages“ gefunden (vgl. Abbildung 1.4 und Galilei, 1638). Dies verweist auf eine begrenzte Messgenauigkeit, wobei auch der Pulsschlag als biologisches Zeitmaß selbst variabel ist. Es ist daher davon auszugehen, dass auch Galileis Messdaten Schwankungen unterlagen, selbst wenn diese innerhalb der angegebenen Messgenauigkeit nicht erkennbar waren. Heute würde man die Variabilität experimenteller Daten mithilfe von Abweichungstermen oder „Fehlern“ ε modellieren, wie in Abbildung 1.4 dargestellt.

Die systematische Behandlung von Unsicherheit und Beobachtungsfehlern hat eine lange Geschichte, die sich parallel zur Entwicklung der deterministisch orientierten Physik entfaltete. Thomas Bayes untersuchte bereits in seinem posthum veröffentlichten Essay von 1763, wie sich aus beobachteten Ereignissen auf eine unbekannte Wahrscheinlichkeit schließen lässt (vgl. Bayes, 1763). Legendre veröffentlichte 1805 die Methode der kleinsten Quadrate, Gauß verband sie 1809 mit einer probabilistischen Theorie der Beobachtungsfehler (vgl. Legendre, 1805, Gauß, 1809). Diese und weitere Ansätze wurden insbesondere im späten 19. und frühen 20. Jahrhundert zu einer allgemeinen Methodik statistischen Schließens weiterentwickelt, auf die wir später zurückkommen werden und zu der Fisher mit seinen *Statistical Methods for Research Workers* einen bis heute einflussreichen Beitrag leistete (vgl. Fisher, 1925).

Im Fallbeispiel lautet die Frage damit aus moderner Sicht, welche Modellparameter die Daten nahelegen, wie unsicher ihre Schätzung ist und ob das Modell Verlauf und Streuung angemessen beschreibt. Naturwissenschaftliche Erkenntnisgewinnung wird dabei ausdrücklich zum Schließen unter Unsicherheit (vgl. etwa Ostwald et al., 2014 und Ostwald und

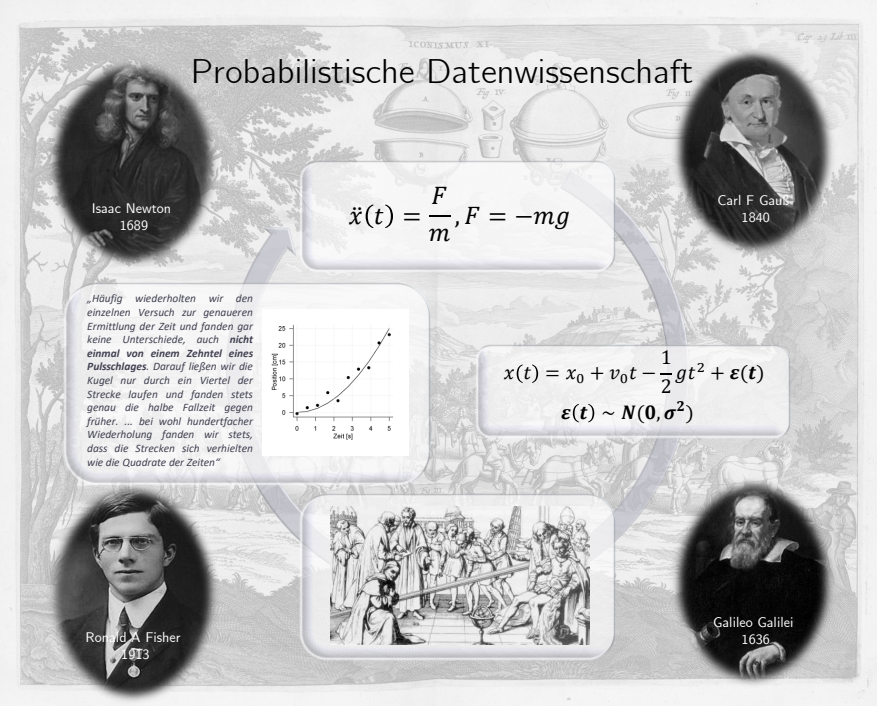

Abbildung 1.4 Die Fallbewegung aus Sicht der modernen probabilistischen Datenwissenschaft. Gegenüber Abbildung 1.3 ergänzt die Darstellung die deterministische Ortsfunktion um den additiven Fehlerterm $\varepsilon(t)$. Die Annahme $\varepsilon(t) \sim N(0, \sigma^2)$ beschreibt normalverteilte Abweichungen mit Erwartungswert null und Varianz σ^2. Die Beobachtungen dürfen damit um den theoretisch vorhergesagten Verlauf streuen, was die schematisch eingezeichneten Datenpunkte veranschaulichen. Die Porträts von Carl Friedrich Gauß und Ronald A. Fisher stehen für die probabilistische Theorie der Beobachtungsfehler und die Entwicklung statistischer Inferenz. Der Vergleich von Theorie und Empirie umfasst damit neben dem Verlauf der Bewegung auch die Streuung der Daten und die Unsicherheit der Parameterschätzung. Die klassische Bewegungsgleichung bleibt dabei deterministisch, während das Beobachtungsmodell probabilistisch erweitert wird.

Starke, 2016). Für die probabilistische Datenwissenschaft ist es grundsätzlich entscheidend, mechanistische Theorien wie Newtons Modell der Bewegung mit einer angemessenen Beschreibung empirischer Unsicherheit zu verbinden.

Weitere Aspekte des naturwissenschaftlichen Ideals

Neben dem bisher skizzierten methodischen Ideal will die Naturwissenschaft weiteren Idealen folgen, die sich am ehesten unter wissenschaftssoziologischen Gesichtspunkten verstehen lassen (vgl. Döring (2023), Kapitel 1). Dazu gehören die Formulierung empirisch untersuchbarer und gut begründeter Forschungsfragen, die Berücksichtigung des Forschungsstands und ein ausdrücklicher Theoriebezug. Forschungsfragen sollen so gestellt sein, dass sie anhand von Beobachtungen oder Experimenten bearbeitet werden können und ihre wissenschaftliche Bedeutung erkennbar wird. Die Einordnung in den Forschungsstand verdeutlicht, welches Wissen bereits vorliegt und an welchen offenen Fragen eine Untersuchung ansetzt. Der Theoriebezug macht die zugrunde liegenden Annahmen deutlich. Empirische Daten sollen systematisch erhoben, aufbereitet und analysiert werden, sodass die einzelnen Arbeitsschritte einem begründeten Vorgehen folgen. Dabei sollen etablierte Methoden zum

Einsatz kommen und wissenschaftliche Qualitätskriterien eingehalten werden, die eine Beurteilung der Aussagekraft der Ergebnisse ermöglichen. Das Vorgehen soll außerdem den Prinzipien der Forschungsethik und der akademischen Ethik entsprechen. Dazu gehören der Schutz der Teilnehmenden sowie ein ehrlicher Umgang mit Daten, Ergebnissen und den Leistungen anderer Forschender. Eine ausführliche Dokumentation soll die Nachvollziehbarkeit und Nachprüfbarkeit der Forschung gewährleisten. Andere Forschende sollen erkennen können, wie eine Untersuchung durchgeführt wurde und auf welcher Grundlage ihre Schlussfolgerungen beruhen. Die Ergebnisse sollen ausgewogen interpretiert werden, wobei auch Widersprüche und Grenzen zu berücksichtigen sind. Dazu gehört, abweichende Befunde offenzulegen und die Reichweite der eigenen Aussagen nicht zu überschätzen. Schließlich sollen die Forschungsergebnisse nach fachkundiger Begutachtung wissenschaftlich veröffentlicht werden. Diese Begutachtung dient der kritischen Prüfung durch andere Fachleute, während die Veröffentlichung die Ergebnisse für weitere Forschung und wissenschaftliche Diskussion zugänglich macht. Einer kritischen Einordnung dieser Ideale im Angesicht der zeitgenössischen Wissenschaftsindustrie widmen wir uns in späteren Abschnitten.

1.4 Theorien, Hypothesen, Experimente und Variablen

In diesem Abschnitt wollen wir mit den Begriffen Theorie, Hypothese, Experiment und Variable vier zentrale Begriffe der Naturwissenschaft genauer betrachten und kritisch reflektieren, die in den bisherigen Überlegungen bereits angeklungen sind.

Theorien

Der Begriff der Theorie wird in der psychologischen Fachliteratur unterschiedlich bestimmt. Die folgenden Definitionen betonen jeweils bestimmte Aufgaben und Eigenschaften wissenschaftlicher Theorien.

„Eine Theorie ist ein Erklärungsmodell, das auf bestimmten Prinzipien basiert. Eine Theorie stellt Einzelbeobachtungen in einen Zusammenhang. Mithilfe einer Theorie können Verhaltensweisen oder Ereignisse in ein System gebracht und Vorhersagen abgeleitet werden.“ (Myers (2010), nach dem Wortlaut der Vorlage)

Diese Definition verbindet die Erklärung und Ordnung einzelner Beobachtungen mit der Ableitung von Vorhersagen. Eine Theorie soll demnach sowohl bereits beobachtete Ereignisse verständlich machen als auch Erwartungen an weitere Beobachtungen begründen.

„Eine Theorie ist eine geordnete Menge von Konzepten oder Aussagen, die ein Phänomen oder eine Gruppe von Phänomenen erklärt.“ (Gerrig et al. (2020))

Hier steht die erklärende Funktion einer Theorie im Vordergrund. Zugleich wird betont, dass ihre Begriffe und Aussagen geordnet miteinander verbunden sind und sich auf einen bestimmten Gegenstandsbereich beziehen.

„Eine Theorie ist ein System von Definitionen, Annahmen und Schlussfolgerungen, welches einen Ordnungs- und Erklärungsversuch für ein oder mehrere Phänomene darstellt.“ (Reiß & Sarris (2012))

Diese Definition benennt die Bestandteile einer Theorie genauer. Definitionen klären die verwendeten Begriffe, Annahmen bilden den Ausgangspunkt und Schlussfolgerungen ergeben sich aus ihrem Zusammenhang. Die Bezeichnung als Erklärungsversuch betont zudem den vorläufigen Charakter theoretischer Erkenntnis. Für unser Verständnis kommt es insbesondere darauf an, dass eine Theorie quantitative Vorhersagen über beobachtbare Daten ermöglicht. Wir legen deshalb die folgende Definition zugrunde.

Definition 1.2 (Theorie)**.** Eine Theorie ist ein System von intuitiv-verbal und mathematisch formulierten Definitionen und Theoremen, das elementare Grundannahmen zur Erklärung eines Phänomens der Wirklichkeit ausdrückt und die Herleitung quantitativer, informatisch implementierbarer Vorhersagen über beobachtbare Daten dieses Phänomens ermöglicht.

•

In der Psychologie wird außerdem gelegentlich zwischen Theorien und Modellen unterschieden. Modelle werden dabei beispielsweise als Bestandteile von Theorien oder als Repräsentationen allgemeiner theoretischer Prinzipien aufgefasst (vgl. Reiß & Sarris (2012), S. 34–37). Für die hier verfolgte Perspektive ist diese Unterscheidung wenig zielführend. Entscheidend ist, dass die theoretischen Annahmen so präzise formuliert werden, dass sich daraus quantitative Datenvorhersagen ableiten und informatisch umsetzen lassen. Mathematische und informatische Modellbildung verstehen wir deshalb als notwendigen Bestandteil naturwissenschaftlicher Arbeit und verwenden die Begriffe Theorie und Modell im Folgenden synonym.

Hypothesen

Auch der Begriff der Hypothese wird in der psychologischen Fachliteratur unterschiedlich bestimmt. Dabei stehen insbesondere die Ableitung aus einer Theorie, die Vorläufigkeit einer Aussage und ihre empirische Überprüfbarkeit im Vordergrund.

„Eine Hypothese ist eine überprüfbare Vorhersage, die aus einer Theorie abgeleitet wird.“ (Myers (2010), nach dem Wortlaut der Vorlage)

Diese Definition stellt den Zusammenhang zwischen Theorie und Vorhersage heraus. Eine Hypothese konkretisiert theoretische Annahmen so, dass sie mit empirischen Beobachtungen verglichen werden können.

„Eine Hypothese ist eine vorläufige und prüfbare Erklärung der Beziehung zwischen zwei oder mehreren Ereignissen oder Variablen […]“ (Gerrig et al. (2020))

Hier werden die Vorläufigkeit und die Prüfbarkeit einer Erklärung betont. Im weiteren Verlauf der Definition wird hervorgehoben, dass Hypothesen häufig als Vorhersagen darüber formuliert werden, welche Ereignisse unter bestimmten Bedingungen eintreten.

„Eine Hypothese ist eine experimentell zu prüfende Tatsachenbehauptung bzw. präzise Angabe über die Art der erwarteten Abhängigkeitsbeziehung. Sie enthält die exakte Festlegung der variierten Bedingungen und der erwarteten Veränderungen, d. h. eine möglichst präzise Vorhersage über die empirische Beziehung zwischen Ereignissen.“ (Reiß & Sarris (2012))

Diese Definition rückt die experimentelle Überprüfung in den Mittelpunkt. Die untersuchten Bedingungen und die erwarteten Veränderungen sollen möglichst genau angegeben werden.

Im allgemeinen Sprachgebrauch bezeichnet eine Hypothese häufig eine vorläufige Aussage über einen empirisch überprüfbaren Zusammenhang zwischen direkt oder indirekt beobachtbaren Phänomenen. Für die hier verfolgte Perspektive ist der allgemeine Hypothesenbegriff verzichtbar und wird durch modellbasierte Datenvorhersagen ersetzt.

In der Psychologie werden Hypothesen und statistische Hypothesen häufig miteinander verwechselt. Während mit einer Hypothese zunächst eine aus einer Theorie abgeleitete Datenvorhersage gemeint sein kann, bezeichnet eine statistische Hypothese eine Aussage über die Lage eines wahren, aber unbekannten Parameters im Parameterraum eines statistischen Modells. Nullhypothese und Alternativhypothese sind Beispiele dafür. Inhaltliche Hypothesen lassen sich unter geeigneten Modellannahmen als statistische Hypothesen formulieren, müssen aber nicht in dieser Form behandelt werden. Die Datenanalyse bietet mehr Möglichkeiten als das frequentistische Hypothesentesten. Statistische Tests liefern zudem keine abschließenden Urteile darüber, ob eine inhaltliche Aussage absolut richtig oder falsch ist. Ihre Entscheidungen beruhen auf Modellannahmen und sind mit Fehlerrisiken verbunden. Insbesondere bedeutet die Nichtablehnung einer Nullhypothese nicht, dass ihre Richtigkeit nachgewiesen wurde. Für unsere Perspektive ist deshalb die probabilistische Quantifizierung von Unsicherheit entscheidend. Eine einfache Gegenüberstellung von Bestätigung und Widerlegung, wie sie in vereinfachten Berufungen auf Poppers Falsifikationsgedanken aus *Logik der Forschung* (Popper (1935)) vorkommt, greift hierfür zu kurz.

Ein starker Fokus auf Hypothesen kann außerdem andere wichtige Beiträge zur naturwissenschaftlichen Forschung abwerten. Dazu gehören die mathematische Modellentwicklung, die analytische oder simulationsbasierte Modellvalidierung, die Erhebung, Aufbereitung und Bereitstellung von Daten sowie explorative Untersuchungen zur Charakterisierung bislang wenig bekannter Phänomene. Solche Arbeiten können wesentliche Erkenntnisse liefern, ohne eine zuvor formulierte Hypothese zu testen. Problematisch wird der Hypothesenfokus insbesondere dann, wenn er Praktiken wie p-Hacking oder HARKing begünstigt (vgl. Simmons et al. (2011) und Kerr (1998)). Beim p-Hacking werden beispielsweise Daten oder Auswertungen so ausgewählt, dass ein statistisch signifikantes Ergebnis entsteht. HARKing bezeichnet die nachträgliche Formulierung von Hypothesen in Kenntnis der Ergebnisse, wenn diese anschließend als vorab aufgestellt dargestellt werden. Entscheidend ist aus unserer Sicht stattdessen, dass Theorien quantitative Vorhersagen über beobachtbare Daten ermöglichen, deren Unsicherheit probabilistisch beschrieben werden kann. Der Schwerpunkt soll daher auf dem Vergleich solcher Modelle anhand empirischer Daten liegen.

Experimente

Der Begriff des Experiments bezeichnet eine besondere Form empirischer Untersuchung. Im Mittelpunkt steht ein gezielter Eingriff, dessen Auswirkungen untersucht werden sollen.

„Ein Experiment ist eine Untersuchung, bei welcher Untersuchungsleitende aktiv und gezielt eine Intervention durchführen, um die Effekte der Intervention zu beobachten.“ (Shadish et al. (2001), nach dem Wortlaut der Vorlage)

Diese Definition betont die aktive Veränderung der untersuchten Situation. Forschende beobachten nicht nur einen bestehenden Zustand, sondern führen gezielt eine Intervention durch und untersuchen, welche Folgen sie hat.

„Ein Experiment ist ein systematischer Beobachtungsvorgang, aufgrund dessen der Versuchsleiter (sic) das jeweils interessierende Phänomen planmäßig erzeugt und variiert sowie gleichzeitig systematische und/oder unsystematische Störfaktoren durch hierfür geeignete Techniken kontrolliert." (Reiß & Sarris (2012))

Hier wird zusätzlich die Kontrolle anderer Einflüsse hervorgehoben. Sie soll helfen, die beobachteten Veränderungen auf die untersuchte Intervention zurückzuführen und alternative Erklärungen einzuschränken. Für die hier verfolgte Perspektive legen wir die folgende Definition zugrunde.

Definition 1.3 (Experiment)**.** Ein Experiment ist eine Interventionsstudie, die zur kausalen Ursachenforschung eingesetzt werden kann.

•

Es sollte aber beachtet werden, dass auch nichtexperimentell gewonnene Erkenntnisse wissenschaftlich wertvoll sein können und auch reine Beobachtungsdaten unter geeigneten Annahmen mit Methoden der kausalen Inferenz analysiert werden können. Ein Beispiel für Erkenntnisgewinn ohne gezielte Intervention ist etwa die Entwicklung von Theorien zur Beschreibung der Planetenbahnen.

Im Kontext empirischer Studien unterscheidet man allgemein zwischen *Experimenten*, *Quasiexperimenten* und *nichtexperimentellen empirischen Studien*. Für diese Unterscheidung sind insbesondere die Intervention und die Zuweisung zu den untersuchten Bedingungen entscheidend. Unsere Definition verwendet Experiment als Oberbegriff für Interventionsstudien. Wenn im engeren Sinne zwischen Experiment und Quasiexperiment unterschieden wird, ist mit Experiment meist ein randomisiertes Experiment gemeint. In einer randomisierten kontrollierten Studie werden Untersuchungseinheiten den Bedingungen zufällig zugewiesen. Beispielsweise können Personen mit Depression per Zufall einer Online-Psychotherapie oder einer Psychotherapie in Präsenz zugeordnet werden. Die zufällige Zuweisung soll systematische Unterschiede zwischen den Gruppen vor der Intervention vermeiden, garantiert aber keine vollständige Gleichheit der tatsächlich entstandenen Gruppen.

Ein Quasiexperiment untersucht ebenfalls die Auswirkungen einer Intervention, jedoch ohne zufällige Zuweisung zu den Bedingungen. Als Vergleich können beispielsweise eine andere Gruppe oder Messungen vor der Intervention dienen. So könnte eine Einrichtung eine Online-Psychotherapie einführen, während eine vergleichbare Einrichtung bei der bisherigen Behandlung bleibt. Bereits bestehende Unterschiede zwischen den Einrichtungen und ihren Patientinnen und Patienten müssen dann als mögliche alternative Erklärungen berücksichtigt werden.

Bei einer nichtexperimentellen empirischen Studie schließlich werden Merkmale und ihre Zusammenhänge beobachtet, ohne dass Forschende die untersuchte Intervention gezielt zuweisen oder herbeiführen. Ein Beispiel ist eine Panelstudie, in der dieselben Personen wiederholt befragt werden. Solche Studien sind nicht grundsätzlich unkontrolliert, denn mögliche Störeinflüsse können beispielsweise durch die Auswahl geeigneter Vergleichspersonen oder durch statistische Verfahren berücksichtigt werden. Welche kausalen Schlussfolgerungen möglich sind, hängt vom konkreten Design und den begründbaren Annahmen ab (vgl. Shadish et al. (2001), Kapitel 1).

Ein rein experimenteller Fokus in Naturwissenschaft und Psychologie, wie er manchmal im Bereich der Allgemeinen Psychologie propagiert wird, greift deshalb zu kurz. Er kann

andere wichtige naturwissenschaftliche Beiträge abwerten und dazu verleiten, das Untersuchungsdesign unabhängig von der Datenanalyse zu beurteilen. Auch Hypothesentests und Korrelationsanalysen bilden keinen grundsätzlichen Gegensatz, denn beispielsweise lässt sich ein Korrelationsparameter mit einem Hypothesentest untersuchen. Datenerhebungen unterscheiden sich vielmehr entlang mehrerer Dimensionen, etwa hinsichtlich der Intervention, der Zuweisung zu Bedingungen, der zeitlichen Struktur und der Kontrolle möglicher Störeinflüsse. Entscheidend ist die kritische Beurteilung dieser Eigenschaften im Zusammenhang mit der Forschungsfrage und der Analyse, wie wir an späterer Stelle genauer diskutieren werden.

Variablen

Variablen beschreiben Merkmale, die unterschiedliche Ausprägungen annehmen können. Im Kontext psychologischer Studien lassen sie sich anhand verschiedener Dimensionen klassifizieren. Die Unterscheidung zwischen manifesten und latenten Variablen betrifft ihre Beobachtbarkeit, die Unterscheidung zwischen unabhängigen und abhängigen Variablen ihre Rolle in einer Studie und die Unterscheidung zwischen diskreten und kontinuierlichen Variablen die Menge ihrer möglichen Ausprägungen. Diese Dimensionen schließen einander nicht aus. So kann ein beobachteter Testwert zugleich eine manifeste, abhängige und diskrete Variable sein. Diese Einteilungen empirischer Merkmale sind zudem von der Verwendung mathematischer Variablen als Symbolen in Formeln zu unterscheiden. Grundsätzlich können Variablen aller genannten Typen durch Zufallsvariablen modelliert werden, müssen es aber nicht.

Manifeste Variablen sind in ihrer Ausprägung direkt beobachtbar. Beispiele sind die Körpergröße, das Lebensalter oder das Ergebnis eines psychologischen Tests. *Latente Variablen* sind dagegen nicht direkt beobachtbar. Sie werden als theoretische Konstrukte herangezogen, um die Variation manifester Variablen zu erklären. Ein Beispiel ist Intelligenz, die zur Erklärung unterschiedlicher Leistungen in psychologischen Tests verwendet wird. Die theoretische Bedeutung latenter Variablen und ihr Zusammenhang mit beobachtbaren Merkmalen bedürfen daher einer besonderen Begründung. Allerdings sind auch die Bedeutung und Messbarkeit manifester Variablen nicht grundsätzlich selbsterklärend. Ob beispielsweise neuronale Aktivität als beobachtete Messgröße oder als latente Größe behandelt wird, hängt von der konkreten Untersuchung und ihrem Modell ab (vgl. Döring (2023), Kapitel 8).

Als *unabhängige Variable* bezeichnet man im experimentellen Kontext eine Variable, die systematisch variiert wird, um ihre Auswirkungen auf eine oder mehrere *abhängige Variablen* zu untersuchen. Beispiele sind psychotherapeutische Behandlungsformen oder unterschiedliches experimentelles Stimulusmaterial. Als abhängige Variablen können etwa Werte in einem psychometrischen Test, Tastendrücke in einem Computerspiel oder Maße der Gehirnaktivität erfasst werden. Auch Gruppierungsmerkmale werden häufig als unabhängige Variablen bezeichnet, obwohl sie nicht gezielt verändert werden. Die Begriffe sind insofern etwas kontraintuitiv, als „unabhängig“ hier weder statistische Unabhängigkeit noch Unabhängigkeit von anderen Einflüssen bedeutet. Ebenso belegt die Bezeichnung „abhängige Variable“ für sich genommen keine kausale Abhängigkeit. Beide Begriffe kennzeichnen zunächst die den Variablen zugewiesenen Rollen innerhalb einer Untersuchung.

Diskrete Variablen können eine endliche oder abzählbar unendliche Menge verschiedener Werte annehmen. Beispiele sind die Anzahl richtiger Antworten in einem Test oder die

Anzahl von Tastendrücken. Kategoriale Variablen unterscheiden verschiedene Kategorien, die häufig durch Zahlen codiert werden. Sie sind damit diskret, doch nicht jede diskrete Variable ist deshalb kategorial. *Kontinuierliche Variablen* können dagegen innerhalb eines Intervalls jeden reellen Wert annehmen. Beispielsweise werden Zeitdauern häufig als kontinuierliche Größen modelliert. Die Einordnung als diskret oder kontinuierlich ist eine Modellannahme. Lebensalter kann etwa als kontinuierliche Zeitdauer oder in vollendeten Lebensjahren angegeben werden. Auch Reaktionszeiten können kontinuierlich modelliert werden, obwohl ihre digitalen Messwerte nur mit begrenzter Genauigkeit gespeichert werden. Bei Merkmalen wie Geschlecht muss zudem präzisiert werden, welcher Aspekt untersucht wird und ob dieser durch Kategorien oder durch kontinuierliche Merkmalsdimensionen beschrieben werden soll.

Die Zuordnung von Phänomenen zu Variablentypen enthält somit einen gestalterischen und von der Forschungsfrage abhängigen Anteil, der begründet werden muss. Das gilt auch für die Entscheidung, welche Variation als interessierendes Signal und welche als störendes Rauschen behandelt wird. Was in einer Untersuchung als Störeinfluss gilt, kann in einer anderen selbst zum Gegenstand der Forschung werden.

Selbstkontrollfragen

1. Erläutern Sie die Begriffe Naturwissenschaft, Geisteswissenschaft und Formalwissenschaft.
2. Erläutern Sie das idealisierte Zusammenspiel von Theorie und Empirie im naturwissenschaftlichen Prozess.
3. Erläutern Sie die Begriffe Induktion und Deduktion.
4. Erläutern Sie den Begriff einer Theorie.
5. Erläutern Sie den Begriff einer Hypothese.
6. Erläutern Sie den Begriff eines Experiments.
7. Erläutern Sie den Begriff einer Variable und die drei im Text behandelten Dimensionen ihrer Klassifikation.
8. Erläutern Sie die Begriffe manifeste und latente Variablen anhand von Beispielen.
9. Erläutern Sie die Rollen unabhängiger und abhängiger Variablen in einer Studie.
10. Erläutern Sie die Begriffe diskrete und kontinuierliche Variablen.

2 Psychologische Forschung

2.1 Formen psychologischer Forschung

Wir wollen uns nun der Frage zuwenden, was *Psychologie* eigentlich ist. Folgende Definition ist allgemein akzeptiert (vgl. Döring (2023, S. 4), Schütz et al. (2015, S. 24), Myers (2010, S. 6)).

Definition 2.1 (Psychologie)**.** Psychologie bezeichnet die Wissenschaft des menschlichen Erlebens, Verhaltens und Handelns. Sie verfolgt das Ziel, neuropsychologische Phänomene zu *beschreiben*, zu *erklären*, *vorherzusagen* und zu *verändern*. Das *Beschreiben* umfasst dabei zunächst das Benennen und Klassifizieren relevanter Phänomene. Das *Erklären* zielt auf die Entwicklung mechanistischer neuropsychologischer Modelle, die verständlich machen, wie diese Phänomene zustande kommen. Das *Vorhersagen* richtet sich auf die Prognose zukünftigen Erlebens, Verhaltens und Handelns. Das *Verändern* schließlich umfasst psychologische Interventionen, wie beispielsweise die Prävention, Diagnose und Behandlung psychiatrischer Erkrankungen.

•

Um sich konkret mit Beispielen psychologischer Forschung zu befassen, ist es hilfreich, mit der psychologischen Grundlagenforschung und der psychologischen Anwendungsforschung zunächst eine grobe Einteilung psychologischer Forschungsaktivitäten vorzunehmen.

Die *psychologische Grundlagenforschung* zielt darauf, die mechanistischen Zusammenhänge eines Gegenstandsbereichs zu verstehen. Sie untersucht, wie und warum menschliches Erleben, Verhalten und Handeln zustande kommen. Auf der Grundlage vorhandenen Wissens werden intuitiv neue mechanistische Ideen entwickelt, quantitativ anhand empirischer Daten überprüft und zusammen mit den sie stützenden Befunden kommuniziert und rational diskutiert. Die *psychologische Anwendungsforschung* zielt darauf, zu verstehen, welche Interventionen ein gewünschtes Ergebnis hervorbringen. Sie untersucht, wie menschliches Erleben, Verhalten und Handeln verändert werden können, ohne die zugrunde liegenden Mechanismen notwendigerweise vollständig zu verstehen. Auch hier werden auf der Grundlage vorhandenen Wissens intuitiv neue Ideen entwickelt, in diesem Fall für Interventionen. Diese werden ebenfalls quantitativ anhand empirischer Daten überprüft und zusammen mit den sie stützenden Befunden kommuniziert und rational diskutiert.

Neben diesen grundsätzlichen Gemeinsamkeiten im wissenschaftlichen Vorgehen unterscheiden sich psychologische Grundlagenforschung und Anwendungsforschung auch in ihren praktischen Rahmenbedingungen und den Maßstäben, nach denen ihre Ergebnisse bewertet werden (vgl. Döring (2023, Kapitel 1, Tabelle 1.3), Freeman & Rossi (1984, S. 572), Neuman (2011, S. 23)). In der *psychologischen Grundlagenforschung* wählen Forschende ihre Themen meist frei und verfolgen vorrangig das Ziel des wissenschaftlichen Erkenntnisgewinns. Dabei orientieren sie sich am aktuellen Forschungsstand und streben

größtmögliche wissenschaftliche Strenge an. Ihre Arbeit wird durch Fachkolleg:innen primär nach wissenschaftlichen Kriterien bewertet. Die Ergebnisse werden in Publikationen veröffentlicht und durch Zitationen aufgegriffen, während sich ein praktischer Nutzen häufig erst indirekt durch spätere Anwendungen ergibt. In der *psychologischen Anwendungsforschung* werden die Themen dagegen meist durch Auftraggeber:innen vorgegeben. Im Vordergrund stehen wissenschaftliche Befunde mit praktischem Nutzen, wobei zeitliche, finanzielle und praktische Rahmenbedingungen die erreichbare wissenschaftliche Strenge begrenzen. Die Bewertung erfolgt durch Auftraggeber:innen primär nach dem praktischen Nutzen der Ergebnisse. Diese dienen als Grundlage für Praxisentscheidungen und können darüber hinaus zu Publikationen und wissenschaftlichem Erkenntnisgewinn beitragen.

Liest man eine psychologische Studie, also ein *Paper*, ist es zunächst sinnvoll, sich einen Überblick darüber zu verschaffen, um welche Form von Studie es sich handelt. Dies hilft dabei, den groben Rahmen und die Zielsetzung des Papers zu antizipieren. Man unterscheidet zunächst theoretische, methodische und empirische Studien (vgl. Döring (2023, Kapitel 7)). *Theoretische Studien* dienen der Präsentation und Bewertung des Forschungsstands zu einem Gegenstand, etwa in Form eines Reviews, oder der Formalisierung und Simulation quantitativer Theorien. *Methodische Studien* befassen sich mit dem Vergleich und der Weiterentwicklung von Forschungsmethoden sowie mit der Simulation und Anwendung datenanalytischer Verfahren. *Empirische Studien* behandeln inhaltliche Forschungsthemen mithilfe empirischer Methoden. Dazu zählen Originalstudien, die neue empirische Befunde zu einer Forschungsfrage beitragen, Replikationsstudien, die untersuchen, ob sich die Ergebnisse früherer Studien bei erneuter Durchführung bestätigen lassen, und Metaanalysen, die die Ergebnisse mehrerer Studien zu einer Forschungsfrage quantitativ zusammenfassen.

Empirische Originalstudien lassen sich anhand ihrer Zielsetzung weiter untergliedern. *Deskriptive Studien* dienen der Charakterisierung einer Population anhand repräsentativer Stichproben. Sie weisen meist einen großen Stichprobenumfang auf und verfolgen ein deskriptiv-statistisches Vorgehen. *Explorative Studien* erkunden bisher wenig untersuchte Gegenstandsbereiche. Sie arbeiten meist mit kleineren Stichproben und einem weniger standardisierten Vorgehen. *Konfirmatorische Studien* dienen der explanativen Überprüfung von Hypothesen, die aus einer Theorie hergeleitet wurden. Sie weisen meist einen mittleren Stichprobenumfang auf und gehen eher inferenzstatistisch vor.

Im Folgenden wollen wir einige Beispiele psychologischer Grundlagen- und Anwendungsforschung im Kontext von empirischen Originalstudien geben. Wir gliedern die Diskussion dieser Beispiele dabei grob in die Beschreibung ihres Gegenstandes, also des neuropsychologischen Phänomens von Interesse, die Darstellung seiner experimentellen Simulation im Rahmen des Studiendesigns, die Erläuterung der zugrunde liegenden Theorie und der daraus abgeleiteten Datenvorhersage sowie die Darstellung der Datenanalyse und der Ergebnisse der jeweiligen Studie.

2.2 Beispiele psychologischer Grundlagenforschung

Beispiel 2.1 (Erklären und Vorhersagen menschlichen Verhaltens)**.** Unser erstes Beispiel lässt sich in den Rahmen der *agentischen Verhaltensmodellierung* einordnen (vgl. Ostwald et al. (2026)). Dabei werden künstliche Agenten als mathematisch und informatisch formulierte Theorien über

menschliche Wahrnehmungs-, Lern- und Entscheidungsprozesse verwendet. Ein Agent nimmt Informationen aus seiner Umgebung auf, verarbeitet diese nach bestimmten Regeln und wählt Handlungen aus. Anhand des beobachtbaren Verhaltens menschlicher Versuchspersonen wird untersucht, welche dieser Regeln ihr Verhalten erklären und vorhersagen können.

Dabei unterscheiden wir drei Modellkomponenten. Das *Aufgabenmodell* beschreibt die experimentelle Umgebung, die verfügbaren Handlungsmöglichkeiten und deren Konsequenzen. Das *Agentenmodell* beschreibt die angenommenen kognitiven Prozesse, mit denen Versuchspersonen die Aufgabe bearbeiten. Das *Datenmodell* stellt die statistische Verbindung zwischen diesen Annahmen und den beobachteten Verhaltensdaten her. Ihr Zusammenspiel ermöglicht es, Verhalten zu simulieren, Modellparameter anhand empirischer Daten zu schätzen und unterschiedliche Erklärungsansätze miteinander zu vergleichen. Entscheidend ist dabei, wie gut die Modelle menschliches Verhalten erfassen. So verbindet die agentische Verhaltensmodellierung mechanistische Theoriebildung mit quantitativer empirischer Überprüfung.

Wie in Abbildung 2.1 dargestellt, kann diese Überprüfung auf unterschiedlichen Ebenen erfolgen. Bei der *Inferenz auf Individualebene* (*participant-level inference*) wird untersucht, welche Modellparameter und welches Agentenmodell das Verhalten einer einzelnen Versuchsperson am besten beschreiben. Dies ermöglicht die Untersuchung individueller Unterschiede und bietet Anknüpfungspunkte für die Computational Psychiatry. Bei der *Inferenz auf Gruppenebene* (*group-level inference*) werden die Befunde mehrerer Versuchspersonen zusammengeführt, um zu beurteilen, welche Agentenmodelle innerhalb einer untersuchten Gruppe besonders gut gestützt werden. Damit lassen sich über einzelne Personen hinausgehende Regelmäßigkeiten menschlichen Verhaltens untersuchen.

Das folgende Beispiel zeigt, wie *agentische Verhaltensmodellierung* im Bereich der *Computational Psychiatry* eingesetzt werden kann. Dieses Forschungsfeld verbindet mathematische Modelle psychischer Prozesse mit empirischen Daten, um psychische Störungen besser zu verstehen und klinische Verläufe sowie Behandlungsergebnisse vorherzusagen (vgl. Montague et al. (2012), Huys et al. (2016), Seriès (2020)).

Gegenstandsbereich und Phänomen. Die Studie von Usée et al. (2026) untersucht menschliches Verhalten in Situationen, in denen mögliche Belohnungen und Bestrafungen miteinander in Konflikt stehen. Solche *Annäherungs-Vermeidungs-Konflikte* (*approach-avoidance conflicts*) sind unter anderem für das Verständnis von Angststörungen relevant. Übermäßiges Vermeidungsverhalten kann den Alltag einschränken und korrigierende Erfahrungen verhindern, wodurch Ängste aufrechterhalten werden können. Um Entscheidungen unter solchen Konflikten untersuchbar zu machen, verwendet die Studie eine visuelle Suchaufgabe, die an die Nahrungssuche (*foraging*) angelehnt ist. Im Mittelpunkt steht die Frage, wann Menschen eine potenziell lohnende, zugleich aber mit möglichen Bestrafungen verbundene Suche fortsetzen oder beenden. Einen theoretischen Bezugspunkt bildet das *Marginal-Value-Theorem*, nach dem die durchschnittlich verfügbare Ertragsrate der Umgebung als Maßstab für das Fortsetzen oder Beenden einer Suche dient. Daran orientierte Agentenmodelle sollen beschreiben, wie Menschen diese Entscheidung unter Annäherungs-Vermeidungs-Konflikten treffen.

Experimentelle Simulation. In der Studie von Usée et al. (2026) bearbeiteten die Versuchspersonen eine visuelle Suchaufgabe (Abbildung 2.2). Teilabbildung A zeigt die vier Versuchsbedingungen eines zweifaktoriellen Designs, in dem die Anzahl möglicher Belohnungen und Bestrafungen jeweils niedrig oder hoch war. Hinter 16 blauen Kreisen waren jeweils zwei oder sechs Münzen beziehungsweise unangenehme Schreie verborgen. Die räumliche Anordnung der Kreise kennzeichnete die jeweilige Bedingung. Diese Zuordnung lernten die Versuchspersonen vor Beginn der eigentlichen Suchaufgabe. Teilabbildung B veranschaulicht den Ablauf eines Durchgangs. Nach einem Fixationspunkt erschien ein Suchfeld, dessen Kreise durch Anklicken untersucht werden konnten. Dabei konnten die Versuchspersonen eine Münze entdecken, einen unangenehmen Schrei hören oder einen leeren Kreis aufdecken. Entdeckte Münzen konnten durch einen weiteren Klick eingesammelt werden und erhöhten den experimentellen Punktestand. Über die Schaltfläche „EXIT“ konnte die Suche jederzeit beendet oder vollständig vermieden werden. Anschließend wurden die Zuordnung des Suchfelds zur Versuchsbedingung und die Sicherheit dieser Einschätzung erfragt. Teilabbildung C zeigt die Anzahl unterschiedlicher untersuchter Kreise (*unique clicks*) als Maß

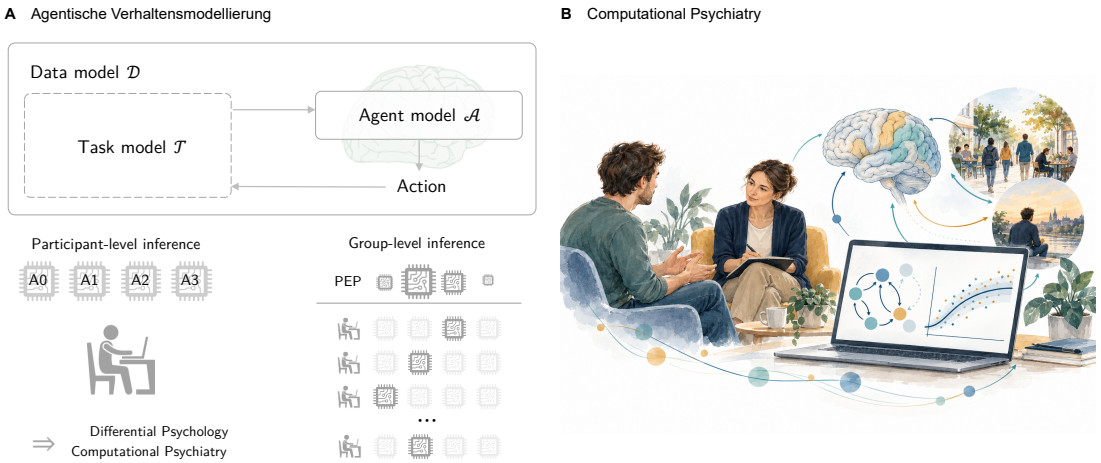

Abbildung 2.1 Agentische Verhaltensmodellierung und Computational Psychiatry. (A) Aufgaben-, Agenten- und Datenmodell bilden den Rahmen zur Erklärung und Vorhersage menschlichen Verhaltens. Die Inferenz auf Individualebene dient der Beurteilung von Agentenmodellen für einzelne Versuchspersonen. Die Inferenz auf Gruppenebene führt die Befunde mehrerer Versuchspersonen zusammen. Darstellung nach Ostwald et al. (2026). (B) Konzeptuelle Illustration der Verbindung von Psychotherapie, quantitativer Modellierung, Gehirnfunktionen und Alltagskontext in der Computational Psychiatry.

für den Suchumfang. Wiederholte Klicks auf denselben Kreis werden dabei nicht erneut gezählt. Deskriptiv fällt der Suchumfang bei hoher Belohnung und niedriger Bestrafung am größten und bei niedriger Belohnung und hoher Bestrafung am kleinsten aus.

Theorie und Datenvorhersage. Die theoretische Erklärung des Suchverhaltens lässt sich anhand eines Beispielagenten aus Usée et al. (2026) grob skizzieren. Dieser Agent ist einer von mehreren möglichen Agenten, mit denen sich unterschiedliche Annahmen über menschliches Suchverhalten formalisieren lassen. Seine Grundannahme lautet, dass eine Person den aktuellen Wert der Suche mit dem Wert alternativer Suchmöglichkeiten vergleicht und ihre Suche eher beendet, wenn die aktuelle Möglichkeit weniger attraktiv erscheint. Vier Formeln beschreiben diesen Zusammenhang. Dabei bezeichnet s die Versuchsbedingung, t den Durchgang und c die Anzahl bereits untersuchter Kreise.

Der *aktuelle Wert der Suche* ergibt sich für den Beispielagenten A7 als

$$v_7(s,t,c) = \beta_{0,s} + \beta_1 r_s + \beta_2 p_s - \beta_1 n_r(s,t,c) + \beta_2 n_p(s,t,c), \qquad \beta_1 > 0, \quad \beta_2 < 0. \tag{2.1}$$

Grob gesprochen verbindet dieser Wert die erwarteten Belohnungen und Bestrafungen mit den bisherigen Entdeckungen, wobei gefundene Belohnungen die verbleibenden Gewinnmöglichkeiten verringern und erfahrene Bestrafungen die weitere Suche unattraktiver machen. Der *Referenzwert alternativer Suchmöglichkeiten* lautet

$$\bar{v}(s) = \frac{1}{|S|-1} \sum_{s' \in S \setminus \{s\}} \left(\beta_1 r_{s'} + \beta_2 p_{s'}\right). \tag{2.2}$$

Er beschreibt die durchschnittliche Attraktivität der anderen Versuchsbedingungen und dient damit als Vergleichsmaßstab für die aktuelle Suche. Die *bedingte Wahrscheinlichkeit, die Suche zu beenden*, ist

$$\pi_7(s,t,c) = \frac{1}{1+\exp\left(v_7(s,t,c) - \bar{v}(s)\right)}, \qquad c < 16, \qquad \pi_7(s,t,16) = 1. \tag{2.3}$$

Je niedriger der aktuelle Wert im Vergleich zum Referenzwert ausfällt, desto wahrscheinlicher beendet der Agent die Suche, sofern er bis dahin noch weitergesucht hat. Die *Wahrscheinlichkeits-*

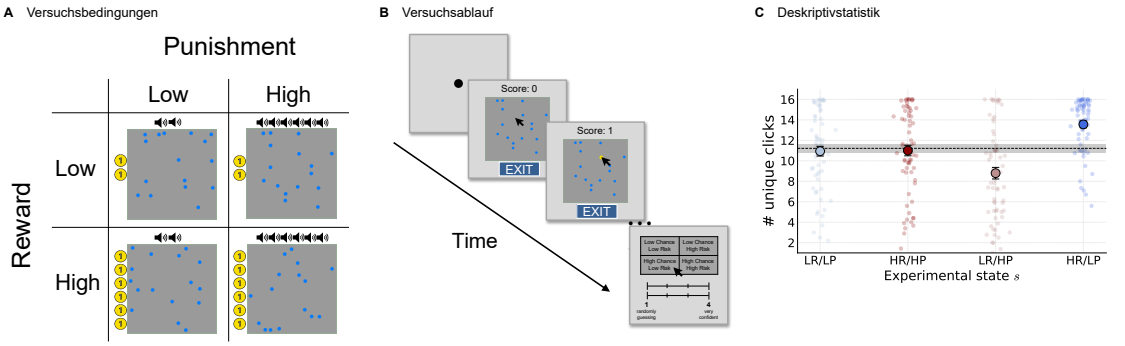

Abbildung 2.2 Experimentelle Untersuchung von Annäherungs-Vermeidungs-Konflikten. (A) Vier Versuchsbedingungen mit jeweils niedriger oder hoher Anzahl verborgener Belohnungen und Bestrafungen. (B) Ablauf eines Suchdurchgangs mit frei wählbarem Suchumfang und anschließender Einschätzung der Versuchsbedingung. (C) Deskriptive Darstellung der Anzahl unterschiedlicher untersuchter Kreise in den vier Bedingungen. LR und HR bezeichnen niedrige beziehungsweise hohe Belohnung, LP und HP niedrige beziehungsweise hohe Bestrafung. Abbildungen nach Usée et al. (2026).

verteilung der Stoppentscheidung ergibt sich als

$$p_7(a_t = c \mid s_t) = \pi_7(s_t, t, c) \prod_{k=1}^{c-1} (1 - \pi_7(s_t, t, k)), \qquad c = 1, \ldots, 16. \tag{2.4}$$

Die Wahrscheinlichkeit, nach genau c untersuchten Kreisen aufzuhören, verbindet somit die Wahrscheinlichkeit des vorherigen Weitersuchens mit der Wahrscheinlichkeit des anschließenden Beendens.

Abbildung 2.3 veranschaulicht diese Schritte für den Beispielagenten A7. Von links nach rechts zeigt sie die entdeckten Belohnungen und Bestrafungen, den aktuellen Wert im Vergleich zum Referenzwert, die daraus resultierende Stoppwahrscheinlichkeit und die Verteilung der Stoppentscheidungen. Auf diese Weise führen Annahmen über die Bewertung der Suche zu *Datenvorhersagen* darüber, mit welcher Wahrscheinlichkeit unterschiedlich lange gesucht wird und wie sich diese Suchlängen zwischen den vier Versuchsbedingungen unterscheiden.

Datenanalyse und Ergebnis. Zur Überprüfung der theoretischen Erklärung passten Usée et al. (2026) neun unterschiedliche Agentenmodelle an die individuellen Verhaltensdaten an. Dabei wurden die Modellparameter für jede Versuchsperson so geschätzt, dass das beobachtete Verhalten unter dem jeweiligen Modell möglichst wahrscheinlich war. Anschließend wurden die Modelle anhand des *Bayesianischen Informationskriteriums* (*BIC*) verglichen, das neben der Passung an die Daten auch die Modellkomplexität berücksichtigt. Für den Suchumfang ergab sich über alle Versuchspersonen hinweg die stärkste Unterstützung für Agent A8, der den zuvor erläuterten Agenten A7 um eine Veränderung der Bewertung im Verlauf des Experiments erweitert (Abbildung 2.4). Beide Agenten schnitten deutlich besser ab als die Vergleichsmodelle A0 bis A6. Auf Individualebene beschrieb A7 die Daten von 27 Personen am besten, A8 die Daten von 21 Personen. Eine ergänzende Auswertung auf Gruppenebene ergab nahezu gleiche *Protected Exceedance Probabilities* (*PEP*) für A7 und A8 von 0,51 beziehungsweise 0,49. Dieses Maß beurteilt, welches Modell in der zugrunde liegenden Population am häufigsten das Verhalten erklärt. Insgesamt stützen die Ergebnisse damit die Vorstellung, dass Menschen ihre Suche unter Annäherungs-Vermeidungs-Konflikten anhand eines Vergleichs zwischen dem aktuellen Wert der Suche und dem Wert alternativer Suchmöglichkeiten regulieren.

△

Beispiel 2.2 (Entwicklung mechanistischer neuropsychologischer Modelle)**.** Ein weiteres Beispiel psychologischer Grundlagenforschung betrifft die Entwicklung *mechanistischer neuropsychologi-*

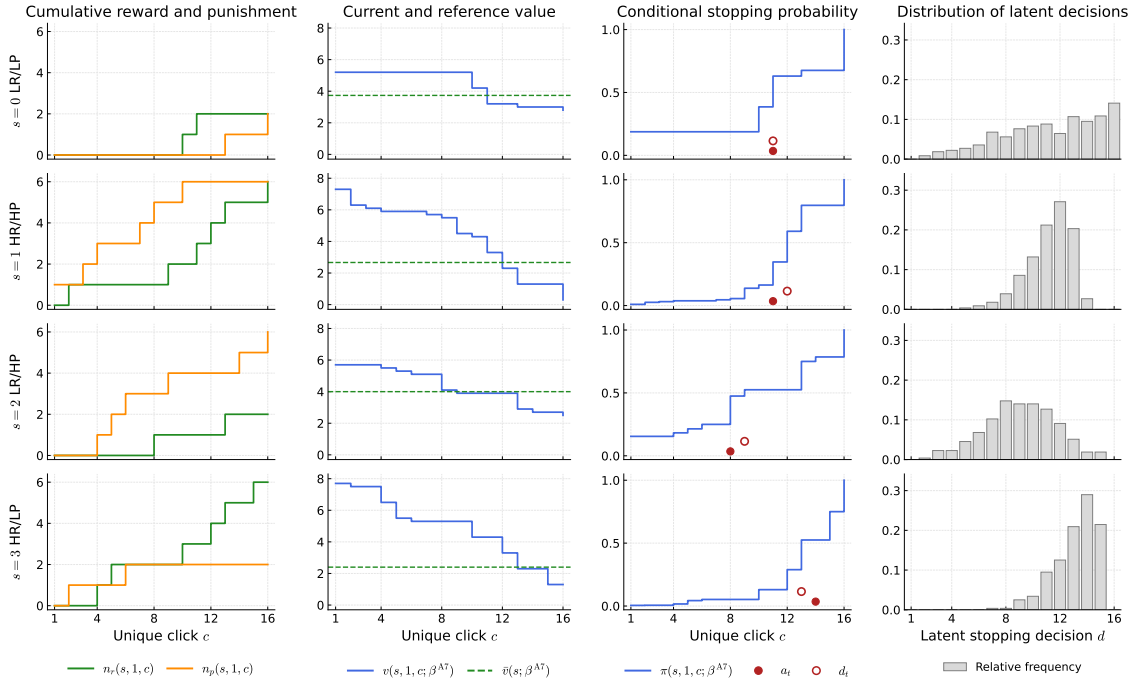

Abbildung 2.3 Datenvorhersagen des Beispielagenten A7. Die Zeilen zeigen die vier Versuchsbedingungen mit niedriger (LR) oder hoher (HR) Belohnung und niedriger (LP) oder hoher (HP) Bestrafung. Von links nach rechts sind die kumulativ entdeckten Belohnungen und Bestrafungen, der aktuelle Wert der Suche und der Referenzwert, die bedingte Stoppwahrscheinlichkeit sowie die Verteilung der Stoppentscheidungen dargestellt. Die Abbildung veranschaulicht, wie aus der Bewertung einer Suchmöglichkeit Vorhersagen über die Suchlänge entstehen. Abbildung nach Usée et al. (2026).

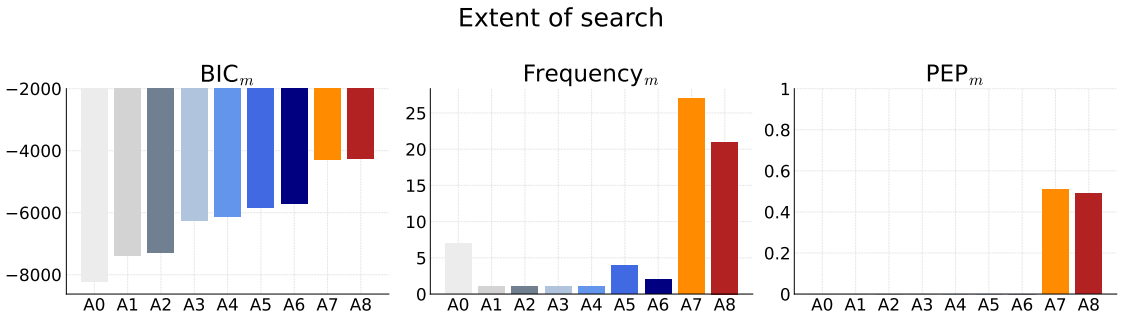

Abbildung 2.4 Vergleich der Agentenmodelle zur Erklärung des Suchumfangs. Links ist das über die Versuchspersonen summierte Bayesianische Informationskriterium (BIC) dargestellt, wobei höhere Werte in der hier verwendeten Konvention eine stärkere Unterstützung anzeigen. Die mittlere Teilabbildung zeigt, für wie viele Versuchspersonen das jeweilige Modell am besten abschnitt. Rechts sind die Protected Exceedance Probabilities (PEP) dargestellt. Der kumulative BIC favorisiert A8, während A7 die meisten individuellen Modellsiege erzielt. Die PEP verteilen sich nahezu gleich auf A7 und A8. Abbildung nach Usée et al. (2026).

scher Modelle. Einen theoretischen Rahmen bildet die *Bayesian Brain Hypothesis* (Abbildung 2.5). Ihr zufolge erschließt das Gehirn die Ursachen seiner Sinneseindrücke, indem es Vorwissen und aktuelle sensorische Informationen nach den Prinzipien Bayesianischer Inferenz miteinander verbindet. In der von Friston (2005) beschriebenen Umsetzung als *Predictive Coding* spielen insbesondere *Prädiktionsfehler* eine zentrale Rolle, also Abweichungen zwischen vorhergesagten und tatsächlich eintreffenden Informationen. Die Idee ist, dass sensorisch ausgelöste neuronale Antworten wesentlich solche Abweichungen repräsentieren und zur Anpassung interner Vorstellungen über die Umwelt

beitragen. Diese Annahmen lassen sich mithilfe mathematischer Modelle konkretisieren und anhand elektrophysiologischer Messungen überprüfen. Ostwald et al. (2012) und Gijsen et al. (2021) untersuchten hierzu Zusammenhänge zwischen modellbasierter Überraschung und EEG-Antworten auf somatosensorische Reize. Lindborg et al. (2023) übertrugen diesen Ansatz auf die Sprachverarbeitung und zeigten, dass semantische Überraschung die N400-Komponente des EEG vorhersagt. Diese Arbeiten veranschaulichen, wie sich abstrakte Annahmen über Wahrnehmung und Lernen mit messbarer Gehirnaktivität verbinden lassen.

Experimentelle Simulation. Zur Untersuchung der Verarbeitung somatosensorischer Reize stimulierten Ostwald et al. (2012) und Gijsen et al. (2021) den *Nervus medianus* mithilfe von Elektroden am Handgelenk und zeichneten gleichzeitig die elektrische Gehirnaktivität mittels EEG auf. Kurze elektrische Impulse wurden in zwei individuell angepassten Intensitäten dargeboten, die deutlich unterscheidbar, aber nicht schmerzhaft waren. Die Reizfolgen folgten einem *Roving-Paradigma*: Ein Reiz gleicher Intensität wurde mehrfach wiederholt, bevor die Intensität wechselte (Abbildung 2.6, A). Durch die Wiederholung konnte sich eine Erwartung ausbilden, die beim Wechsel verletzt wurde. Der erste Reiz nach einem Wechsel wurde als *Deviant*, der letzte Reiz vor dem nächsten Wechsel als *Standard* ausgewertet. Somit konnten sowohl schwache als auch starke Reize beide Rollen einnehmen, wodurch sich Effekte der Reizgeschichte von Unterschieden der physikalischen Reizintensität trennen ließen. Bei Ostwald et al. (2012) war die Wahrscheinlichkeitsstruktur vergleichsweise einfach: Die Länge jeder Wiederholungsfolge wurde gleichwahrscheinlich aus 2, 4, 8 oder 16 Reizen gewählt, der Abstand zwischen den Reizen betrug 650 ms. Gijsen et al. (2021) verwendeten bei einem Reizabstand von 750 ms eine komplexere Reizgenerierung. Hier wechselte die Sequenz zwischen verborgenen Zuständen mit unterschiedlichen Wahrscheinlichkeiten für Reizwiederholungen und Intensitätswechsel. Zusätzlich hing die Wahrscheinlichkeit des nächsten Reizes von den beiden vorherigen Reizen ab. Dadurch entstanden Phasen mit überwiegend längeren beziehungsweise kürzeren Wiederholungsfolgen. Diese Manipulation ermöglichte es zu untersuchen, wie das Gehirn statistische Regelmäßigkeiten erlernt und seine Erwartungen an Veränderungen dieser Regelmäßigkeiten anpasst.

Theorie. Die theoretischen Modelle beschreiben das Gehirn als ein System, das aus einer beobachteten Reizfolge Wahrscheinlichkeiten zukünftiger Reize erschließt. Dazu werden Annahmen über die Wahrscheinlichkeitsverteilung der Reize und ihre bedingten Abhängigkeiten formuliert. Ein *Dirichlet-Categorical-Modell* beschreibt beispielsweise das Lernen von Auftretens- oder Übergangswahrscheinlichkeiten, während ein *Hidden-Markov-Modell* zusätzlich verborgene Zustände annimmt, die unterschiedliche statistische Regelmäßigkeiten der Reizfolge erzeugen. Neue Beobachtungen aktualisieren die bisherigen Annahmen, indem eine Priorverteilung mithilfe der Likelihood in eine Posteriorverteilung überführt wird. Ein Vergessensmechanismus kann dabei ältere Beobachtungen geringer gewichten, sodass sich die Erwartungen an veränderte Reizwahrscheinlichkeiten anpassen. Auf dieser Grundlage lassen sich unterschiedliche Formen von *Überraschung* (*Surprise*) als probabilistische Beschreibungen von Erwartungsverletzungen und damit als mögliche Prädiktionsfehlerrepräsentationen bestimmen. *Prädiktive Überraschung* (*Predictive Surprise*) erfasst, wie unwahrscheinlich ein beobachteter Reiz unter der prädiktiven Wahrscheinlichkeitsverteilung war. *Bayesianische Überraschung* (*Bayesian Surprise*) beschreibt dagegen anhand der Kullback-Leibler-Divergenz zwischen Prior- und Posteriorverteilung, wie stark die Beobachtung die bisherigen Annahmen verändert. *Konfidenzkorrigierte Überraschung* (*Confidence-Corrected Surprise*) berücksichtigt zusätzlich, wie sicher das System seiner bisherigen Einschätzung war, sodass eine Verletzung sicherer Erwartungen besonders überraschend sein kann. Diese Größen sind keine einfachen Differenzen zwischen vorhergesagter und beobachteter Reizintensität, sondern erfassen unterschiedliche Aspekte probabilistischer Prädiktionsfehler und der daraus folgenden Modellaktualisierung. Die zentrale Hypothese lautet, dass sich solche modellbasierten Größen in den reizbezogenen EEG-Antworten widerspiegeln und dadurch Hinweise auf die Mechanismen neuronaler Vorhersage und Anpassung liefern (vgl. Ostwald et al. (2012), Gijsen et al. (2021)).

Ergebnis. Bei Ostwald et al. (2012) erklärte Bayesianische Überraschung die EEG-basierte Schätzung der Aktivität im sekundären somatosensorischen Kortex etwa 140 ms nach Reizbeginn besser als die bloße Unterscheidung zwischen Reizwiederholung und Reizwechsel. Dies spricht dafür, dass

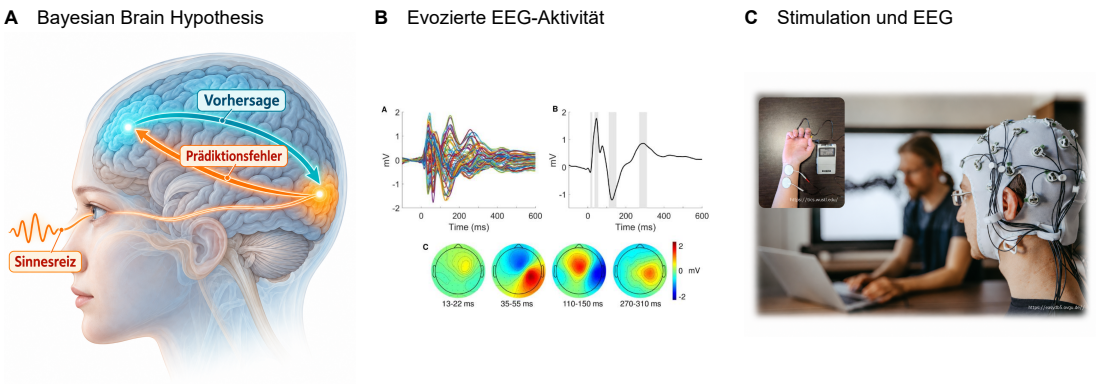

Abbildung 2.5 Bayesian Brain Hypothesis und elektrophysiologische Untersuchung der Wahrnehmung. (A) Schematische Illustration des Zusammenspiels von sensorischen Informationen, Vorhersagen und Prädiktionsfehlern. Am Beispiel der visuellen Wahrnehmung erreicht der Sinnesreiz den Okzipitallappen. Vorhersagen verlaufen schematisch vom Frontal- zum Okzipitallappen, Prädiktionsfehler in umgekehrter Richtung. Die Pfeile veranschaulichen das Modellprinzip und stellen keine exakten anatomischen Verbindungsbahnen dar. (B) Zeitverläufe evozierter EEG-Aktivität und räumliche Verteilungen elektrischer Potentiale auf der Kopfoberfläche, übernommen aus der Darstellung auf Folie 21 der Präsentation zu Ostwald et al. (2012). (C) Illustration der elektrischen Stimulation des Nervus medianus am Handgelenk und der EEG-Aufnahme mittels Elektrodenkappe.

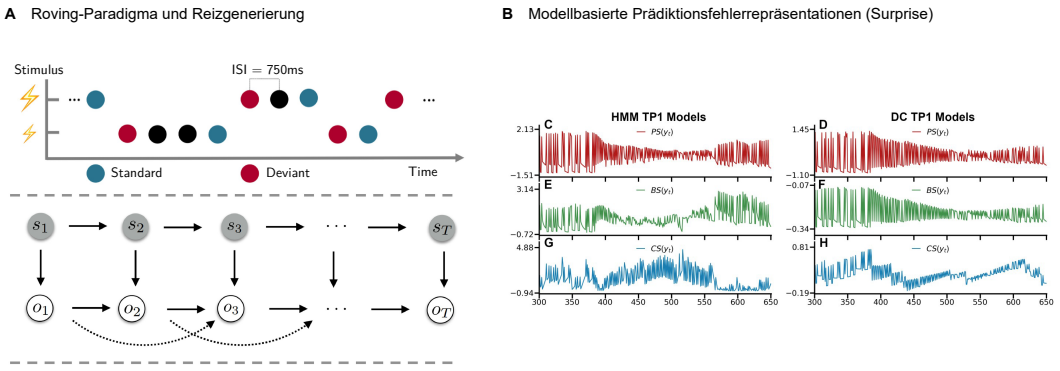

Abbildung 2.6 Roving-Paradigma und modellbasierte Prädiktionsfehlerrepräsentationen (Surprise). (A) Reizfolge mit zwei Intensitäten und schematische Darstellung ihrer probabilistischen Generierung. Verborgene Zustände bestimmen gemeinsam mit der bisherigen Reizfolge die Wahrscheinlichkeiten nachfolgender Reize. (B) Beispielhafte Verläufe prädiktiver Überraschung (PS), Bayesianischer Überraschung (BS) und konfidenzkorrigierter Überraschung (CS) für ein Hidden-Markov-Modell (HMM) und ein Dirichlet-Categorical-Modell (DC). Dargestellt sind Modellgrößen über aufeinanderfolgende Reize, keine gemessenen EEG-Signale. Abbildungen nach Gijsen et al. (2021).

die neuronale Antwort von der vorausgehenden Reizgeschichte und der damit verbundenen Aktualisierung von Erwartungen abhängt. Spätere Antworten spiegelten um 250 ms im rechten inferioren Frontalkortex eher den Reizwechsel wider, während sich um 360 ms Hinweise auf weitere Lernprozesse mit einer vermuteten Quelle im mittleren cingulären Kortex ergaben. Bei Gijsen et al. (2021) erklärte unter den untersuchten Modellen ein nicht-hierarchisches *Dirichlet-Categorical-Modell* die EEG-Daten am besten, das Übergangswahrscheinlichkeiten zwischen aufeinanderfolgenden Reizen lernt und ältere Beobachtungen geringer gewichtet. *Konfidenzkorrigierte Überraschung* zeigte sich bereits ab etwa 70 ms und wurde dem sekundären somatosensorischen Kortex zugeordnet. Für *Bayesianische Überraschung* fanden sich schwächere Hinweise um 140 ms im primären somatosensorischen Kortex. Dieser spätere Befund stimmt zeitlich, jedoch nicht in der anatomischen Zuord-

nung mit Ostwald et al. (2012) überein. Zusammengenommen stützen die Ergebnisse die Annahme, dass unterschiedliche Aspekte von Prädiktionsfehlern und Erwartungsaktualisierungen in zeitlich und räumlich unterscheidbaren neuronalen Antworten repräsentiert werden.

△

2.3 Beispiele psychologischer Anwendungsforschung

Beispiel 2.3 (Online- und Face-to-face-Therapie bei Depression)**.** Die Studie von Wagner et al. (2014) ist ein Beispiel psychologischer Anwendungsforschung aus dem Bereich der *klinischen Forschung*, auf den wir an späterer Stelle ausführlich eingehen werden. Im Mittelpunkt steht die Frage, ob eine therapeutisch begleitete Onlinebehandlung depressive Beschwerden ähnlich wirksam reduzieren kann wie eine Behandlung im persönlichen Gespräch (Abbildung 2.7).

Gegenstandsbereich und Phänomen. Depressionen beeinträchtigen das Erleben und Verhalten sowie die Bewältigung des Alltags. Internetbasierte Behandlungen könnten den Zugang zu psychotherapeutischer Unterstützung erleichtern. Untersucht wurde deshalb, wie sich die Depressionssymptomatik bei einer schriftlichen Onlinebehandlung im Vergleich zu einer Face-to-face-Behandlung verändert. Als zentrales Maß diente das *Beck-Depressions-Inventar II* (*BDI-II*), ein Fragebogen zur Schwere depressiver Symptome.

Experimentelle Simulation. Insgesamt 62 Teilnehmende wurden zufällig einer Onlinegruppe mit 32 Personen oder einer Face-to-face-Gruppe mit 30 Personen zugeordnet. Beide Gruppen erhielten über acht Wochen dieselben Behandlungsmodule der kognitiven Verhaltenstherapie in derselben Reihenfolge. Online wurden schriftliche Aufgaben mit individuellem schriftlichem Feedback bearbeitet. Die Symptomatik wurde vor und nach der Behandlung sowie nach weiteren drei Monaten erfasst.

Theorie. Die Untersuchung knüpfte an Befunde zur Wirksamkeit internetbasierter Interventionen und zur Bedeutung therapeutischer Begleitung an. Die Annahme war, dass zentrale Elemente der kognitiven Verhaltenstherapie auch durch strukturierte Schreibaufgaben und persönliche Rückmeldungen vermittelt werden können. Bei vergleichbaren Inhalten und intensiver Begleitung sollte daher auch die Onlinebehandlung depressive Symptome deutlich reduzieren.

Datenvorhersage. Erwartet wurde eine deutliche Abnahme der BDI-II-Werte in beiden Gruppen vom Beginn bis zum Ende der Behandlung. Die Verbesserungen sollten auch nach drei Monaten bestehen bleiben. Zwischen Online- und Face-to-face-Behandlung wurden weder unmittelbar nach der Therapie noch bei der Nachuntersuchung signifikante Unterschiede erwartet.

Ergebnis. Beide Gruppen zeigten deutliche Symptomreduktionen mit großen Effektstärken innerhalb der Gruppen, online mit $d = 1{,}27$ und Face-to-face mit $d = 1{,}37$. Unmittelbar nach der Therapie bestand kein signifikanter Gruppenunterschied. Nach drei Monaten blieb die Verbesserung online erhalten, während die Beschwerden in der Face-to-face-Gruppe wieder zunahmen. Der Gruppenunterschied war auch dann nicht signifikant ($p = 0{,}09$). Die Befunde sprechen für das Potenzial therapeutisch begleiteter Onlinebehandlungen, belegen jedoch keine vollständige Gleichwertigkeit.

△

2.4 Psychologische Anwendungsforschung durch BigTech

Beispiel 2.4 (Persönlichkeitspsychologie und Partnermatching bei Parship)**.** Die Partnervermittlung Parship veranschaulicht die kommerzielle Anwendung persönlichkeitspsychologischer Konzepte. Ein Fragebogen erfasst partnerschaftsbezogene Eigenschaften, Wünsche und Verhaltensweisen.

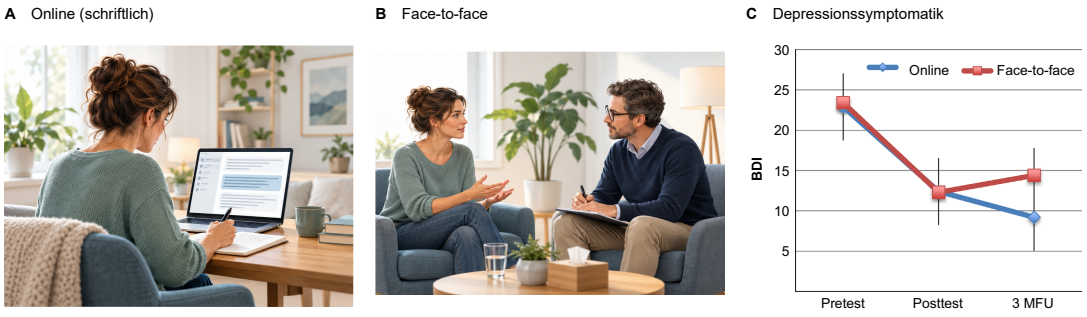

Abbildung 2.7 Vergleich schriftlicher Onlinebehandlung und Face-to-face-Behandlung bei Depression. (A) Illustration der Onlinebehandlung mit schriftlichen Aufgaben und therapeutischem Feedback. (B) Illustration der Behandlung im persönlichen Gespräch. (C) Mittlere BDI-II-Werte vor der Behandlung, unmittelbar danach und bei der Nachuntersuchung nach drei Monaten (3 MFU). Die Fehlerbalken zeigen Standardfehler. Ergebnisdarstellung nach Wagner et al. (2014).

Ein Algorithmus vergleicht anschließend die Profile hinsichtlich ihrer Gemeinsamkeiten und Unterschiede. Die daraus berechneten *Matching-Punkte* sollen nach Angaben des Anbieters die partnerschaftliche Passung vorhersagen. Weitere Kriterien wie Alter und Entfernung ergänzen die Auswahl möglicher Partnerinnen und Partner. Psychologische Merkmale werden somit operationalisiert und für individuelle Empfehlungen genutzt. Eine wissenschaftliche Überprüfung müsste untersuchen, wie gut diese Empfehlungen spätere Beziehungsqualität und Zufriedenheit vorhersagen. Die Beschreibung des Verfahrens durch den Anbieter allein liefert diesen Nachweis noch nicht (vgl. Parship, 2026).

△

Beispiel 2.5 (Kaufentscheidungsverhalten und Recommender Systems)**.** *Empfehlungssysteme* (*Recommender Systems*) nutzen Verhaltensdaten, um individuelle Präferenzen für Produkte und Inhalte vorherzusagen. Klicks, Käufe und Bewertungen geben Hinweise darauf, welche Angebote eine Person interessieren könnten. Beim *Collaborative Filtering* entstehen Empfehlungen aus Ähnlichkeiten zwischen den Präferenzen verschiedener Personen. Beim *Content-based Filtering* werden dagegen Eigenschaften bereits bevorzugter Produkte oder Inhalte genutzt, um ähnliche Angebote auszuwählen. Abbildung 2.8 veranschaulicht solche personalisierten Empfehlungen für Waren und Medieninhalte. Die Vorhersagegüte lässt sich anhand bislang ungenutzter Daten überprüfen. In A/B-Tests kann anschließend untersucht werden, ob ein verändertes Empfehlungssystem beispielsweise häufiger zu Käufen führt. So verbindet sich die Modellierung menschlichen Entscheidungsverhaltens mit der Optimierung digitaler Angebote (vgl. Aggarwal (2016)).

△

Beispiel 2.6 (Psychische Gesundheit und Gesprächsverhalten bei ChatGPT)**.** OpenAI untersucht Gesprächsmerkmale, die auf psychische Belastungen wie Psychose oder Manie hinweisen könnten, und nutzt diese Untersuchungen zur Weiterentwicklung von ChatGPT. Für 2025 schätzte das Unternehmen entsprechende Signale bei 0,07 % der wöchentlich aktiven Nutzenden und 0,01 % der Nachrichten. Ziel ist es, unerwünschte Antworten von ChatGPT in diesem Kontext zu minimieren. Als *unerwünschte Antworten* gelten hier Antworten von ChatGPT, die seinen festgelegten Verhaltensvorgaben widersprechen, etwa indem sie wahnhafte Überzeugungen bestätigen oder verstärken, statt sie behutsam einzuordnen und gegebenenfalls auf Unterstützung außerhalb des Chats hinzuweisen. Nach einem GPT-5-Update berichtete OpenAI in diesem Bereich 65 % weniger unerwünschte Antworten in realen Gesprächen. Eine Expertenbewertung von 677 schwierigen Gesprächsfällen ergab 39 % weniger unerwünschte Antworten als bei GPT-4o. In automatisierten Tests mit über 1.000 Fällen entsprachen 92 % statt zuvor 27 % der Antworten den Unternehmensvorgaben (vgl. OpenAI, 2025). Das Beispiel verbindet psychologische Forschung zur *Human-Computer-Interaktion*

Abbildung 2.8 Personalisierte Empfehlungen für Produkte und Medieninhalte. Verhaltensdaten bilden die Grundlage für die Auswahl potenziell interessanter Angebote. Die Illustration zeigt beispielhafte Anwendungsbereiche und Anbieter von Empfehlungssystemen. Zu den methodischen Grundlagen vgl. Aggarwal (2016).

mit *Sprachforschung*: Untersucht wird, wie Menschen mit einem sprachbasierten System kommunizieren, welche psychologisch relevanten Merkmale sich in ihren Äußerungen erkennen lassen und wie die sprachliche Gestaltung der Systemantworten bewertet und verbessert werden kann. Diese Verbindung hat eine lange Geschichte: Bereits das von Joseph Weizenbaum entwickelte Programm *ELIZA*, das als erster Chatbot gilt, simulierte in seinem bekannten DOCTOR-Skript das Gesprächsverhalten eines Psychotherapeuten nach dem Ansatz von Carl Rogers (vgl. Weizenbaum (1966)).

△

Beispiel 2.7 (Selbstkonzept und soziale Vergleiche bei Meta)**.** Interne Untersuchungen von Facebook, heute Meta, beschäftigten sich mit sozialen Vergleichen auf Instagram und dem Körperbild Jugendlicher. Damit greifen sie eine zentrale sozialpsychologische Frage auf: Wie beeinflusst der Vergleich mit anderen Menschen die Wahrnehmung und Bewertung der eigenen Person? Das *Selbstkonzept* umfasst Vorstellungen über die eigenen Eigenschaften, zu denen auch das eigene Aussehen gehört. Insbesondere Vergleiche mit als attraktiver wahrgenommenen Personen können für die Bewertung des eigenen Körpers bedeutsam sein. In den auf den Folien zusammengefassten Befragungen berichteten 66 % der Mädchen und 40 % der Jungen negative soziale Vergleiche. Unter den Mädchen mit negativem Körpergefühl gaben 32 % an, dass Instagram dieses Gefühl verstärke (vgl. Facebook, 2020). Die Veröffentlichung interner Befunde im Rahmen der *Facebook Files* des Wall Street Journal (2021) machte den Umgang mit diesem Wissen zum Gegenstand öffentlicher Debatten. Der Film *The Social Reckoning* (2026) greift die Geschichte der Whistleblowerin Frances Haugen und des Journalisten Jeff Horwitz auf.

△

Selbstkontrollfragen

1. Definieren Sie den Begriff Psychologie.
2. Nennen Sie vier Aspekte psychologischer Wissenschaft.
3. Erläutern Sie den Begriff der psychologischen Grundlagenforschung.
4. Erläutern Sie den Begriff der psychologischen Anwendungsforschung.
5. Erläutern Sie die Begriffe der theoretischen, methodischen und empirischen Studien.
6. Erläutern Sie die Begriffe der explorativen, deskriptiven und konfirmatorischen empirischen Studien.

3 Psychologische Daten

Wenn man einen empirischen Forschungsprozess betrachtet (Abbildung 3.1), so nehmen Daten eine zentrale Rolle ein. Nach Wahl eines *Forschungsthemas* und Rezeption des *Forschungsstandes* sind alle nachfolgenden Arbeitsphasen direkt datenbezogen: Im *Studiendesign* überlegt man sich, welche Daten benötigt werden, um die Forschungsfrage zu beantworten, und wie diese erhoben und ausgewertet werden sollen. Man legt beispielsweise fest, welche Variablen unter welchen Bedingungen und bei welchen Personen erfasst werden. In der *Datenerhebung* setzt man diese Planung um und zeichnet die interessierenden Beobachtungen auf, etwa die Antworten auf einen Fragebogen, die Reaktionszeiten in einem Experiment oder die elektrische Aktivität des Gehirns. In der *Datenanalyse* bereitet man die erhobenen Daten auf, fasst sie zusammen und untersucht mithilfe statistischer Verfahren, welche Aussagen sie im Hinblick auf die Forschungsfrage erlauben. In der *Ergebnispräsentation* stellt man schließlich die Befunde dar, erläutert ihre Bedeutung und diskutiert ihre Grenzen. Die Ergebnisse gehen damit in den Forschungsstand ein und können den Ausgangspunkt für neue Forschungsfragen und weitere Datenerhebungen bilden.

Rohdaten und Primärdaten

In der Psychologie unterscheidet man nach Schönbrodt et al. (2017) und Gollwitzer et al. (2021) zunächst einmal *Rohdaten* und *Primärdaten*. Dabei bezeichnen Rohdaten die ursprünglichen Aufzeichnungen einer Datenerhebung, etwa die Kreuze auf einem Papierfragebogen, Zeichnungen oder Audioaufnahmen. Primärdaten sind die erste Übertragung dieser Aufzeichnungen in ein digitales Format, beispielsweise die Kodierung einer angekreuzten Ja-Antwort durch die Zahl 1. Sie liegen damit digital, ansonsten aber noch unbearbeitet vor und umfassen sowohl quantitative als auch qualitative Daten. Werden Daten bereits bei ihrer Erhebung digital gespeichert, wie bei einem Onlinefragebogen oder einem computergestützten Experiment, sind Rohdaten und Primärdaten äquivalent. Als Beispiele für Primärdaten nennen Schönbrodt et al. (2017) und Gollwitzer et al. (2021) etwa die Werte aller manipulierten und gemessenen Variablen für jeden Versuchsdurchgang jeder Person, die einzelnen Antworten jeder Person auf die Items eines Fragebogens und den unveränderten Wortlaut von Freitexteingaben. Weitere Beispiele sind digitalisierte Videoaufnahmen, gespeicherte Inhalte sozialer Medien sowie EEG- oder fMRT-Daten, die verlustfrei in ein standardisiertes Rohdatenformat übertragen und noch nicht über Messungen gemittelt oder auf ausgewählte Messkanäle beziehungsweise Hirnregionen reduziert wurden. Ein wichtiges Prinzip der öffentlich geförderten, transparenten Forschung ist die Bereitstellung von Primärdaten anhand der *FAIR-Prinzipien*. Forschungsdaten sollen demnach *auffindbar* (*Findable*), *zugänglich* (*Accessible*), *interoperabel* (*Interoperable*) und *nachnutzbar* (*Reusable*) sein. Dabei kann der Zugang aus Gründen des Datenschutzes oder der Forschungsethik an bestimmte Bedingungen gebunden sein. Auf die Bereitstellung von Primärdaten und die FAIR-Prinzipien wollen wir an späterer Stelle genauer eingehen.

Psychologische Daten als observierbare Variablen

Vor dem Hintergrund der in Kapitel 1 eingeführten Unterscheidung zwischen latenten und observierbaren Variablen (vgl. Kapitel 1.4) stellen Daten Beobachtungen observier-

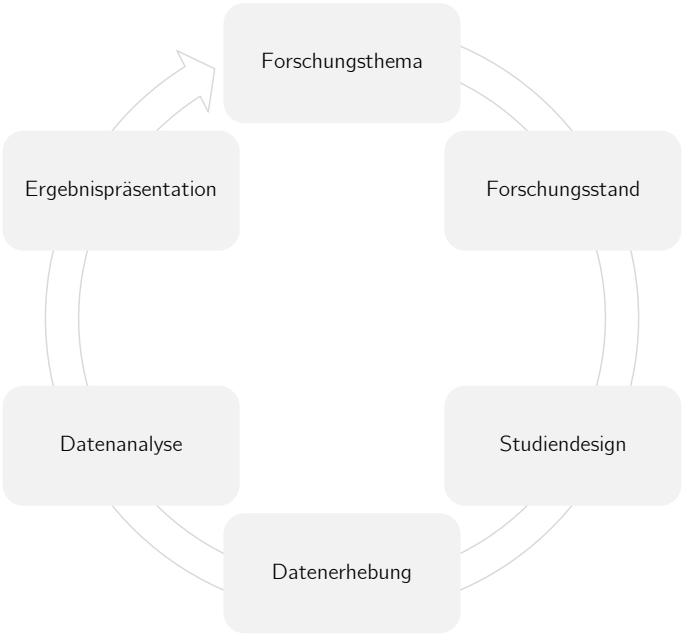

Abbildung 3.1 Arbeitsphasen des empirischen Forschungsprozesses.

barer Variablen dar (Abbildung 3.2). Es sei daran erinnert, dass diese Beobachtungen in der psychologischen Forschung im Zusammenhang mit Annahmen über latente Variablen interpretiert werden, etwa über psychologische Konstrukte oder kognitive Prozesse. Latente Variablen sind Bestandteile wissenschaftlicher Theorien und nicht direkt beobachtbar. Durch Überlegungen zu ihrer *Operationalisierung* legt man fest, anhand welcher observierbaren Merkmale sie indirekt erfasst werden sollen. Das Schließen von vorliegenden Daten auf die Werte latenter Variablen ist eine Form der *Inferenz*. Solche Schlussfolgerungen beruhen auf Annahmen darüber, wie latente und observierbare Variablen miteinander zusammenhängen, und sind mit Unsicherheit verbunden. Die moderne probabilistische Datenwissenschaft stellt eine Vielzahl von Verfahren bereit, um diese Zusammenhänge zu modellieren und die Unsicherheit entsprechender Schlussfolgerungen zu quantifizieren.

Psychologische Datentypen

Aber was sind nun *psychologische* Daten? Generell sind zunächst einmal alle beobachtbaren menschlichen Artefakte potenziell hinsichtlich psychologischer Prozesse aussagekräftig. So könnten Gebrauchsspuren auf Fußbodenbelägen ebenso wie die Verteilung zurückgelassener Gegenstände in einem Aufenthaltsraum Hinweise darauf geben, welche Orte Menschen bevorzugen und wie sie diese nutzen. Welche Rückschlüsse auf psychologische Prozesse solche Spuren erlauben, hängt allerdings von den Umständen ihrer Entstehung und den zugrunde gelegten Annahmen ab. Im engeren Sinne sind psychologische Daten diejenigen Daten, die in der psychologischen Forschung genutzt werden, um auf latente biopsychologische Prozesse zu schließen (Abbildung 3.3). Die Abbildung zeigt eine Auswahl häufig genutzter psychologischer Daten, ohne einen Anspruch auf Vollständigkeit zu erheben. Traditionelle psychologische Datentypen sind dabei etwa Fragebogenantworten, Interviewtranskripte, Verhaltensbeobachtungen sowie physiologische Messungen wie Herzrate, Hautleitwiderstand oder Elektroenzephalographie. Neueren Charakters sind insbesondere die vielfältigen digitalen Verhaltensspuren, die bei der Nutzung von Computern, Smartphones und Onlineplattformen entstehen, etwa Mausklicks und Mausbewegungen,

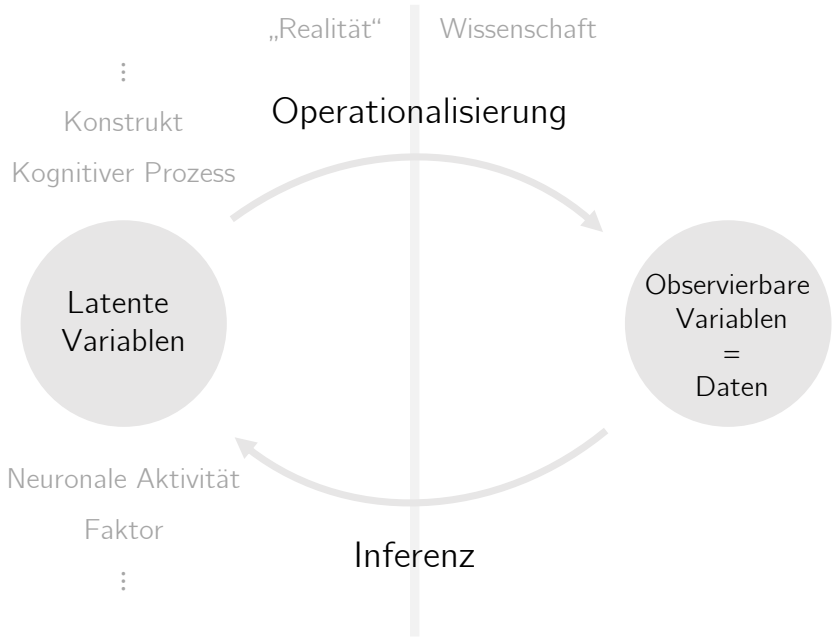

Abbildung 3.2 Psychologische Daten als observierbare Variablen.

Browserverläufe, Bewegungsprofile oder Aktivitäten in sozialen Medien. Die psychologische Bedeutung liegt dabei nicht in den Daten allein, sondern ergibt sich aus der Forschungsfrage und den theoretischen Annahmen, die ihre Interpretation leiten.

Konzeptueller Datenaufnahmeraum

Generell sollte man sich bei einem vorliegenden Datensatz immer klarmachen, dass dieser aufgrund des Studiendesigns und der Bedingungen der Datenaufnahme an einer bestimmten Stelle in einem mehrdimensionalen *Datenaufnahmeraum* verortet ist. Damit ermöglicht ein Datensatz bestimmte Aussagen, während andere durch ihn nur eingeschränkt oder gar nicht gestützt werden. Abbildung 3.4 veranschaulicht drei Dimensionen: Die Achse *reduktionistisch bis holistisch* beschreibt, wie stark einzelne Prozesse isoliert und artifiziell oder in ihrem umfassenderen lebensnahen Kontext untersucht werden. Die Achse *unkontrolliert bis kontrolliert* beschreibt den Grad der Kontrolle über die Untersuchungsbedingungen. Die Achse *wenige bis viele Variablen* beschreibt den Umfang der erfassten Merkmale. Diese Eigenschaften sind voneinander zu unterscheiden. Eine große Zahl gemessener Variablen bedeutet beispielsweise weder hohe Kontrolle noch eine holistische Untersuchung. Die eingezeichneten Beispiele sind schematisch zu verstehen, ihre genaue Position hängt vom konkreten Studiendesign ab.

Unstrukturierte Alltagsbeobachtungen sind eher holistisch und wenig kontrolliert. In der dargestellten Einordnung werden dabei nur wenige Merkmale systematisch erfasst, obwohl die beobachtete Situation selbst komplex ist. Solche Daten können psychologische Prozesse in ihrem Alltagskontext sichtbar machen, erlauben aber häufig keine eindeutige Zuordnung zu einzelnen Ursachen. *Digitale Verhaltensspuren aus sozialen Medien* liegen ebenfalls im eher holistischen und wenig kontrollierten Bereich, können jedoch viele Variablen umfassen, etwa Inhalte, Zeitpunkte, Interaktionen und Nutzungsverläufe. Ihr Umfang ersetzt keine Kontrolle über die Bedingungen ihrer Entstehung. Auch bilden sie jeweils nur den durch die Plattform erfassbaren Ausschnitt menschlichen Verhaltens ab.

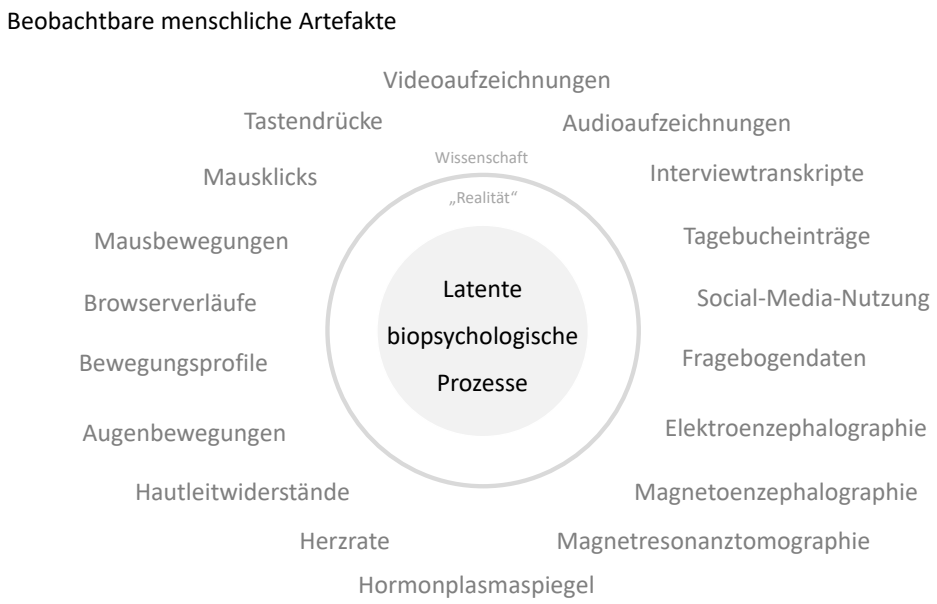

Abbildung 3.3 Psychologische Datentypen.

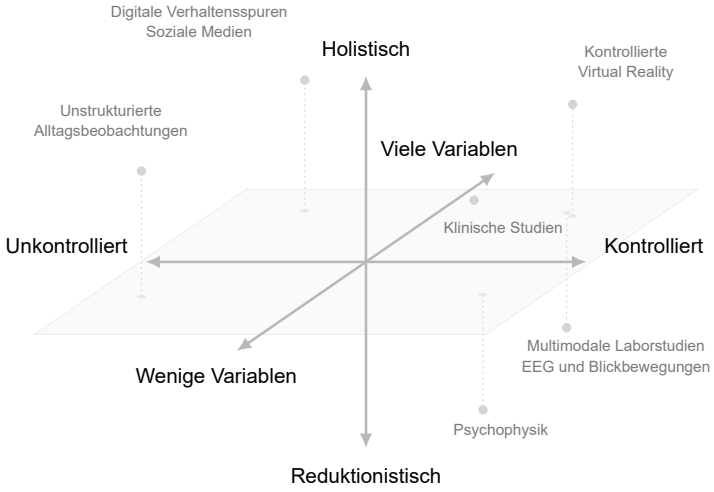

Abbildung 3.4 Konzeptueller Datenaufnahmeraum.

Kontrollierte Virtual-Reality-Studien verbinden in der dargestellten Einordnung einen vergleichsweise holistischen Untersuchungskontext mit hoher Kontrolle und vielen erfassten Variablen. Virtuelle Umgebungen können komplexe Situationen simulieren, während Reize gezielt variiert und Bewegungen, Entscheidungen oder physiologische Reaktionen aufgezeichnet werden. Ob sich die Befunde auf entsprechende Alltagssituationen übertragen lassen, bleibt dennoch zu prüfen. *Psychophysische Laborexperimente* sind demgegenüber typischerweise stark kontrolliert und reduktionistisch. Sie konzentrieren sich häufig auf wenige ausgewählte Variablen, beispielsweise einen Reizparameter und eine Wahrnehmungsent-

scheidung. Dies erleichtert die präzise Untersuchung einzelner Zusammenhänge, begrenzt aber zunächst die Aussagen über komplexere Situationen. *Multimodale Laborstudien mit EEG und Blickbewegungsmessungen* sind ebenfalls eher kontrolliert und reduktionistisch, erfassen jedoch viele Variablen. Die zusätzliche Information aus mehreren Messverfahren macht die Untersuchungssituation nicht automatisch holistischer. *Klinische Studien* sind hier bei vielen Variablen sowie ungefähr mittlerer Kontrolle und mittlerem Holismus eingeordnet. Sie können beispielsweise Symptome, Funktionsniveau, Begleiterkrankungen, Behandlungsmerkmale und zeitliche Verläufe erfassen. Standardisierte Untersuchungen und Behandlungsprotokolle schaffen Kontrolle, während individuelle Krankheitsverläufe und Lebensbedingungen nur teilweise kontrollierbar sind. Zugleich verbinden solche Studien die gezielte Untersuchung bestimmter Beschwerden oder Interventionen mit dem umfassenderen klinischen Kontext. Randomisierte Laborstudien und naturalistische Versorgungsstudien können entsprechend deutlich unterschiedliche Positionen einnehmen.

Ein methodisches Ideal besteht darin, eine möglichst holistische Untersuchung mit ausreichender Kontrolle und einer umfassenden Erfassung relevanter Variablen zu verbinden. Diesem Ziel setzen jedoch sowohl Messverfahren als auch Forschungsfragen Grenzen. Beispielsweise schränkt ein fMRT-Scanner die Bewegungsfreiheit und die möglichen Interaktionen der untersuchten Person stark ein. Eine klar eingegrenzte Forschungsfrage kann zudem gerade eine gezielte Reduktion und Kontrolle der Untersuchungssituation erfordern. Entscheidend ist daher, die Datenaufnahme so zu gestalten, dass sie die für die jeweilige Forschungsfrage erforderlichen Schlussfolgerungen erlaubt.

Im Folgenden wollen wir uns nun mit einigen typischen psychologischen Datentypen etwas genauer befassen. Dabei erheben wir keinen Anspruch auf Vollständigkeit. Ein umfassenderes Verständnis der jeweiligen Datentypen und ihrer Besonderheiten lässt sich am ehesten in den entsprechenden Fachdisziplinen erwerben. Hier wollen wir vielmehr verdeutlichen, dass quantitative Daten trotz großer Unterschiede in ihrer Erhebung und inhaltlichen Bedeutung in ihrer digitalen Form grundlegende Gemeinsamkeiten aufweisen. Sie lassen sich als Werte von Variablen für bestimmte Beobachtungseinheiten darstellen, in tabellarischer Form organisieren und mit verwandten datenanalytischen Methoden untersuchen.

3.1 Verhaltensdaten

Verhaltensdaten erfassen menschliche Äußerungen und Handlungen. Wir unterscheiden hier *Befragungsdaten*, die durch gezielte Fragen oder Aufgaben entstehen, und *Beobachtungsdaten*, die aus der Registrierung von Verhalten hervorgehen (Tabelle 3.1). Tests und Fragebögen spielen besonders in der Differentiellen Psychologie, Persönlichkeitspsychologie und psychologischen Diagnostik sowie in der Klinischen, Pädagogischen und Sozialpsychologie eine zentrale Rolle. Ecological Momentary Assessment (EMA) Daten sind unter anderem in der Klinischen Psychologie und Gesundheitspsychologie verbreitet. Experimentelle Verhaltensdaten prägen die Allgemeine Psychologie, strukturierte Fremdbeobachtungen beispielsweise die Entwicklungspsychologie und digitale Verhaltensspuren die Medienpsychologie.

Befragungsdaten: Psychologische Tests und Fragebögen

Als erstes Beispiel für Befragungsdaten betrachten wir *psychologische Tests und Fragebögen*. Die dabei erhobenen Antworten gehören wohl zu den am weitesten verbreiteten psychologischen Daten. Ihrer Messung und Analyse widmet sich mit der *Psychometrie* ein

Tabelle 3.1 Auswahl von Befragungs- und Beobachtungsdaten.

Bereich	Daten
Befragungsdaten	Mündliche Interviews
	Schriftliche Interviews
	Tests und Fragebögen
	Strukturierte Tagebuchberichte
	Ecological Momentary Assessment (EMA) Daten
Beobachtungsdaten	Analoge strukturierte Fremdbeobachtung
	Verhaltensparadigmendaten
	Psychophysikdaten
	Verhaltensökonomiedaten
	Social-Media-Daten
	Computerspieldaten

eigener Bereich der Psychologie. Ein Test besteht aus einzelnen *Items*, also Fragen, Aussagen oder Aufgaben mit einem festgelegten Antwortformat. Während Leistungstests häufig richtige und falsche Antworten unterscheiden, erfassen Fragebögen beispielsweise Einschätzungen der eigenen Persönlichkeit oder des aktuellen Befindens. Testtheoretisch werden beide Formen gemeinsam betrachtet, weil beobachtbare Antworten genutzt werden, um auf latente Merkmale zu schließen (vgl. Bühner (2010), Rost (2004)).

Dafür wurden verschiedene Modellklassen entwickelt. Die *klassische Testtheorie* (KTT) unterscheidet wahre Werte und Messfehler und bildet eine Grundlage zur Beurteilung der Messgenauigkeit. Die *Faktoranalyse* (FA) erklärt Zusammenhänge zwischen Itemantworten durch gemeinsame latente Faktoren. *Item-Response-Theorien* (IRT) beschreiben die Wahrscheinlichkeit bestimmter Antworten in Abhängigkeit von Personenmerkmalen und Itemeigenschaften. Trotz unterschiedlicher Modelle bildet jeweils die systematische Verknüpfung beobachteter Antworten mit nicht direkt beobachtbaren Merkmalen den Ausgangspunkt.

Tabellarisch dargestellt könnte ein mit dem BDI-II-Fragebogen erhobener Datensatz etwa die Form der Daten in Tabelle 3.2 haben. Der simulierte Beispieldatensatz umfasst $n = 12$ Personen und $m = 21$ Items. Die Antworten sind mit 0, 1, 2 oder 3 kodiert. Jede Zeile entspricht einer Person, jede Spalte einem Item und jeder Tabelleneintrag einer Antwort. Die Itemantworten bilden die Primärdaten, aus denen beispielsweise Summenwerte berechnet oder testtheoretische Modelle geschätzt werden können.

Befragungsdaten: Ecological Momentary Assessment

Eine weitere Form von Befragungsdaten entsteht beim *Ecological Momentary Assessment* (EMA), das eng mit der *Experience Sampling Method* (ESM) verwandt ist. Während Tests und Fragebögen häufig rückblickend nach dem Erleben in einem längeren Zeitraum fragen, etwa während der letzten zwei Wochen, erfasst EMA momentanes Erleben und Verhalten wiederholt in der natürlichen Alltagsumgebung. Dazu beantworten Personen kurze Fragen auf digitalen Endgeräten, beispielsweise mithilfe einer Smartphone-App. Die Abfragen können an bestimmte Ereignisse gekoppelt sein, in festgelegten Zeitintervallen erfolgen oder zu zufällig ausgewählten Zeitpunkten ausgelöst werden. Die zeitliche Nähe zum berichteten Erleben kann Erinnerungsverzerrungen verringern und ermöglicht es, Veränderungen innerhalb einer Person im Alltag zu untersuchen.

Tabelle 3.2 Itemantworten von zwölf Personen auf 21 Items. Die Spaltennummern bezeichnen die Items, i die Person.

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21
1	2	0	2	2	0	1	3	2	1	3	0	1	1	2	3	2	0	1	2	1	2
2	0	2	1	2	1	1	3	2	1	1	1	1	0	2	3	3	1	2	1	2	2
3	1	2	0	2	3	2	2	1	0	2	2	0	2	3	1	2	1	2	3	3	2
4	2	3	2	1	0	3	1	2	2	1	1	1	1	0	3	2	2	2	1	0	2
5	1	2	2	1	2	1	1	0	3	2	3	1	2	2	2	1	0	2	2	1	3
6	0	3	2	2	1	2	1	2	2	0	1	3	2	2	0	1	2	1	2	0	2
7	3	3	1	1	3	2	0	2	2	3	3	1	3	3	0	2	1	2	3	3	0
8	1	1	1	1	1	1	2	2	1	1	1	1	1	2	3	2	3	1	0	1	1
9	2	0	1	2	2	3	2	3	3	1	2	2	2	1	2	0	1	0	1	3	2
10	1	3	0	1	3	2	1	0	2	3	1	1	2	0	2	2	2	1	1	1	2
11	2	1	1	0	1	1	1	1	2	1	1	1	2	0	3	2	1	2	3	0	2
12	2	2	0	1	2	2	3	2	2	2	2	1	0	3	1	1	2	2	1	0	0

Tabellarisch dargestellt könnte ein mithilfe von EMA erhobener Datensatz etwa die Form der Daten in Tabelle 3.3 haben. Der simulierte Beispieldatensatz enthält Angaben von $n = 10$ Personen zu $m = 7$ Abfragezeitpunkten. Die momentane Stimmung wird auf einer visuellen Skala von traurig (0) bis glücklich (1) erfasst und als Wert im Intervall $[0, 1]$ kodiert. Jede Zeile entspricht einer Person, jede Spalte einem Abfragezeitpunkt und jeder Eintrag der jeweiligen Stimmungseinschätzung.

Beobachtungsdaten: Psychophysik und Verhaltensökonomie

Als Beispiel für *Beobachtungsdaten* betrachten wir computerbasierte Verhaltensaufgaben, wie sie in der Psychophysik und Verhaltensökonomie eingesetzt werden. In der Psychophysik wird etwa untersucht, wie Personen auf Unterschiede zwischen sensorischen Reizen reagieren. In der Verhaltensökonomie interessieren beispielsweise Entscheidungen zwischen Handlungsoptionen mit unterschiedlichen Belohnungen, Kosten oder Risiken. Aufgezeichnet werden konkrete Handlungen wie Tastendrücke, Mausklicks oder Bewegungen sowie häufig deren Zeitpunkte und Reaktionszeiten. Abbildung 3.5 veranschaulicht unterschiedliche Aufnahmesituationen: am eigenen Computer, unter kontrollierten Laborbedingungen und in einer virtuellen Umgebung.

Ein konkretes Beispiel haben wir bereits in Kapitel 2 im Bereich der *Computational Psychiatry* kennengelernt. In der Studie von Usée et al. (2026) untersuchten Versuchspersonen durch Mausklicks eine Umgebung mit möglichen Belohnungen und Bestrafungen und konnten die Suche jederzeit beenden. Die registrierten Suchhandlungen und Stoppentscheidungen bilden Beobachtungsdaten, aus denen beispielsweise die Anzahl unterschiedlicher untersuchter Kreise bestimmt wird. Agentenmodelle beschreiben, wie Annahmen über die Bewertung von Belohnungen und Bestrafungen solche Entscheidungen hervorbringen. Die latenten Bewertungsprozesse werden somit anhand beobachtbaren Verhaltens untersucht.

Tabellarisch dargestellt könnte ein Datensatz aus einer Aufgabe mit zwei Handlungsalternativen etwa die Form der Daten in Tabelle 3.4 haben. Der simulierte Beispieldatensatz enthält $m = 5$ binäre Entscheidungen von $n = 8$ Personen, kodiert als Elemente von $\{0, 1\}$. Jede Zeile entspricht einer Person, jede Spalte einer Entscheidungssituation. Die Tabelle illustriert eine einfache Datenstruktur und enthält keine Originaldaten der genannten Studie. Für deren Analyse werden zusätzlich die Versuchsbedingungen und die Abfolge der Suchereignisse berücksichtigt.

Tabelle 3.3 Simulierte EMA-Stimmungseinschätzungen von zehn Personen zu sieben Abfragezeitpunkten auf einer Skala von traurig (0) bis glücklich (1).

Person	T1	T2	T3	T4	T5	T6	T7
1	0.85	0.43	0.10	0.45	0.78	0.43	0.31
2	0.27	0.33	0.69	0.47	0.89	0.57	0.01
3	0.63	0.54	0.07	0.09	0.17	0.42	0.74
4	0.80	0.50	0.76	0.42	0.34	0.02	0.98
5	0.49	0.58	0.66	0.34	0.39	0.20	0.69
6	0.04	0.22	0.62	0.97	0.66	0.06	0.35
7	0.92	0.97	0.49	0.08	0.10	0.66	0.43
8	0.07	0.57	0.11	0.98	0.43	0.40	0.43
9	0.55	0.98	0.47	0.30	0.84	0.81	0.51
10	0.92	0.37	0.82	0.87	0.12	0.44	0.15

Abbildung 3.5 Aufnahme von Verhaltensdaten am eigenen Computer (links), bei einer kontrollierten psychophysischen Aufgabe im Labor (Mitte) und in einer virtuellen Umgebung (rechts).

Tabelle 3.4 Simulierte binäre Entscheidungen von acht Personen in fünf Entscheidungssituationen.

Person	Entscheidung 1	Entscheidung 2	Entscheidung 3	Entscheidung 4	Entscheidung 5
1	1	0	0	0	0
2	0	1	0	0	1
3	1	0	1	0	0
4	1	1	0	0	0
5	0	0	0	0	0
6	1	0	0	0	0
7	0	1	1	0	0
8	1	1	0	0	0

3.2 Physiologische Daten

Physiologische Daten erfassen körperliche Zustände und Prozesse, die mit psychischem Erleben und Verhalten zusammenhängen. Tabelle 3.5 unterscheidet körperbezogene Daten außerhalb der unmittelbaren Erfassung des Gehirns von neurophysiologischen Daten. Hautleitwiderstand, Hormonspiegel und Immunmarker sind beispielsweise für die Untersuchung von Stress und Emotionen bedeutsam. EEG, MEG und fMRT dienen der Untersuchung neuronaler Prozesse beziehungsweise ihrer physiologischen Begleiterscheinungen. Solche Daten bilden einen Schwerpunkt der Biologischen Psychologie und Neuropsycholo-

Abbildung 3.6 A. Messung des Hautleitwiderstands mit Fingerelektroden, **B.** Elektroenzephalographie (EEG), **C.** funktionelle Magnetresonanztomographie (fMRT).

Tabelle 3.5 Auswahl physiologischer Daten.

Bereich	Daten
Vegetativphysiologie	Medizinische Befunde
	Hormonspiegel
	Immunmarker
	Hautleitwiderstand
Neurophysiologie	Elektroenzephalographiedaten (EEG)
	Magnetoenzephalographiedaten (MEG)
	Funktionelle Magnetresonanztomographiedaten (fMRT)
	Transkranielle Magnetstimulationsdaten (TMS)
	Transkranielle Gleichstromstimulationsdaten (tDCS)

gie und werden außerdem häufig in der Allgemeinen Psychologie, Klinischen Psychologie, Gesundheitspsychologie und Sportpsychologie genutzt.

Vegetativphysiologische Daten: Hautleitwiderstand

Als Beispiel für einen vegetativphysiologischen Datentyp betrachten wir die Messung des *Hautleitwiderstands* (Abbildung 3.6, A). Populärwissenschaftlich sind solche Verfahren unter anderem als Bestandteil sogenannter „Lügendetektoren“ bekannt. Tatsächlich messen sie jedoch keine Lügen, sondern Veränderungen der elektrischen Eigenschaften der Haut, die insbesondere von der Aktivität der sympathisch innervierten Schweißdrüsen abhängen. Dazu werden beispielsweise zwei Elektroden an den Fingern angebracht. Mit zunehmender Schweißdrüsenaktivität steigt typischerweise die *Hautleitfähigkeit* (*skin conductance*), während der *Hautleitwiderstand* sinkt. Die Leitfähigkeit ist der Kehrwert des Widerstands und wird meist in Mikrosiemens (μS) angegeben, der Widerstand in Ohm (Ω). Solche Messungen der *elektrodermalen Aktivität* werden unter anderem zur Untersuchung von Stress, emotionaler Erregung und kognitiver Beanspruchung eingesetzt. Sie liefern Hinweise auf sympathische Aktivierung, erlauben für sich genommen aber keine eindeutige Zuordnung zu einer bestimmten Emotion oder zur Wahrheit einer Aussage (vgl. Posada-Quintero & Chon (2020)). Neuere Übersichten behandeln die Entwicklung tragbarer Sensoren (Hosseinzadeh et al. (2025)) sowie Störeinflüsse durch Bewegung, Elektrodenkontakt und Umgebungsbedingungen (Bari et al. (2026)). Typischerweise lassen sich Daten, die auf elektrischen Signalen beruhen, mit hoher zeitlicher Auflösung aufzeichnen. Dabei bestimmt die *Abtastrate*, also die Zahl der Messwerte pro Sekunde, den zeitlichen Abstand zwischen aufeinanderfolgenden Werten. Bei einer beispielhaften Abtastrate von 500 Hz beträgt dieser

Tabelle 3.6 Simulierte Hautleitwiderstandsdaten von acht Personen zu sieben Messzeitpunkten im Abstand von 2 ms. Die Werte in Ω dienen ausschließlich der Veranschaulichung der Tabellenstruktur.

Person	0 ms	2 ms	4 ms	6 ms	8 ms	10 ms	12 ms
1	1.30	4.04	2.01	3.29	1.07	4.45	1.93
2	7.58	1.70	8.24	7.58	5.98	9.01	5.56
3	5.04	7.30	3.48	1.98	7.49	1.31	5.65
4	4.23	2.33	8.97	6.02	3.16	7.86	9.69
5	4.57	6.30	4.57	2.46	4.29	8.03	5.57
6	8.40	5.40	9.36	6.18	1.81	4.11	2.08
7	2.26	8.07	6.00	3.21	2.78	9.19	7.00
8	6.29	7.67	5.89	9.04	9.00	8.83	9.13

Abstand $1/500\,\mathrm{s} = 2\,\mathrm{ms}$. Die physiologischen Hautleitreaktionen selbst verlaufen allerdings deutlich langsamer, sodass eine solche Abtastrate für ihre Erfassung meist nicht erforderlich ist. Eine feinere Abtastung bedeutet somit nicht automatisch eine entsprechend feinere zeitliche Auflösung des zugrunde liegenden psychologischen Prozesses.

Tabellarisch dargestellt könnte ein solcher Datensatz etwa die Form der Daten in Tabelle 3.6 haben, wobei jede Zeile einer Person, jede Spalte einem Messzeitpunkt und jeder Eintrag einem Hautleitwiderstandswert entspricht.

Neurophysiologische Daten: Elektroenzephalographie

Als Beispiel für einen neurophysiologischen Datentyp betrachten wir die *Elektroenzephalographie* (EEG), mit der elektrische Potentialunterschiede an der Kopfoberfläche aufgezeichnet werden (Abbildung 3.6, B). Dazu werden Elektroden nach standardisierten Schemata, etwa dem 10–20-System, auf der Kopfhaut angeordnet. Abbildung 3.7 veranschaulicht den Aufbau der Messung. Jeder Messkanal erfasst die Spannung zwischen einer Ableitelektrode und einer Referenz, nicht ein absolutes Potential. Eine zusätzliche Masseelektrode dient der technischen Stabilisierung der Messung. Die kleinen Spannungen werden verstärkt, gefiltert und digitalisiert, beispielsweise mit 500 Messwerten pro Sekunde und Kanal. Gleichzeitig übermittelte Ereigniscodes markieren den Zeitpunkt einer Reizdarbietung oder einer Reaktion in der kontinuierlichen Aufzeichnung (vgl. Luck (2014)).

Biologisch beruht das an der Kopfhaut gemessene EEG wesentlich auf der Überlagerung *postsynaptischer Ströme* vieler Nervenzellen, insbesondere ähnlich ausgerichteter Pyramidenzellen der Großhirnrinde. Synaptische Eingänge verändern die Durchlässigkeit der Zellmembran für Ionen. Die dadurch entstehenden Ströme und ihre Rückströme erzeugen räumlich getrennte Stromsenken und Stromquellen. Werden viele benachbarte Zellen hinreichend synchron aktiviert, können sich ihre Beiträge zu einem messbaren Feld summieren. Vereinfachend lässt sich eine solche Zellpopulation als *äquivalenter Stromdipol* modellieren (Abbildung 3.8). Durch *Volumenleitung* tragen diese Ströme auch zu Potentialunterschieden an der Kopfoberfläche bei, wobei Gehirn, Hirnflüssigkeit, Schädel und Kopfhaut die gemessene räumliche Verteilung beeinflussen. Das EEG bildet somit nicht einfach die Aktionspotentiale einzelner Neurone ab. Umgekehrt lässt sich aus einer Spannung an einer Elektrode auch nicht eindeutig auf eine einzelne darunterliegende Hirnregion schließen. Die Schätzung neuronaler Quellen erfordert zusätzliche Annahmen über ihre Lage und Ausrichtung sowie die Leitfähigkeit des Kopfes (vgl. Buzsáki et al. (2012)).

Um Reaktionen auf bestimmte Ereignisse zu untersuchen, verwendet man häufig die *ereignisbezogene Mittelung* (*event-related averaging*). Nach Kontrolle beziehungsweise Korrektur von Artefakten, etwa durch Augenbewegungen oder Muskelaktivität, wird das kon-

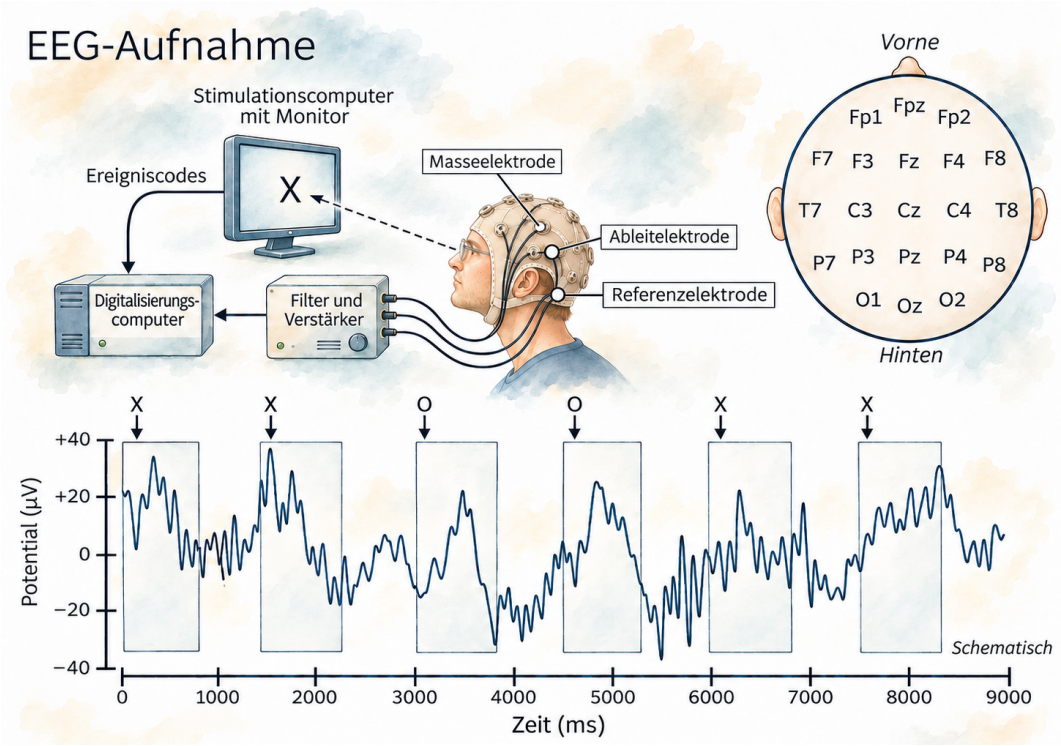

Abbildung 3.7 Prinzip der EEG-Aufnahme mit Ableit- und Referenzelektrode, Verstärkung und Digitalisierung sowie Ereigniscodes zur zeitlichen Zuordnung der aufgezeichneten Signale (nach Luck, 2014).

Tabelle 3.7 Simulierte EEG-Daten einer Person an acht Elektroden zu sieben Messzeitpunkten im Abstand von 2 ms. Die Werte in μV veranschaulichen die Tabellenstruktur.

Elektrode	0 ms	2 ms	4 ms	6 ms	8 ms	10 ms	12 ms
1	8.28	4.16	8.39	3.69	2.00	6.10	2.36
2	-1.64	-1.23	2.35	1.86	5.08	9.02	4.77
3	0.28	7.46	-0.81	-0.35	-0.23	3.11	7.51
4	8.76	3.93	9.55	1.29	4.24	1.72	6.36
5	8.64	1.66	7.42	0.17	2.60	6.90	4.23
6	9.50	9.60	2.52	6.81	4.76	8.45	8.71
7	5.56	3.32	3.35	-0.39	4.21	0.32	5.80
8	6.23	-0.92	5.58	8.94	8.78	4.65	1.80

tinuierliche EEG anhand der Ereigniscodes in kurze Zeitabschnitte, sogenannte *Epochen*, unterteilt, wie sie in Abbildung 3.7 durch die markierten Zeitfenster angedeutet sind. Diese werden am Ereignisbeginn ausgerichtet und üblicherweise relativ zu einem Ausgangsniveau vor dem Ereignis betrachtet. Anschließend mittelt man für jede Elektrode und jeden relativen Zeitpunkt über viele Wiederholungen derselben Versuchsbedingung. Dahinter steht ein vereinfachtes Modell, nach dem sich jede Einzelmessung aus einer wiederkehrenden ereignisbezogenen Antwort und wechselnden Hintergrundanteilen zusammensetzt. Soweit diese Hintergrundanteile nicht systematisch mit dem Ereignis zusammenhängen, werden sie durch die Mittelung abgeschwächt. Die zeitlich konsistente Antwort tritt als *ereigniskorreliertes Potential* (EKP, englisch *event-related potential*, ERP) hervor. Systematische Artefakte verschwinden dadurch jedoch nicht, und zeitliche Schwankungen einer Antwort können deren gemittelte Form abschwächen oder verbreitern (vgl. Luck (2014)).

Tabellarisch dargestellt könnte ein kurzer Ausschnitt einer EEG-Aufzeichnung die Form

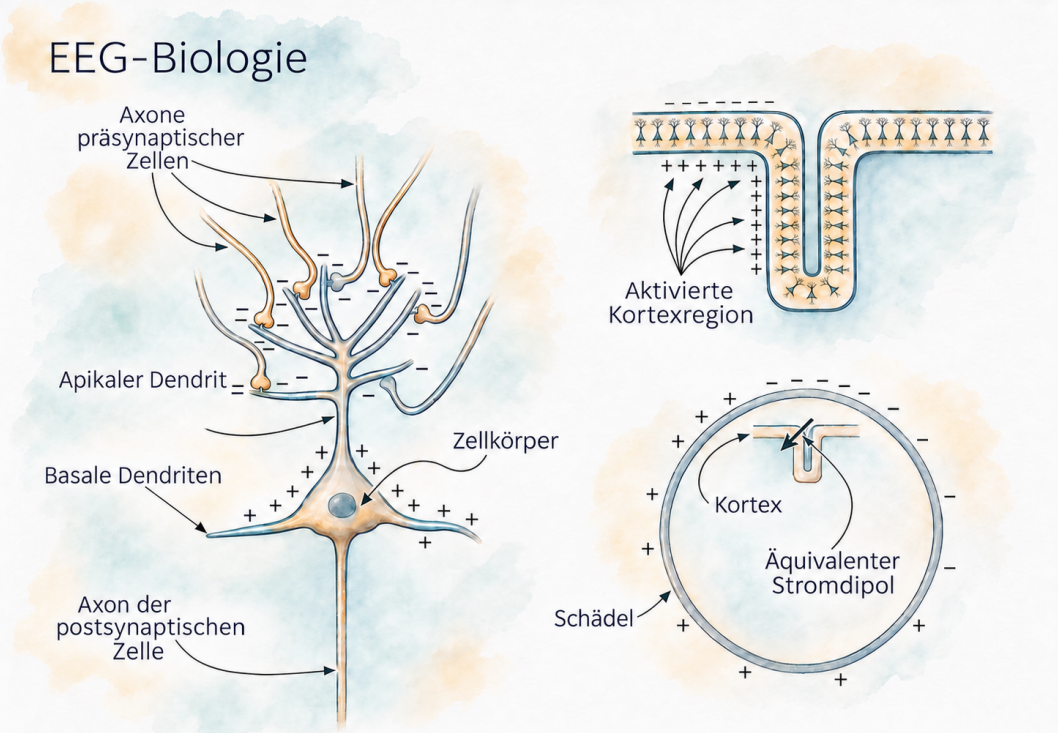

Abbildung 3.8 Biologische Grundlagen des EEG: postsynaptische Ströme, die gemeinsame Aktivität ausgerichteter Pyramidenzellen und ihre Beschreibung durch einen äquivalenten Stromdipol (nach Luck, 2014).

der Daten in Tabelle 3.7 haben. Hier entspricht jede Zeile einer Elektrode einer Person, jede Spalte einem Messzeitpunkt und jeder Eintrag einer Spannung gegenüber der Referenz in Mikrovolt (μV). Die simulierten Werte illustrieren eine Aufzeichnung vor der Mittelung über wiederholte Ereignisse.

Neurophysiologische Daten: Funktionelle Magnetresonanztomographie

Ein weiterer neurophysiologischer Datentyp entsteht bei der *funktionellen Magnetresonanztomographie* (fMRT), mit der räumlich aufgelöste Veränderungen des Magnetresonanzsignals im Gehirn erfasst werden (Abbildung 3.6, C). Im starken statischen Magnetfeld des Scanners entsteht eine bevorzugte Ausrichtung der magnetischen Momente von Wasserstoffkernen und damit eine messbare Nettomagnetisierung. Hochfrequenzimpulse lenken diese aus. Das anschließend von Empfangsspulen registrierte Signal hängt unter anderem davon ab, wie die Magnetisierung in ihren Ausgangszustand zurückkehrt und die gemeinsame Phasenlage der Kernbewegungen verloren geht. Zusätzliche Magnetfeldgradienten ermöglichen die räumliche Zuordnung des Signals. Daraus werden Bilder rekonstruiert, deren dreidimensionale Bildelemente als *Voxel* bezeichnet werden. Während eines Messdurchgangs werden wiederholt Volumenbilder aufgenommen, sodass für jedes Voxel eine Zeitreihe entsteht (Abbildung 3.9). Mehrere Messdurchgänge können innerhalb einer Sitzung und mehrere Sitzungen bei einer Person erhoben werden (vgl. Huettel et al. (2014)).

Die in der psychologischen Forschung verbreitete BOLD-fMRT nutzt den *Blood-Oxygenation-Level-Dependent-Kontrast*, also die Abhängigkeit des Magnetresonanzsignals vom Oxygenierungszustand des Blutes. Sauerstoffarmes Hämoglobin (*Desoxyhämoglobin*) ist paramagnetisch und verursacht lokale Unregelmäßigkeiten des Magnetfelds, die den Signalzerfall bei T_2^*-gewichteten Aufnahmen beschleunigen. Bei erhöhter neuronaler

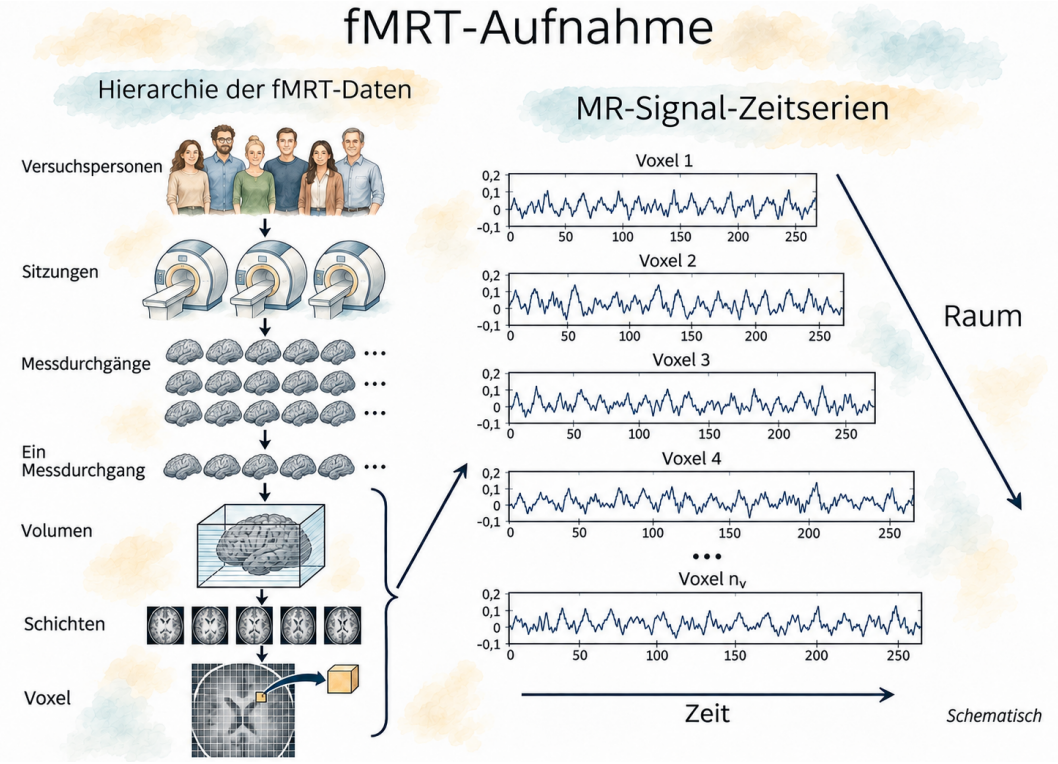

Abbildung 3.9 Hierarchie der fMRT-Daten von Personen und Sitzungen über Messdurchgänge und Volumenbilder bis zu einzelnen Voxeln. Für jedes Voxel ergibt sich eine Zeitreihe des Magnetresonanzsignals (nach Huettel et al., 2014).

Tabelle 3.8 Simulierte fMRT-Signalintensitäten einer Person in acht Voxeln zu sieben Aufnahmezeitpunkten im Abstand von 1,5 s. Die Werte veranschaulichen die Tabellenstruktur.

Voxel	0 s	1.5 s	3 s	4.5 s	6 s	7.5 s	9 s
1	196	83	225	201	86	77	112
2	53	73	25	106	2	139	87
3	195	61	91	162	25	190	17
4	93	61	218	19	61	252	131
5	109	185	96	107	139	189	127
6	201	200	124	181	221	190	169
7	115	48	36	226	95	176	132
8	110	164	48	64	125	175	19

Aktivität ändern sich über die *neurovaskuläre Kopplung* unter Beteiligung von Neuronen, Gliazellen und Gefäßzellen die lokale Durchblutung, das Blutvolumen und der Sauerstoffumsatz. Typischerweise steigt die Durchblutung stärker als der Sauerstoffverbrauch, sodass der Desoxyhämoglobingehalt im betrachteten Gewebe abnimmt und das BOLD-Signal zunimmt. Abbildung 3.10 veranschaulicht diese Wirkungskette. Das Signal bildet neuronale Aktivität somit indirekt über eine hämodynamische Antwort ab. Seine Stärke hängt sowohl von neuronalen Prozessen als auch vom Gefäßsystem und dessen Ausgangszustand ab, weshalb ein größerer BOLD-Wert nicht einfach mit einer entsprechend höheren Zahl neuronaler Aktionspotentiale gleichgesetzt werden kann (vgl. Logothetis (2008)).

Für die Untersuchung psychologischer Prozesse werden die Zeitpunkte von Reizen, Aufgaben oder Reaktionen mit den Volumenaufnahmen synchronisiert. Die erwartete Signaländ-

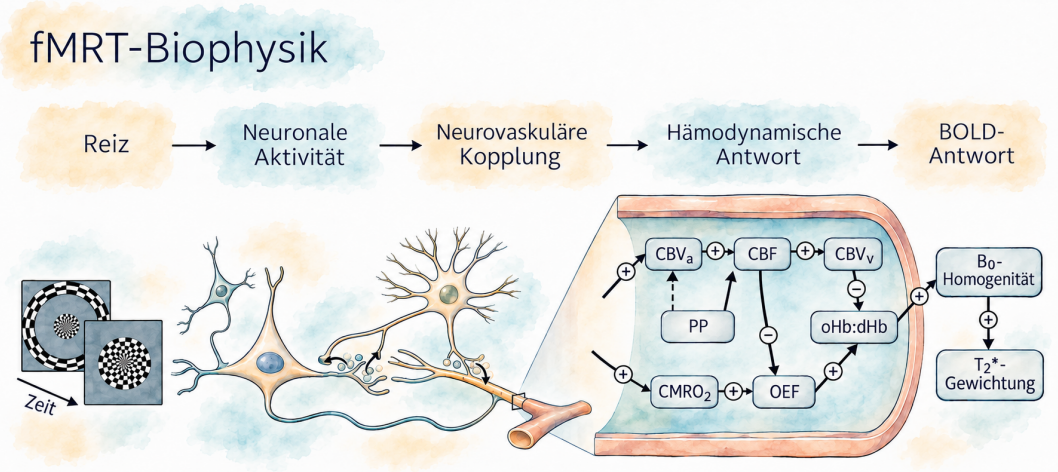

Abbildung 3.10 Biophysikalische Grundlagen des BOLD-Signals: neuronale Aktivität, neurovaskuläre Kopplung und hämodynamische Antwort beeinflussen den Oxygenierungszustand des Blutes und damit das gemessene Magnetresonanzsignal (nach Tsvetanov et al., 2020).

derung wird unter Berücksichtigung der verzögerten und über mehrere Sekunden ausgedehnten *hämodynamischen Antwort* modelliert und mit den beobachteten Voxelzeitreihen verglichen. Dabei müssen unter anderem Kopfbewegungen und physiologische Störeinflüsse berücksichtigt werden. Ein Aufnahmeabstand von beispielsweise 1,5 s bedeutet, dass für jedes Voxel alle 1,5 Sekunden ein neuer Messwert vorliegt. Er entspricht jedoch nicht einer ebenso feinen zeitlichen Auflösung der zugrunde liegenden neuronalen Aktivität, da die Gefäßantwort schnell aufeinanderfolgende Prozesse zeitlich überlagert (vgl. Huettel et al. (2014)).

Tabellarisch dargestellt könnte ein Ausschnitt eines fMRT-Datensatzes die Form der Daten in Tabelle 3.8 haben. Jede Zeile entspricht hier einem Voxel einer Person, jede Spalte einem Aufnahmezeitpunkt und jeder Eintrag einer Signalintensität. Die simulierten Ganzzahlen von 0 bis 255 dienen ausschließlich der Veranschaulichung. Tatsächliche fMRT-Signalintensitäten werden in geräte- und verarbeitungsabhängigen Einheiten gespeichert und sind nicht auf diesen Wertebereich beschränkt.

Datenmatrix

Die betrachteten Beispiele verdeutlichen, dass sich alle hier vorgestellten quantitativen Datentypen trotz ihrer unterschiedlichen Erhebungsverfahren in einer gemeinsamen tabellarischen *Matrixform* darstellen lassen. Abstrakt hat eine solche Datenmatrix mit n_r Zeilen und n_c Spalten die Form

$$M = \begin{pmatrix} m_{11} & m_{12} & \cdots & m_{1n_c} \\ m_{21} & m_{22} & \cdots & m_{2n_c} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n_r1} & m_{n_r2} & \cdots & m_{n_rn_c} \end{pmatrix}. \tag{3.1}$$

Dabei bezeichnet m_{ij} den Eintrag in Zeile i und Spalte j, mit $i = 1, \ldots, n_r$ und $j = 1, \ldots, n_c$. Für die fachliche Einordnung entscheidend sind die Bedeutung der Zeilen und Spalten sowie die Einheiten beziehungsweise Kodierungen der Messwerte m_{ij}. So können die Zeilen Personen, Elektroden oder Voxel repräsentieren und die Spalten beispielsweise Items, Entscheidungssituationen oder Messzeitpunkte. Die Einträge können kodierte Antworten, Hautleitwiderstände in Ohm, Spannungen in Mikrovolt oder fMRT-Signalintensitäten in

geräteabhängigen Einheiten enthalten. Erst diese inhaltlichen Zuordnungen machen aus einer Zahlentabelle einen interpretierbaren psychologischen Datensatz. Die gemeinsame Struktur ermöglicht zugleich, Daten aus unterschiedlichen Erhebungsverfahren aufeinander zu beziehen, zu integrieren und mit verwandten datenanalytischen Methoden zu untersuchen.

3.3 Datenbereitstellung

Die nachvollziehbare Aufbereitung und Bereitstellung von Forschungsdaten zur Nachnutzung gehört heute zum regulären Anspruch an öffentlich geförderte universitäre Forschung (vgl. Gollwitzer et al. (2021)). Die FAIR-Prinzipien geben dafür die übergeordneten Leitlinien vor. In Deutschland bietet das Leibniz-Institut für Psychologie (ZPID) mit PsychArchives und seinem Forschungsdatenzentrum die Infrastruktur, um psychologische Forschungsdaten zu dokumentieren, zu archivieren und zugänglich zu machen. Abgestufte Zugangsbedingungen ermöglichen dabei, den Schutz der Teilnehmenden, datenschutzrechtliche Anforderungen und die wissenschaftliche Nachnutzung miteinander zu verbinden. Die Datenbereitstellung lässt sich damit als regulärer Teil eines Forschungsprojekts planen und über bestehende fachspezifische Angebote umsetzen.

Das FAIR-Datenideal

Das FAIR-Datenideal ist ein Prinzip zum Management von Forschungsdaten, das der weiten Verbreitung, Nützlichkeit und Transparenz von Forschungsdaten im Digitalzeitalter Rechnung trägt. Unter *Forschungsdaten* werden dabei im Allgemeinen "elektronisch repräsentierte analoge oder digitale Daten, die im Zuge wissenschaftlicher Vorhaben entstehen oder genutzt werden, z. B. durch Beobachtungen, Experimente, Simulationsrechnungen, Erhebungen, Befragungen, Quellenforschungen, Aufzeichnungen von Audio- und Videosequenzen, Digitalisierung von Objekten, Auswertungen" (Rat für Informationsinfrastrukturen (2017)) verstanden. Konkret handelt es sich dabei etwa um Zahlenarrays oder Characterarrays, aber auch um Computersoftware wie **R**-Skripte, digitale Werkzeuge, Workflows und Analysepipelines.

Neben diesen manchmal auch als *Primärdaten* bezeichneten Datenformen sind für das FAIR-Datenideal sogenannte *Metadaten* von Bedeutung. Dabei handelt es sich um Daten, die Informationen über andere Daten repräsentieren. Man unterscheidet dabei beispielsweise *deskriptive*, *strukturelle* und *administrative Metadaten* (Riley (2017), Ulrich et al. (2022)).

- *Deskriptive Metadaten* dienen dem Auffinden und der Identifikation einer Datenquelle. Beispiele für deskriptive Metadaten sind etwa Titel einer wissenschaftlichen Publikation oder ihr Digital Object Identifier (DOI, Rosenblatt (1997)). DOIs sind alphanumerische Kennungen, die digitale Objekte eindeutig identifizieren und als persistente Links zu Objekten im Internet funktionieren.
- *Strukturelle Metadaten* sind Metadaten über Datencontainer und repräsentieren den strukturellen Aufbau einer Datenquelle. Beispiele sind die Ordnung der Seiten eines Buches oder die For-Schleifen-Enkodierung dreidimensionaler Datenobjekte.

- *Administrative Metadaten* schließlich sind Daten, die das Management einer Datenquelle erleichtern. Beispiele für administrative Metadaten sind Provenienz, das Dateiformat, die Zugangsrechte oder andere technische Informationen zu einer Datenquelle.

Das FAIR-Ideal zum Forschungsdatenmanagement hat seinen Ursprung in Diskussionen im Rahmen der FORCE11-Konferenzserie und wurde 2016 durch Wilkinson et al. (2016) akademisch kommuniziert. Es besagt im Kern, dass Forschungsdaten *Findable*, *Accessible*, *Interoperable* und *Reusable* für Menschen und Maschinen aufbereitet und vorgehalten werden sollen. Speziell formuliert das FAIR-Datenideal folgende Ansprüche an das Management von Forschungs(meta)daten:

Findability (Auffindbarkeit)

- F1. (Meta)Daten haben einen persistenten global einzigartigen Identifikator.
- F2. Daten werden mit Metadaten angereichert.
- F3. Metadaten sind zweifelsfrei einem Datensatz zuzuordnen.
- F4. (Meta)Daten sind in einer durchsuchbaren Ressource indexiert.

Accessibility (Zugänglichkeit)

- A1. (Meta)Daten sind mit standardisierten Protokollen abrufbar.
- A1.1. Das genutzte Protokoll ist offen, kostenlos und nutzbar.
- A1.2. Das Protokoll ermöglicht Authentifizierung und Rechtevergabe.
- A2. Metadaten bleiben zugänglich, auch wenn Daten nicht mehr vorliegen.

Interoperability (Interoperabilität)

- I1. (Meta)Daten nutzen eine formale, zugängliche, gemeinsam genutzte und breit anwendbare Sprache zur Wissensrepräsentation.
- I2. (Meta)Daten nutzen Vokabularien, die den FAIR-Prinzipien folgen.
- I3. (Meta)Daten enthalten qualifizierte Referenzen auf andere (Meta)Daten.

Reusability (Wiederverwendbarkeit)

- R1. (Meta)Daten haben eine Vielzahl genauer und relevanter Attribute.
- R1.1. (Meta)Daten enthalten eine eindeutige Nutzungslizenz.
- R1.2. (Meta)Daten enthalten detaillierte Provenienz-Informationen.
- R1.3. (Meta)Daten genügen den Standards der jeweiligen Fachcommunity.

Die FAIR-Prinzipien beschreiben einen etablierten Anspruch an den Umgang mit Forschungsdaten, auch wenn noch nicht alle Datensätze entsprechend aufbereitet und zugänglich sind. Für die psychologische Forschung stehen mit PsychArchives und dem Forschungsdatenzentrum des ZPID jedoch bereits konkrete Angebote zur Verfügung, die ihre Umsetzung unterstützen. Forschende müssen daher keine eigene Infrastruktur zur Archivierung und Bereitstellung ihrer Daten aufbauen. Dokumentation, dauerhafte Auffindbarkeit und geregelte Zugangsbedingungen lassen sich über diese Angebote organisieren. Dabei können auch der Schutz der Teilnehmenden und die Bedingungen der wissenschaftlichen Nachnutzung berücksichtigt werden. Die Aufbereitung der Daten und die Klärung der rechtlichen und ethischen Voraussetzungen bleiben Teil der Projektarbeit, lassen sich aber mit vorhandener fachlicher Unterstützung bewältigen. Datenbereitstellung ist damit eine praktisch umsetzbare Aufgabe universitärer Forschung. Wie das ZPID dies ermöglicht, erläutert der folgende Abschnitt.

Zugriffsklassen

Die von Gollwitzer et al. (2021) unterschiedenen Zugriffsklassen erlauben es, die Bereitstellung von Forschungsdaten an deren Schutzbedarf anzupassen. Die Entscheidung über die Zugriffsklasse soll begründet und dokumentiert werden. Dabei gilt, den Zugang so weit wie möglich zu öffnen und Einschränkungen auf das fachlich, rechtlich oder ethisch erforderliche Maß zu begrenzen.

- *Zugriffsklasse 0 (Open Data).* Die Daten sind ohne individuelle Zugangsgenehmigung öffentlich abrufbar und breit nachnutzbar. Offene Lizenzen, etwa aus der Creative-Commons-Familie, regeln die Nutzung. Auch dabei können Pflichten wie die Namensnennung bestehen. Eine freiwillige Angabe des Nutzungszwecks beschränkt den Zugang nicht.
- *Zugriffsklasse 1 (Conditional Access).* Der Zugang setzt die Zustimmung zu standardisierten Nutzungsbedingungen voraus, beispielsweise zur Beschränkung auf wissenschaftliche Zwecke. Nach deren Annahme ist keine zusätzliche Einzelfallfreigabe durch die Datenbereitstellenden erforderlich.
- *Zugriffsklasse 2 (Restricted Access).* Die Nutzung wird durch einen individuellen Vertrag geregelt, der zusätzliche Bedingungen für das jeweilige Vorhaben festlegt. Der Zugang erfolgt erst, wenn Datenbereitstellende und Nachnutzende diesen Bedingungen zugestimmt haben.
- *Zugriffsklasse 3 (Secure Data).* Besonders schutzbedürftige Daten werden nur in einer kontrollierten Umgebung zugänglich gemacht, etwa an einem gesicherten Arbeitsplatz in einem Forschungsdatenzentrum oder über einen abgesicherten Fernzugang. Art und Umfang der Nutzung werden festgelegt und überwacht.

Dieses allgemeine Modell ist von der konkreten technischen Umsetzung zu unterscheiden. Laut aktueller PsychArchives-Dokumentation sind dort die Sharing Levels 0, 0+ und 1 verfügbar, während Level 2 noch als in Vorbereitung beschrieben wird. Das Forschungsdatenzentrum des ZPID stellt bereits Daten unter standardisierten Scientific-Use-Bedingungen und unter individuell vereinbarten Bedingungen bereit. FAIR-Zugänglichkeit kann daher auch einen geregelten Zugang umfassen.

Scientific-Use-Lizenz

Eine konkrete Umsetzung der Zugriffsklasse 1 ist die von Kreutzer (2021) entwickelte und über das ZPID bereitgestellte Scientific Use License, Version 1. Sie erlaubt die unentgeltliche Nutzung des Materials für eigene wissenschaftliche Zwecke. Dazu gehören nach Gollwitzer et al. (2021) beispielsweise die Reanalyse zur Qualitätssicherung, die Verwendung in universitärer Lehre, die Erprobung statistischer Verfahren und die Bearbeitung neuer Forschungsfragen. Die Lizenz erlaubt hierfür insbesondere das Kopieren, Analysieren und Bearbeiten des Materials sowie die Veröffentlichung eigener wissenschaftlicher Ergebnisse.

Vor dem Datenabruf muss der beabsichtigte wissenschaftliche Zweck hinreichend genau angegeben werden. Bei Veröffentlichungen sind die Urheberinnen und Urheber beziehungsweise weitere vorgesehene Rechteinhabende zu nennen und der DOI des Datensatzes zu zitieren. Die Daten selbst dürfen weder unverändert noch verändert an Dritte weitergegeben oder erneut veröffentlicht werden. Für Lehrveranstaltungen bedeutet dies, dass Studierende die Daten bei eigener Nutzung jeweils selbst unter den Lizenzbedingungen beziehen

müssen. Versuche, Teilnehmende zu reidentifizieren oder zu kontaktieren, sind untersagt. Die Lizenz endet mit der Erfüllung des angegebenen Zwecks oder bei einem Verstoß gegen ihre Bedingungen. Danach sind das lizenzierte Material und seine Kopien zu löschen. Für einen weiteren wissenschaftlichen Zweck kann eine neue Lizenz erworben werden, sofern das Material weiterhin verfügbar ist.

Bei PsychArchives akzeptieren Nachnutzende die Bedingungen vor dem Download und geben ihren Verwendungszweck an. Diese Angabe wird an die Datenbereitstellenden übermittelt, ohne dass das PsychArchives-Team ihre wissenschaftliche Angemessenheit im Einzelfall prüft. Maßgeblich sind der verlinkte Lizenztext und die Bedingungen des jeweiligen Datensatzes.

Daten bei PsychArchives einreichen

Nach der ZPID-Anleitung zur Einreichung erfolgt die Datenbereitstellung derzeit über den PsychArchives Submission Assistant. Der folgende Ablauf beschreibt den Dokumentationsstand vom 4. November 2026.

1. *Daten vorbereiten.* Der Datensatz wird anonymisiert und mit einem Codebuch versehen, das Variablen, Einheiten, Kodierungen und Datenstruktur erläutert. Rechte, Einwilligungen und die Zustimmung aller Mitwirkenden sind zu klären. Geeignete offene Dateiformate erleichtern die spätere Nachnutzung.
2. *Dateien und Metadaten einreichen.* Im Submission Assistant werden die Dateien hochgeladen, einem Objekttyp wie „Research Data“ zugeordnet und beschrieben. Zusammengehörige Daten, Analyseskripte und Publikationen können als mehrere miteinander verknüpfte Objekte eingereicht werden. Außerdem werden Sharing Level und Lizenz gewählt.
3. *Formale Prüfung abwarten.* Das PsychArchives-Team prüft die fachliche Passung und die Qualität der Metadaten. Dies ist kein wissenschaftliches Peer Review. Laut Dokumentation erfolgt die formale Prüfung üblicherweise innerhalb von ein bis zwei Arbeitstagen.
4. *Veröffentlichen und zitieren.* Nach Annahme werden die Objekte archiviert und die endgültigen DOIs mitgeteilt. Diese dienen zur dauerhaften Referenzierung der Daten und der zugehörigen Materialien.

Die technischen und inhaltlichen Richtlinien erläutern die Vorbereitung im Detail. Für Datenobjekte über 1 GB soll vorab der Kontakt zum Team gesucht werden. Bei späteren wesentlichen Änderungen wird in der Regel eine neue Version angelegt. Damit sind die Einreichung und die spätere Nutzung als geregelte Schritte des Forschungsprozesses organisiert.

Selbstkontrollfragen

1. Nennen und erläutern Sie die sechs dargestellten Arbeitsphasen des empirischen Forschungsprozesses.
2. Erläutern Sie die Begriffe der Rohdaten und der Primärdaten.
3. Erläutern Sie den Begriff der FAIR-Bereitstellung von Forschungsdaten.
4. Erläutern Sie die Begriffe der latenten und der observierbaren Variablen.

5. Erläutern Sie die Begriffe der Operationalisierung und der Inferenz.
6. Erläutern Sie das Modell eines dreidimensionalen Datenaufnahmeraums.
7. Nennen Sie drei Arten von Verhaltensbeobachtungsdaten.
8. Nennen Sie drei Arten von Verhaltensbefragungsdaten.
9. Nennen Sie drei Arten von vegetativphysiologischen Daten.
10. Nennen Sie drei Arten von neurophysiologischen Daten.
11. Erläutern Sie das Aufnahmeprinzip und die biologischen Grundlagen des EEG.
12. Erläutern Sie das Aufnahmeprinzip der fMRT und ihre biologischen Grundlagen.
13. Erläutern Sie die Zugriffsklassen 0 bis 3 zur Bereitstellung von psychologischen Forschungsdaten.
14. Erläutern Sie die Scientific-Use-Lizenz nach Kreutzer (2021).

4 Messen und Quantifizieren

Menschen nutzen seit alters her Symbole und Zahlen, um Mengen und Größen darzustellen. Messen und Quantifizieren spielen dabei insbesondere im ökonomisch-gesellschaftlichen Austausch eine zentrale Rolle und gewannen durch die wissenschaftliche Revolution und die Industrialisierung weiter an Bedeutung. Heute reichen Messverfahren von der Erfassung physikalischer bis zur Untersuchung psychobiologischer Phänomene. Messen ist damit ein wesentlicher Bestandteil wissenschaftlicher Datenerhebung. Doch ist jede Datenerhebung auch eine Messung, und welche Vorstellungen vom Messen liegen der modell-basierten Datenwissenschaft, wie wir sie in unserer wissenschaftlichen Arbeit verfolgen, zugrunde?

Messen und Quantifizieren werfen grundlegende Fragen der Epistemologie und der Ontologie auf. Die Epistemologie, also die Lehre von der Erkenntnis, fragt danach, was Wissen ist, wie wir es erwerben und wo seine Grenzen liegen. Für das Messen stellt sich damit die Frage, welches Wissen Messungen ermöglichen und wie unsere Sprache und Begriffe dieses Wissen prägen. Die Ontologie, also die Lehre vom Sein, beschäftigt sich dagegen damit, was existiert und welche Eigenschaften dem Existierenden zukommen. In diesem Zusammenhang ist zu fragen, ob gemessene Eigenschaften unabhängig von unseren Messverfahren existieren und ob ihre quantitative Struktur bereits in der Welt vorliegt oder erst durch unsere Beschreibungen entsteht.

Messen und Quantifizieren besitzen zweifellos epistemische und soziale Autorität. Beide gelten als wirksamer Weg, neues Wissen zu erschließen und Aussagen, die auf Daten basieren, werden in der Regel als glaubwürdiger angesehen als bloße Behauptungen. In politischen Diskussionen kann beispielsweise die Forderung nach zusätzlichen Angeboten zur psychotherapeutischen Versorgung an Überzeugungskraft gewinnen, wenn sie mit Zahlen zur Häufigkeit psychischer Erkrankungen begründet wird. Solche Zahlen können politische Entscheidungen informieren, ihre Aussagekraft hängt jedoch davon ab, wie psychische Erkrankungen definiert und erfasst wurden. Die Autorität des Messens entbindet uns daher nicht von der Frage, was überhaupt gemessen wird und unter welchen Bedingungen die gewonnenen Zahlen eine Schlussfolgerung rechtfertigen.

Trotz ihrer epistemischen und sozialen Autorität ist keineswegs eindeutig, was eine Tätigkeit zu einer Messung macht. Müssen die gemessenen Eigenschaften unabhängig von unserer Anschauung existieren? Lassen sich psychologische Eigenschaften wie Intelligenz oder die Stärke einer Empfindung im gleichen Sinne messen wie die Länge eines Stabes oder die Temperatur eines Gegenstandes? Auch die Definitionen des Messens geben darauf keine einheitliche Antwort. Wie Tabelle 4.1 zeigt, unterscheiden sie sich bereits darin, ob sie den Messprozess oder sein Ergebnis in den Mittelpunkt stellen, den Vergleich mit einer Einheit voraussetzen, Zahlen als Ergebnis verlangen oder empirische Eingriffe erfordern. Was jeweils als Messung gilt, hängt somit auch von den zugrunde gelegten begrifflichen und theoretischen Annahmen ab.

Tabelle 4.1 Unterschiedliche Charakterisierungen des Messens. Nach Mari et al. (2021), Tabelle 4.1, S. 74, aus dem Englischen übersetzt.

Kriterium	Beispielhafte Definition oder Charakterisierung
Ist Messen durch die Struktur des Prozesses charakterisiert?	Jedes Messsystem besteht aus mehreren Elementen oder Bausteinen. Es lassen sich vier Arten von Elementen unterscheiden, wobei in einem gegebenen System eine Art fehlen oder mehrfach vorkommen kann. (Bentley, 2005)
Oder durch die erzeugten Ergebnisse?	Messen ist im Wesentlichen ein Produktionsprozess, dessen Produkt Zahlen sind. (Speitel, 1992)
Setzt Messen den Vergleich mit einer Referenz, möglicherweise einer Einheit, voraus?	Messungen sind die Durchführung geplanter Handlungen zum qualitativen Vergleich einer Messgröße mit einer Einheit. (DIN Deutsches Institut für Normung, 1995)
Oder nicht?	Messen ist der Prozess der empirischen, objektiven Zuordnung von Zahlen zu den Eigenschaften von Objekten und Ereignissen der realen Welt, um diese zu beschreiben. (Finkelstein, 1994)
Müssen Messergebnisse Zahlen sein?	Das Messen von Größen ist im allgemeinsten Sinne jede Methode, durch die eine eindeutige und wechselseitige Zuordnung zwischen allen oder einigen Größen einer Art und allen oder einigen Zahlen hergestellt wird, je nach Fall ganzen, rationalen oder reellen Zahlen. (Russell, 1903)
Oder nicht?	Das einzig entscheidende Merkmal aller Messungen ist die symbolische Repräsentation. Auch Zahlen sind keineswegs die einzigen verwendbaren Symbole. Messen erlaubt es, Dinge relativ zur angenommenen Messgrundlage mithilfe von Symbolen begrifflich darzustellen. (Weyl, 1949)
Sind experimentelle Tätigkeiten erforderlich, um eine Messung durchzuführen?	Messen ist die Gesamtheit der empirischen und informationsbezogenen Operationen, die mithilfe geeigneter Geräte in Wechselwirkung mit dem untersuchten System durchgeführt werden, um einer als Systemparameter angenommenen Größe einen Wert zuzuweisen. (Ente Italiano di Normazione, 1984)
Oder nicht?	Messen ist die Zuordnung von Zahlzeichen zu Objekten oder Ereignissen nach einer Regel, gleich welcher. (Stevens, 1959)

Die folgenden Sektionen stellen unterschiedliche Auffassungen des Messens vor und untersuchen ihre Voraussetzungen, Möglichkeiten und Grenzen. Als Leitfaden dient das Kapitel „Philosophical perspectives on measurement“ von Mari et al. (2021), das zentrale messtheoretische Positionen systematisch gegenüberstellt. Ergänzend bietet Tal (2020) mit „Measurement in Science“ einen Überblick über philosophische Fragen und Erklärungsansätze zum wissenschaftlichen Messen. Pedersen et al. (2025) verdeutlichen in „Discourse on Measurement“, warum ein reflektiertes Verständnis des Messens für wissenschaftliches Schlussfolgern, die Planung von Untersuchungen und die Interpretation von Ergebnissen wesentlich ist. Eine historische Vertiefung bietet Chang (2007) mit „Inventing Temperature“, das am Beispiel der Temperaturmessung zeigt, wie heute selbstverständlich erscheinendes Wissen durch begriffliche Arbeit, Experimente und wissenschaftliche Kontroversen entsteht.

Bei aller notwendigen Reflexion über die Grundlagen des Messens verfolgen wir dabei im Wesentlichen den Gedanken, dass die quantitative Beschreibung von Phänomenen ein zentraler Weg zu wissenschaftlicher Erkenntnis ist. Diesen Anspruch formulierte William Thomson, besser bekannt als Lord Kelvin, besonders pointiert:

> “I often say that when you can measure what you are speaking about and express it in numbers you know something about it; but when you cannot measure it, when you cannot express it in numbers, your knowledge of it is of a meagre and unsatisfactory kind; it may be the beginning of knowledge, but you have scarcely, in your thoughts, advanced to the stage of science, whatever that may be.” (Thomson, 1891)

4.1 Naiver Realismus

Der naive Realismus ist ein wissenschaftlich-philosophisches Anschauungskonstrukt mit langer Geschichte, das einen einfachen und direkten Zugang zur Einordnung des Messens und Quantifizierens ermöglicht. Grob skizziert geht der naive Realismus davon aus, dass die Welt unabhängig von uns und unserem Verständnis von ihr existiert und dass wir sie direkt erkennen können, ohne dass unser Wissen durch begriffliche oder sprachliche Schemata vermittelt wird (Abbildung 4.1). Objekte besitzen demnach Eigenschaften mit jeweils einem wahren Wert, den eine Messung feststellen soll. Die mathematische Struktur dieser Eigenschaften wird dabei als Bestandteil der Welt selbst verstanden, der unabhängig von menschlicher Kognition besteht. Messen erscheint aus dieser Perspektive als ein Transmissionsprozess, bei dem eine bereits vorhandene Eigenschaft in ein Messergebnis übertragen wird. Im Idealfall entspricht diese Übertragung einer Identitätsabbildung, sodass der gemessene Wert mit dem wahren Wert übereinstimmt. Abweichungen vom wahren Wert lassen sich dann als Messfehler auffassen. Damit bietet diese Vorstellung einen unmittelbaren Anknüpfungspunkt für die statistische Messfehlertheorie, in der beobachtete Werte als Zusammensetzung eines wahren Wertes und eines Messfehlers modelliert werden.

Ein früher Bezugspunkt für die Vorstellung einer mathematischen Ordnung der Welt findet sich in Aristoteles' *Metaphysik* (ca. 350 v. Chr.). In der folgenden Passage beschreibt Aristoteles die Auffassungen der Pythagoreer.

„Unter diesen nun und noch vor ihnen haben die Pythagoreer, wie man sie nennt, sich mit dem Studium der Mathematik beschäftigt und zunächst diese gefördert; in dieser heimisch geworden, haben sie so dann die Prinzipien derselben zu Prinzipien des Seienden überhaupt machen zu dürfen geglaubt. Da nun unter den Prinzipien der Mathematik der Natur der Sache nach in erster Linie die Zahlen stehen, so glaubten sie in den Zahlen mancherlei Gleichnisse für das, was ist und was geschieht zu finden, und zwar hier eher als in Feuer, Erde oder Wasser. So bedeutete ihnen eine Zahl mit bestimmten Eigenschaften die Gerechtigkeit, eine andere Seele und Vernunft, wieder eine andere den rechten Augenblick, und so fand sich eigentlich für alles ein Gleichnis in einer Zahl. Da sie nun auch darauf aufmerksam wurden, dass die Verhältnisse und Gesetze der musikalischen Harmonie sich in Zahlen darstellen lassen, und da auch alle anderen Erscheinungen eine natürliche Verwandtschaft mit den Zahlen zeigten, die Zahlen aber das erste in der gesamten Natur sind, so kamen sie zu der Vorstellung, die Elemente der Zahlen seien die Elemente alles Seienden und das gesamte Weltall sei eine Harmonie und eine Zahl.“ (Aristoteles, *Metaphysik*, I, 5, Übersetzung nach Aristoteles (1907))

Eine Aussage aus der pythagoreischen Tradition selbst ist von Philolaos von Kroton überliefert, der im 5. Jahrhundert v. Chr. wirkte. In einem als echt anerkannten, bei Stobaios erhaltenen Fragment heißt es:

“And indeed all things that are known have number. For it is not possible that anything whatsoever be understood or known without this.” (Philolaos, Fragment 4, DK 44 B 4, englische Übersetzung nach Huffman (2024), Abschnitt 3)

Philolaos verbindet hier die Erkennbarkeit der Dinge mit ihrer zahlenmäßigen Struktur. Damit bietet das Fragment einen Beleg für die Vorstellung, dass quantitative Verhältnisse einen grundlegenden Zugang zum Verständnis der Welt eröffnen. Eine verwandte Vorstellung begegnet uns zu Beginn der neuzeitlichen Naturwissenschaft bei Galileo Galilei. In *Il Saggiatore* (*Der Prüfer mit der Goldwaage*, 1623) beschreibt er das Universum als ein Buch, dessen Sprache die Mathematik ist. Wissenschaftliche Erkenntnis setzt demnach voraus, diese Sprache zu verstehen und die mathematische Ordnung der Natur zu erschließen.

Abbildung 4.1 Naiver Realismus: Messen als Übertragung einer unabhängig vom Beobachter bestehenden Objekteigenschaft in ein Messergebnis.

„Die Philosophie ist in diesem großartigen Buch geschrieben, das vor unseren Augen immer offen steht (ich meine das Universum), das man aber nicht begreifen kann, wenn man nicht zuerst lernt, die Sprache zu verstehen und die Buchstaben zu erkennen, in denen es geschrieben ist. Es ist in mathematischer Sprache geschrieben, und seine Buchstaben sind Dreiecke, Kreise und andere geometrische Figuren; ohne diese Mittel ist es den Menschen unmöglich, ein einziges Wort zu verstehen; eine vergebliche Wanderung durch ein dunkles Labyrinth.“ (Galilei (1623), deutsche Fassung nach der Folienvorlage)

Isaac Newton schließlich unterscheidet in seinen *Philosophiae naturalis principia mathematica* (1687) ausdrücklich zwischen den Größen selbst und den sinnlich zugänglichen Maßen, mit denen wir sie erfassen. Im Scholium zu den Definitionen fordert er dazu auf,

“[…] to abstract from our senses, and consider things themselves, distinct from what are only sensible measures of them.” (Newton (1934), Scholium zu den Definitionen, Abschnitt VII, englische Übersetzung von Andrew Motte, überarbeitet von Florian Cajori)

Damit wird eine für das realistische Verständnis des Messens zentrale Unterscheidung greifbar: Die zu bestimmende Größe besteht unabhängig von dem Verfahren, mit dem wir sie erfassen. Ihre sinnlich zugänglichen Maße können mehr oder weniger genau sein. An diese Unterscheidung lässt sich die Vorstellung anschließen, dass Messergebnisse von einem wahren Wert abweichen können und diese Abweichungen als Messfehler zu untersuchen sind.

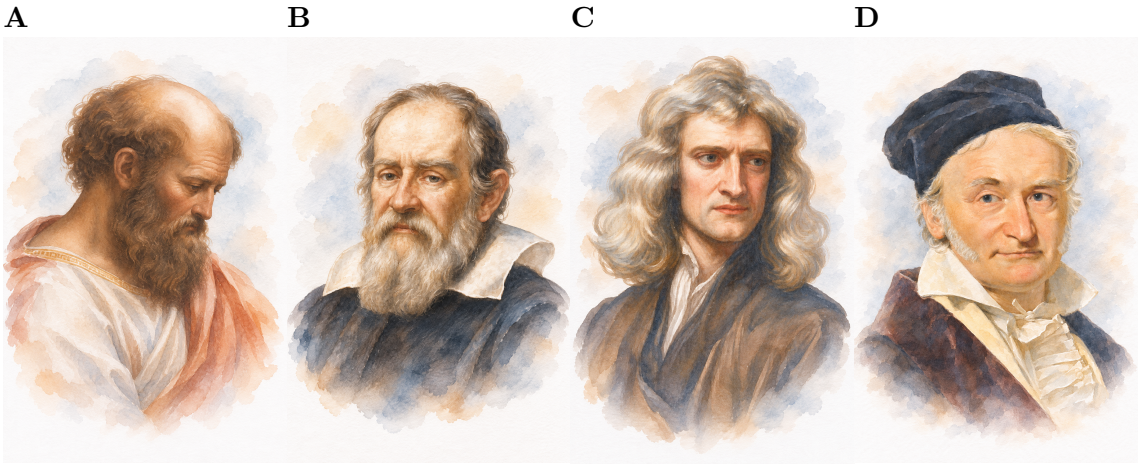

Abbildung 4.2 Vertreter realistischer Positionen: **A** Pythagoras (ca. 570–490 v. Chr.), **B** Galileo Galilei (1564–1642), **C** Isaac Newton (1643–1727), **D** Carl Friedrich Gauß (1777–1855). Pythagoras ist in einer idealisierten Darstellung nach Raffael wiedergegeben.

Naiver Realismus und statistische Messfehlertheorie

Die Vorstellung, dass eine Objekteigenschaft einen wahren Wert besitzt, den wir durch Messungen erschließen können, findet einen mathematischen Ausdruck in der statistischen Messfehlertheorie. In der durch Gauss (1809) und Laplace (1810) geprägten Tradition werden beobachtete Werte als Zusammensetzung eines wahren Wertes und eines zufälligen Messfehlers aufgefasst. Eine wichtige Anwendung war die astronomische Bestimmung von Himmelskörperpositionen und Planetenbahnen. Die Annahme, dass ein Himmelskörper zu einem bestimmten Zeitpunkt eine bestimmte Position besitzt, die durch Beobachtungen mehr oder weniger genau erfasst wird, erscheint dabei unmittelbar plausibel. Unter der zusätzlichen Annahme normalverteilter Messfehler ergibt sich das Modell

$$\text{Beobachteter Wert} = \text{Wahrer Wert} + \text{Normalverteilter Messfehler}. \tag{4.1}$$

Für wiederholte Messungen einer unveränderten Größe lässt sich dieses Modell als

$$y_i = \mu + \varepsilon_i, \qquad \varepsilon_i \overset{\text{iid}}{\sim} N(0, \sigma^2), \qquad i = 1, \ldots, n \tag{4.2}$$

formulieren. Dabei bezeichnet y_i den beobachteten Wert der i-ten Messung, μ den gemeinsamen wahren Wert und ε_i den jeweiligen Messfehler. Die Fehler werden als unabhängig und identisch normalverteilt mit Erwartungswert null und Varianz σ^2 angenommen. Unter diesen Voraussetzungen lässt sich μ durch den Mittelwert der Beobachtungen schätzen. Die Normalverteilungsannahme wird durch den zentralen Grenzwertsatz gestützt (Liapounoff, 1901; Lindeberg, 1922): Setzt sich ein Messfehler aus vielen unabhängigen zufälligen Einflüssen zusammen, von denen keiner dominiert, kann ihre Summe unter geeigneten Bedingungen näherungsweise normalverteilt sein. Die so begründete Modellierung zufälliger Messabweichungen ermöglicht es, die Unsicherheit einer Schätzung des wahren Wertes zu quantifizieren, und bildet damit einen grundlegenden Anwendungsfall der frequentistischen Inferenz, zu deren Entwicklung insbesondere Fisher (1925) beitrug.

Die Übertragung dieser Vorstellung auf Unterschiede zwischen Menschen wirft allerdings zusätzliche Fragen auf. Quetelet (1846) untersuchte die Verteilung der Brustumfänge von

rund 5.000 Soldaten und deutete sie nach dem Vorbild der Messfehlertheorie als Abweichungen von einem gemeinsamen menschlichen Typus. Dabei bleibt unklar, was der durch den Mittelwert geschätzte „wahre Brustumfang eines Soldaten“ eigentlich sein soll. Anders als bei wiederholten Messungen derselben Planetenposition liegt hier keine einzelne Objekteigenschaft vor, deren wahrer Wert durch mehrere Beobachtungen angenähert wird. Die Soldaten besitzen vielmehr unterschiedliche Brustumfänge, und der durchschnittliche Brustumfang muss nicht der Brustumfang irgendeines tatsächlich existierenden Soldaten sein. Galton (1869) übertrug die Vorstellung einer gesetzmäßigen Verteilung von Abweichungen auf Unterschiede geistiger Fähigkeiten zwischen Menschen. Hier stellt sich zusätzlich die ontologische Frage, inwieweit eine „wahre Intelligenz“ als unabhängig von unseren Begriffen und Messverfahren bestehende Eigenschaft in der Welt angenommen werden darf. Die Beschreibung einer Verteilung allein beantwortet diese Frage nicht. Die von Edgeworth (1892) diskutierte Unterscheidung zwischen Mittelwerten als Beschreibungen und als Schätzungen zugrunde liegender Ursachen verdeutlicht das gemeinsame Problem: Ein Mittelwert kann Daten sinnvoll zusammenfassen, ohne deshalb einen unabhängig bestehenden wahren Wert zu repräsentieren.

In der klassischen Testtheorie versuchen Novick (1966) und Lord & Novick (1968), den Begriff des wahren Wertes statistisch zu bestimmen und damit von einer solchen ontologischen Festlegung zu lösen (vgl. auch Borsboom et al. (2004)). Die Zufallsvariable y bezeichnet den beobachteten Wert und die Zufallsvariable τ den wahren Wert einer Testperson. Es gilt

$$\tau = \mathbb{E}(y \mid \tau), \tag{4.3}$$

und der Messfehler wird definiert als

$$\varepsilon := y - \tau. \tag{4.4}$$

Daraus folgen die Zerlegung und die Bedingung

$$y = \tau + \varepsilon, \qquad \mathbb{E}(\varepsilon \mid \tau) = 0. \tag{4.5}$$

Anschaulich soll der wahre Wert dem im Mittel zu erwartenden Ergebnis wiederholter Testmessungen unter identischen Bedingungen entsprechen. Die angestrebte antimetaphysische Grundhaltung bleibt jedoch fragwürdig: Identische Testwiederholungen sind ein Gedankenexperiment, und der wahre Wert ist ein theoretischer Erwartungswert statt eines empirischen Mittelwerts.

Probleme des Naiven Realismus

Ein grundlegendes Problem des naiven Realismus besteht darin, dass er Aussagen über wahre Werte trifft, die unserer Erfahrung nicht unmittelbar zugänglich sind. Ob ein Messergebnis mit dem wahren Wert einer Eigenschaft übereinstimmt, lässt sich nicht unabhängig von weiteren, ihrerseits möglicherweise fehlerbehafteten Messungen feststellen. Der

wahre Wert bleibt damit eine theoretische Annahme, deren Interpretation sich vom vermeintlich unmittelbar erfassbaren Merkmal der Wirklichkeit zum Ergebnis einer idealisierten Messung verschiebt. Dies kommt in der Formulierung von Regtien & Finkelstein (2004) zum Ausdruck:

> "The true value of the measurand is the result that would be obtained by a perfect measurement. Since perfect measurements are only imaginary, a true value is always indeterminate and unknown."

Die Annahme unbekannter wahrer Parameterwerte bleibt gleichwohl für weite Teile der frequentistischen und bayesianischen Inferenz grundlegend. Frequentistische Verfahren beurteilen beispielsweise, wie zuverlässig Schätzungen einen angenommenen wahren Parameterwert erfassen. Bayesianische Verfahren beschreiben die Unsicherheit über mögliche Parameterwerte durch Wahrscheinlichkeitsverteilungen und aktualisieren diese anhand beobachteter Daten. In beiden Fällen ermöglicht die Unterscheidung zwischen beobachteten Daten und unbekannten Größen das statistische Schlussfolgern über die unmittelbar vorliegenden Beobachtungen hinaus. Diese Gemeinsamkeit setzt jedoch keine vollständige Übernahme des naiven Realismus voraus. Die Parameter können innerhalb eines ausdrücklich als vereinfachend verstandenen Modells interpretiert werden, ohne sie mit unmittelbar zugänglichen Eigenschaften der Wirklichkeit gleichzusetzen. Einen Überblick über diese Grundlagen bietet Romeijn (2025), *Philosophy of Statistics*.

Die statistische Verwendung wahrer Werte beantwortet somit noch nicht die Frage, wodurch die Bedeutung einer gemessenen Eigenschaft bestimmt wird. Der Operationalismus setzt an dieser Schwierigkeit an und verlagert die Aufmerksamkeit von unabhängig bestehenden, aber unbekannten Werten auf die tatsächlich ausführbaren Messoperationen. Die Bedeutung einer Eigenschaft soll sich aus den Verfahren ergeben, mit denen sie erfasst wird.

4.2 Operationalismus

Der Operationalismus bietet einen Zugang zum Messen und Quantifizieren, bei dem die Bedeutung wissenschaftlicher Begriffe durch die zugehörigen Messoperationen bestimmt wird (Abbildung 4.3). Grob skizziert geht er davon aus, dass uns Phänomene der Welt durch Erfahrung zugänglich sind, diese aber nicht bereits von sich aus numerische Eigenschaften besitzen, deren wahre Werte durch Messungen lediglich aufzudecken wären. Ein Begriff wie Länge, Temperatur oder Intelligenz erhält seine Bedeutung vielmehr durch die Regeln und Verfahren, mit denen eine entsprechende Messung durchgeführt wird. Die Frage, was unabhängig von diesen Operationen „wirklich" gemessen wird, gilt aus dieser Perspektive als bedeutungslos. Der Operationalismus ist damit primär ein semantischer Ansatz, also eine Auffassung darüber, wodurch Begriffe ihre Bedeutung erhalten. Er ist nicht lediglich eine methodologische Forderung, Messverfahren möglichst genau zu beschreiben.

Historisch lässt sich der Operationalismus in das Umfeld des logischen Empirismus einordnen, der auch als logischer Positivismus bezeichnet wird und insbesondere durch den Wiener Kreis der Jahre 1924 bis 1936 geprägt wurde. Dessen Vertreter verbanden eine empiristische Orientierung an der Erfahrung mit der logischen Analyse wissenschaftlicher Sprache und mathematischer Begriffe. Gemeinsam war ihnen eine antimetaphysische Grundhaltung: Wissenschaftliche Aussagen sollten einen erfahrungsbezogenen Gehalt besitzen, während Behauptungen über eine prinzipiell erfahrungsunzugängliche Wirklichkeit

Abbildung 4.3 Operationalismus: Die Bedeutung einer gemessenen Eigenschaft wird durch die zu ihrer Messung verwendeten Operationen bestimmt.

zurückgewiesen wurden. Diese Haltung kommt in der von Hans Hahn, Otto Neurath und Rudolf Carnap verfassten Programmschrift *Wissenschaftliche Weltauffassung: Der Wiener Kreis* zum Ausdruck (Neurath et al., 1929):

„Der Wiener Kreis aber vertritt darüber hinaus die Auffassung, dass auch die Aussagen des (kritischen) Realismus und Idealismus über Realität oder Nichtrealität der Außenwelt und des Fremdpsychischen metaphysischen Charakters sind, da sie denselben Einwänden unterliegen wie die Aussagen der alten Metaphysik: Sie sind sinnlos, weil nicht verifizierbar, nicht sachhaltig. Etwas ist *wirklich* dadurch, dass es eingeordnet wird dem Gesamtgebäude der Erfahrung."

Der Operationalismus greift eine verwandte Grundhaltung auf, indem er die Bedeutung wissenschaftlicher Begriffe an erfahrungszugängliche Operationen bindet. Für das Messen verschiebt sich damit die zentrale Frage von der Existenz einer unabhängig gegebenen Eigenschaft zu den konkreten Handlungen und Regeln, durch die ein Messbegriff seinen Inhalt erhält.

Eine besonders prägnante Formulierung des operationalistischen Ansatzes findet sich bei dem Physiker Percy Williams Bridgman. In *The Logic of Modern Physics* erläutert Bridgman (1927) am Beispiel der Länge, wie die Bedeutung eines Begriffs durch die zugehörigen Messoperationen bestimmt wird:

"The concept of length is (…) fixed when the operations by which length is measured are fixed: that is, the concept of length involves as much as and nothing more than the set of operations by which length is determined."

Rudolf Carnap veranschaulicht die Einführung quantitativer Begriffe in *Philosophical Foundations of Physics* am Beispiel des Gewichts (Carnap, 1966):

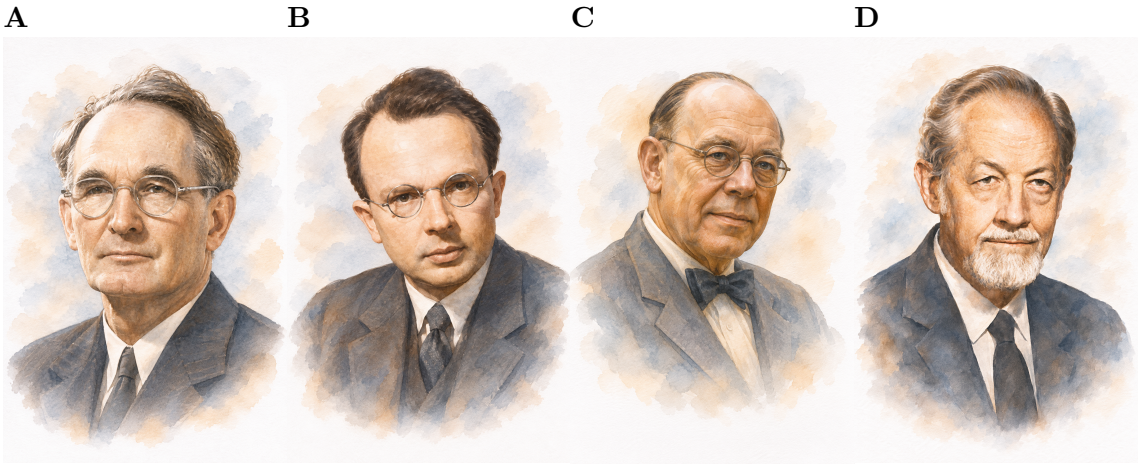

Abbildung 4.4 Vertreter operationalistischer Positionen: **A** Percy Williams Bridgman (1882–1961), **B** Rudolf Carnap (1891–1970), **C** Edwin Garrigues Boring (1886–1968), **D** Stanley Smith Stevens (1906–1973).

"Let us (…) consider the physical magnitude of weight. You pick up a stone. It is heavy. You compare it with another stone, a much lighter one. If you examine both stones, you will not come upon any numbers or find any discrete units that can be counted. The phenomenon itself contains nothing numerical – only your private sensations of weight. (…) We introduce the numerical concept of weight by setting up a procedure for measuring it. It is we who assign numbers to nature. The phenomena exhibit only qualities that we observe."

Die Verbindung zwischen der Bedeutung eines Größenbegriffs und den Regeln seiner Messung fasst Carnap anschließend so zusammen:

"In order to give meaning to such terms as 'length' and 'temperature', we must have rules for the process of measuring. These rules are nothing other than rules that tell us how to assign a certain number to a certain body or process so we can say that this number represents the value of the magnitude for that body."

Operationalistische Einflüsse in der Psychologie

In der Psychologie fanden operationalistische Vorstellungen insbesondere bei der Bestimmung psychologischer Begriffe und der Entwicklung von Messverfahren Anklang. Bereits vor Bridgmans programmatischer Darstellung formulierte Boring (1923) eine Auffassung von Intelligenz, die deren Bedeutung an die verwendeten Tests bindet:

"If we agree, then, to define intelligence as what the tests of intelligence test, there is a good deal that we can say about it."

Im Behaviorismus richtete sich das Interesse auf die Beschreibung und Erklärung von Verhalten anhand empirisch zugänglicher Bedingungen. Skinner (1945) setzte sich ausdrücklich mit der operationalen Analyse psychologischer Begriffe auseinander. Dabei stand die Frage im Vordergrund, unter welchen Bedingungen solche Begriffe verwendet werden und welchen Bezug sie zum Verhalten besitzen. Eine für die psychologische Methodenlehre besonders einflussreiche Formulierung lieferte schließlich Stevens (1946). Stevens, der bei Boring studiert hatte und zur Psychophysik der Lautheitswahrnehmung forschte, bestimmte Messen als regelgeleitete Zuordnung von Zahlzeichen:

"(…), we may say that measurement, in the broadest sense, is defined as the assignment of numerals to objects or events according to rules."

Damit rückten die Regeln der Zuordnung in den Mittelpunkt der Bestimmung dessen, was als Messung gilt. Stevens' Definition eröffnet einen weiten Messbegriff, der unterschiedliche Formen der Zuordnung von Zahlen zu psychologischen Beobachtungen einschließt. Daran knüpft die Repräsentationstheorie des Messens an, die wir im nächsten Abschnitt vertiefen: Sie untersucht, unter welchen Bedingungen Beziehungen zwischen empirischen Objekten durch Beziehungen zwischen Zahlen angemessen dargestellt werden können. Entscheidend ist dabei, welche empirischen Strukturen eine solche Zuordnung erhält und wie eindeutig die resultierende numerische Darstellung bestimmt ist (Krantz et al., 1971; Scott & Suppes, 1958).

Probleme des Operationalismus

Ein grundlegendes Problem eines radikalen Operationalismus ergibt sich aus der Gleichsetzung eines Begriffs mit den zu seiner Messung verwendeten Operationen. Wenn unterschiedliche Messverfahren unterschiedliche Begriffe definieren, messen ein Zollstock und ein Maßband verschiedene „Längen", ein Digitalthermometer und ein Quecksilberthermometer verschiedene „Temperaturen" und zwei Depressionsfragebögen verschiedene „Depressionen". Es fehlt dann ein gemeinsamer Bezugspunkt, der es erlaubt, die Ergebnisse unterschiedlicher Verfahren als Messungen derselben Eigenschaft zu verstehen und miteinander zu vergleichen.

Zudem lässt sich innerhalb dieser Gleichsetzung schwer erklären, was ein Messfehler sein soll. Wenn die korrekt ausgeführten Messoperationen die Bedeutung der gemessenen Eigenschaft vollständig festlegen, kann ihr Ergebnis nicht von einem unabhängig bestimmten Wert dieser Eigenschaft abweichen. Fehler bei der Durchführung eines Verfahrens bleiben zwar möglich, doch für die Frage, ob das Verfahren selbst die betreffende Eigenschaft angemessen erfasst, bietet der radikale Operationalismus keinen unabhängigen Maßstab. Damit gerät er in Spannung zur wissenschaftlichen Praxis, in der wir Messverfahren vergleichen, ihre Genauigkeit beurteilen und ihre Ergebnisse als mehr oder weniger verlässliche Aussagen über denselben Gegenstand behandeln.

Der Operationalismus fordert somit eine klare Bindung wissenschaftlicher Begriffe an nachvollziehbare Verfahren, erklärt aber allein noch nicht, weshalb deren Ergebnisse Wissen über die Welt liefern. Die epistemische und soziale Autorität des Messens lässt sich durch die Festlegung von Messoperationen nicht hinreichend begründen. Für eine weiterführende Messtheorie bleibt daher zu klären, unter welchen Bedingungen die Zuordnung von Zahlen empirische Verhältnisse angemessen darstellt. Diese Frage führt zur Repräsentationstheorie des Messens.

Selbstkontrollfragen

1. Erläutern Sie die Aussage, dass Messen „epistemische und soziale Autorität besitzt".
2. Erläutern Sie die Grundannahmen des Naiven Realismus.
3. Skizzieren Sie die Historie der Messfehlertheorie.
4. Erläutern Sie Probleme des Naiven Realismus.
5. Erläutern Sie die Grundannahmen des Operationalismus.
6. Erläutern Sie Probleme des (radikalen) Operationalismus.

Referenzen

Aggarwal, C. C. (2016). *Recommender Systems: The Textbook*. Springer. https://doi.org/10.1007/978-3-319-29659-3

Aristoteles. (1907). *Metaphysik* (A. Lasson, Übers.). Eugen Diederichs.

Bari, D. S., Yacoob Aldosky, H. Y., & Martinsen, Ø. G. (2026). Electrodermal Activity Measurements: A Review of Artifacts. *Physiological Measurement*, *47*(7), 07TR01. https://doi.org/10.1088/1361-6579/ae7bae

Bentley, J. P. (2005). *Principles of Measurement Systems* (4. Aufl.). Pearson Prentice Hall.

Boring, E. (1923). Intelligence as the Tests Test It. *New Republic*, *36*, 35–37.

Borsboom, D., Mellenbergh, G. J., & Van Heerden, J. (2004). The Concept of Validity. *Psychological Review*, *111*(4), 1061–1071. https://doi.org/10.1037/0033-295X.111.4.1061

Bridgman, P. W. (1927). *The Logic of Modern Physics*. MacMillan.

Bühner, M. (2010). *Einführung in die Test- und Fragebogenkonstruktion* (2., aktualisierte und erw. Aufl., [Nachdr.]). Pearson Studium.

Buzsáki, G., Anastassiou, C. A., & Koch, C. (2012). The Origin of Extracellular Fields and Currents — EEG, ECoG, LFP and Spikes. *Nature Reviews Neuroscience*, *13*(6), 407–420. https://doi.org/10.1038/nrn3241

Carnap, R. (1966). *Philosophical Foundations of Physics. An Introduction to the Philosophy of Science*. Basic Books.

Chang, H. (2007). *Inventing Temperature: Measurement and Scientific Progress* (1. issued as paperback). Oxford University Press.

DIN Deutsches Institut für Normung. (1995). *Grundlagen Der Meßtechnik – Teil 1: Grundbegriffe* (Norm DIN 1319-1:1995-01). DIN Deutsches Institut für Normung.

Döring, N. (2023). *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-64762-2

Edgeworth, F. Y. (1892). The Law of Error and Correlated Averages. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, *34*(210), 429–438. https://doi.org/10.1080/14786449208620355

Ente Italiano di Normazione. (1984). *Misure e misurazioni. Termini e definizioni fondamentali* ({Norm} UNI 4546:1984). Ente Italiano di Normazione.

Finkelstein, L. (1994). Measurement: Fundamental Principles. In L. Finkelstein & K. Grattan (Hrsg.), *Concise Encyclopedia of Measurement and Instrumentation* (S. 201–205). Pergamon.

Fisher, R. A. (1925). Applications of "Student's" Distribution. *Metron*, *5*, 90–104.

Freeman, H. E., & Rossi, P. H. (1984). Furthering the Applied Side of Sociology. *American Sociological Review*, *49*(4), 571–580. https://doi.org/10.2307/2095470

Friston, K. J. (2005). A Theory of Cortical Responses. *Philosophical Transactions of the Royal Society B: Biological Sciences*, *360*(1456), 815–836. https://doi.org/10.1098/rstb.2005.1622

Galilei, G. (1623). *Il Saggiatore*.

Galton, F. (1869). *Hereditary Genius: An Inquiry Into Its Laws and Consequences*. MacMillan.

Gauss, C. F. (1809). *Theoria Motus Corporum Coelestium in Sectionibus Conicis Solem Ambientium*. Cambridge University Press.

Gerrig, R. J., Zimbardo, P. G., Graf, R., & Gerrig, R. J. (2020). *Psychologie* (18., aktualis. Aufl., [Nachdr.]). Pearson Studium.

Gijsen, S., Grundei, M., Lange, R. T., Ostwald, D., & Blankenburg, F. (2021). Neural Surprise in Somatosensory Bayesian Learning. *PLOS Computational Biology*, *17*(2), e1008068. https://doi.org/10.1371/journal.pcbi.1008068

Gollwitzer, M., Abele-Brehm, A., Fiebach, C. J., Ramthun, R., Scheel, A., Schönbrodt, F., & Steinberg, U. (2021). Management und Bereitstellung von Forschungsdaten in der Psychologie: Überarbeitung der DGPs-Empfehlungen. *Psychologische Rundschau*, *72*(2), 132–146. https://doi.org/10.1026/0033-3042/a000514

Hosseinzadeh, B., Tonello, S., Lopomo, N. F., & Sardini, E. (2025). Printed Sensors for Quantifying Electrodermal Activity and Sweat Rate: A Review. *Sensors*, *25*(22), 6878. https://doi.org/10.3390/s25226878

Huettel, S. A., Song, A. W., & McCarthy, G. (2014). *Functional Magnetic Resonance Imaging* (3rd ed). Sinauer Associates.

Huffman, C. (2024). *Philolaus*. Stanford Encyclopedia of Philosophy.

Huys, Q. J. M., Maia, T. V., & Frank, M. J. (2016). Computational Psychiatry as a Bridge from Neuroscience to Clinical Applications. *Nature Neuroscience*, *19*(3), 404–413. https://doi.org/10.1038/nn.4238

Kerr, N. L. (1998). HARKing: Hypothesizing after the Results Are Known. *Personality and Social Psychology Review*, *2*(3), 196–217. https://doi.org/10.1207/s15327957pspr0203_4

Krantz, D. H., Luce, D., Suppes, P., & Tversky, A. (1971). *Foundations of Measurement, Vol. I*. Dover Publications.

Kreutzer, T. (2021). *License for Scientific Purposes ("Scientific Use License")*. PsychArchives. https://doi.org/10.23668/PSYCHARCHIVES.4988

Laplace, P. S. (1810). Mémoire Sur Les Approximations Des Formules Qui Son Fonctions de Très Grands Nombres et Sur Lear Appliaction Aux Probabilités. *Mémoires de l'Institut de Franc*, *1*, 383–389.

Liapounoff, A. M. (1901). Nouvelle Forme Du Théorème Sur La Limite de Probabilité. *Mémoires de l'Académie Impériale des Sciences de Saint Pétersbourg, VIII*, *12*(5).

Lindborg, A., Musiolek, L., Ostwald, D., & Rabovsky, M. (2023). Semantic Surprise Predicts the N400 Brain Potential. *Neuroimage: Reports*, *3*(1), 100161. https://doi.org/10.1016/j.ynirp.2023.100161

Lindeberg, J. W. (1922). Eine Neue Herleitung Des Exponentialgesetzes in Der Wahrscheinlichkeitsrechnung,. *Mathematische Zeitschrift*, *15*, 211–225.

Logothetis, N. K. (2008). What We Can Do and What We Cannot Do with fMRI. *Nature*, *453*(7197), 869–878. https://doi.org/10.1038/nature06976

Lord, F. M., & Novick, M. R. (1968). *Statistical Theories of Mental Test Scores* (Nachdr. der Ausg. Reading, Mass. [u.a.], 1968). Information Age Publ.

Luck, S. J. (2014). *An Introduction to the Event-Related Potential Technique* (Second edition). The MIT Press.

Mari, L., Wilson, M., & Maul, A. (2021). *Measurement across the Sciences: Developing a Shared Concept System for Measurement*. Springer International Publishing. https://doi.org/10.1007/978-3-030-65558-7

Montague, P. R., Dolan, R. J., Friston, K. J., & Dayan, P. (2012). Computational Psychiatry. *Trends in Cognitive Sciences*, *16*(1), 72–80. https://doi.org/10.1016/j.tics.2011.11.018

Myers, D. G. (2010). *Psychology* (9th ed). Worth Publishers.
Neuman, W. L. (2011). *Social Research Methods: Qualitative and Quantitative Approaches* (7. Aufl.). Allyn & Bacon.
Neurath, O., Hahn, H., & Carnap, R. (1929). *Wissenschaftliche Weltauffassung: Der Wiener Kreis*. Artur Wolf Verlag.
Newton, I. (1934). *Sir Isaac Newton's Mathematical Principles of Natural Philosophy and His System of the World* (F. Cajori, Hrsg.; A. Motte, Übers.). University of California Press.
Novick, M. R. (1966). The Axioms and Principal Results of Classical Test Theory. *Journal of Mathematical Psychology*, *3*(1), 1–18. https://doi.org/10.1016/0022-2496(66)90002-2
Ostwald, D., Bruckner, R., Usée, F., Fleischmann, B., Soch, J., & Mulready, S. (2026). *On Agentic Behavioral Modeling*. https://doi.org/10.48550/arXiv.2604.27894
Ostwald, D., Porcaro, C., Mayhew, S. D., & Bagshaw, A. P. (2012). EEG-fMRI Based Information Theoretic Characterization of the Human Perceptual Decision System. *PLoS ONE*, *7*(4), e33896. https://doi.org/10.1371/journal.pone.0033896
Pedersen, A. P., Kellen, D., Mayo-Wilson, C., Davis-Stober, C. P., Dunn, J. C., Khan, M. A., Stinchcombe, M. B., Kalish, M. L., Tentori, K., & Haaf, J. (2025). Discourse on Measurement. *Proceedings of the National Academy of Sciences*, *122*(5), e2401229121. https://doi.org/10.1073/pnas.2401229121
Popper, K. (1935). *Logik der Forschung: Zur Erkenntnistheorie der modernen Naturwissenschaft*. Julius Springer.
Posada-Quintero, H. F., & Chon, K. H. (2020). Innovations in Electrodermal Activity Data Collection and Signal Processing: A Systematic Review. *Sensors*, *20*(2), 479. https://doi.org/10.3390/s20020479
Quetelet, A. (1846). *Lettres a S.A.R. Le Duc Regnant de Saxe-Cobourg et Gotha, Sur La Theorie Des Probabilites, Appliquee Aux Sciences Morales et Politiques*.
Rat für Informationsinfrastrukturen. (2017). *Datenschutz Und Foschungsdaten - Aktuelle Empfehlungen*.
Regtien, P. P. L., & Finkelstein, L. (Hrsg.). (2004). *Measurement Science for Engineers*. Kogan Page Science.
Reiß, S., & Sarris, V. (2012). *Experimentelle Psychologie: von der Theorie zur Praxis*. Pearson.
Riley, J. (2017). *Understanding Metadata: What Is Metadata, and What Is It For*. National Information Standards Organization.
Romeijn, J.-W. (2025). Philosophy of Statistics. In *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University.
Rosenblatt, B. (1997). The Digital Object Identifier: Solving the Dilemma of Copyright Protection Online. *Journal of Electronic Publishing*, *3*(2). https://doi.org/10.3998/3336451.0003.204
Rost, J. (2004). *Lehrbuch Testtheorie, Testkonstruktion* (2., vollständig überarbeitete und erweiterte Aufl). H. Huber.
Russell, B. (1903). *The Principles of Mathematics*. Cambridge University Press.
Schönbrodt, F., Gollwitzer, M., & Abele-Brehm, A. (2017). Der Umgang mit Forschungsdaten im Fach Psychologie: Konkretisierung der DFG-Leitlinien: Im Auftrag des DGPs Vorstands (17. 09. 2016). *Psychologische Rundschau*, *68*(1), 20–35. https://doi.org/10.1026/0033-3042/a000341
Schütz, A., Brand, M., Selg, H., & Lautenbacher, S. (Hrsg.). (2015). *Psychologie: Eine Einführung in ihre Grundlagen und Anwendungsfelder* (5. Aufl.). Kohlhammer.

Scott, D., & Suppes, P. (1958). Foundational Aspects of Theories of Measurement. *Journal of Symbolic Logic*, *23*(2), 113–128. https://doi.org/10.2307/2964389

Seriès, P. (Hrsg.). (2020). *Computational Psychiatry: A Primer*. The MIT Press.

Shadish, W. R., Cook, T. D., & Campbell, D. T. (2001). *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Houghton Mifflin.

Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant. *Psychological Science*, *22*(11), 1359–1366. https://doi.org/10.1177/0956797611417632

Skinner, B. F. (1945). The Operational Analysis of Psychological Terms. *Psychological Review*, *52*(5), 270–277. https://doi.org/10.1037/h0062535

Speitel, K. (1992). Measurement Assurance. In G. Salvendy (Hrsg.), *Handbook of Industrial Engineering* (S. 2235–2251). Wiley.

Stevens, S. S. (1946). On the Theory of Scales of Measurement. *Science, New Series*, *103*(2684), 677–680. https://www.jstor.org/stable/1671815

Stevens, S. S. (1959). Measurement, Psychophysics, and Utility. In C. W. Churchman & P. Ratoosh (Hrsg.), *Measurement: Definitions and Theories* (S. 18–63). Wiley.

Tal, E. (2020). Measurement in Science. *Stanford Encyclopedia of Philosophy*.

Tsvetanov, K. A., Henson, R. N. A., & Rowe, J. B. (2020). Separating Vascular and Neuronal Effects of Age on fMRI BOLD Signals. *Philosophical Transactions of the Royal Society B: Biological Sciences*, *376*(1815), 20190631. https://doi.org/10.1098/rstb.2019.0631

Ulrich, H., Kock-Schoppenhauer, A.-K., Deppenwiese, N., Gött, R., Kern, J., Lablans, M., Majeed, R. W., Stöhr, M. R., Stausberg, J., Varghese, J., Dugas, M., & Ingenerf, J. (2022). Understanding the Nature of Metadata: Systematic Review. *Journal of Medical Internet Research*, *24*(1), e25440. https://doi.org/10.2196/25440

Usée, F., Melzig, C. A., Ostwald, D., & Collins, A. G. E. (2026). *A Computational Account of Approach-Avoidance Conflict in a Foraging-Inspired Search Paradigm*. PsyArXiv; Center for Open Science. https://doi.org/10.31234/osf.io/7rbng_v1

Wagner, B., Horn, A. B., & Maercker, A. (2014). Internet-Based versus Face-to-Face Cognitive-Behavioral Intervention for Depression: A Randomized Controlled Non-Inferiority Trial. *Journal of Affective Disorders*, *152–154*, 113–121. https://doi.org/10.1016/j.jad.2013.06.032

Weizenbaum, J. (1966). ELIZA—a Computer Program for the Study of Natural Language Communication between Man and Machine. *Communications of the ACM*, *9*(1), 36–45. https://doi.org/10.1145/365153.365168

Weyl, H. (1949). *Philosophy of Mathematics and Natural Science*. Princeton University Press.

Wilkinson, M. D., Dumontier, M., Aalbersberg, Ij. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., da Silva Santos, L. B., Bourne, P. E., Bouwman, J., Brookes, A. J., Clark, T., Crosas, M., Dillo, I., Dumon, O., Edmunds, S., Evelo, C. T., Finkers, R., … Mons, B. (2016). The FAIR Guiding Principles for Scientific Data Management and Stewardship. *Scientific Data*, *3*(1), 160018. https://doi.org/10.1038/sdata.2016.18